Universidade do Minho
Escola de Engenharia
Departamento de Informática

Otimização e Procura

Algoritmos *Population-based*

LICENCIATURA EM ENGENHARIA INFORMÁTICA
MESTRADO integrado EM ENGENHARIA INFORMÁTICA
Inteligência Artificial
2025/26

ISLab
Synthetic Intelligence Lab

Agenda

- Procura vs Otimização
- Procura local vs procura global
- Solução única vs Population-Based
- *Population-Based*
  - **Algoritmos Genéticos (Genetic Algorithms)**
  - Ant Colony Optimization
  - Particle Swarm Optimization

ISLab
Synthetic Intelligence Lab

Otimização e Procura

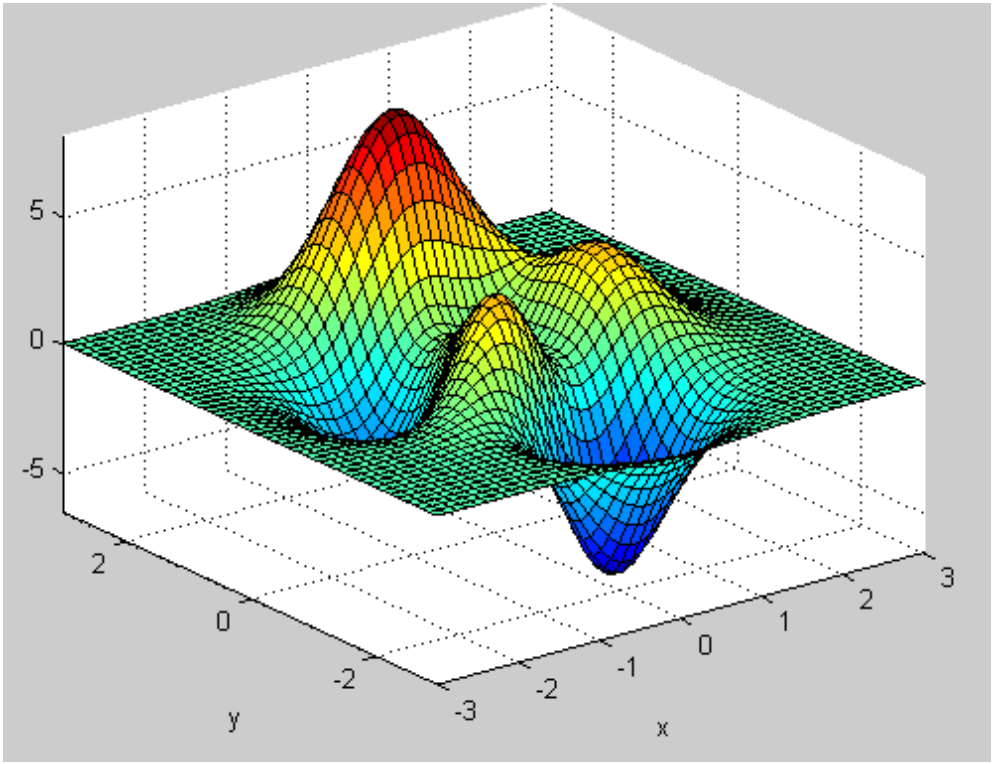

Tjalling C. Koopmans (Nobel Memorial Prize in Economic Sciences (1975)):
– “best use of scarce resources”
– “Mathematical Methods of Organizing and Planning of Production”

Roger Fletcher (Mathematician (1987)):
”The subject of optimization is a fascinating blend of heuristics and rigour, of theory and experiment.”

ISLab
Synthetic Intelligence Lab

Problemas de Otimização

- **Problema de Otimização Matemática (minimização):**

$$\begin{aligned} &\text{minimize} \quad f_0(x) \\ &\text{subject to} \quad g_i(x) \le b_i, \quad i = 1,\ldots,m \end{aligned}$$

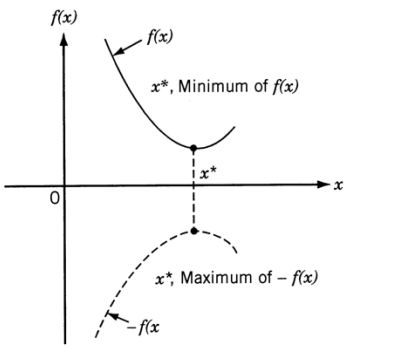

- ***$f_0 : R^n \rightarrow R$:***
  - Função objetivo (calcula um valor)
- ***$x = (x_1,\ldots,x_n)$:***
  - Variáveis controláveis (linearmente independentes)
- ***$g_i : R^n \rightarrow R$: ($I = 1,\ldots,m$):***
  - Restrições (podem ser de outros tipos)

Contínua vs Discreta

Otimização Contínua

“encontrar os máximos e mínimos de funções, possivelmente sujeitos a restrições”;

“Na otimização contínua, as variáveis no modelo podem assumir qualquer valor dentro de um intervalo de valores, geralmente números reais. ...”.

Otimização Discreta

“procurar minuciosamente para encontrar um item com propriedades especificadas entre um conjunto de itens”;

“Ao contrário da otimização contínua, as variáveis usadas (ou algumas delas) são restritas a assumir apenas valores discretos, como os inteiros.”.

ISLab
Synthetic Intelligence Lab

Para além da Procura Clássica
Algoritmos de Melhoria Iterativa

- Em muitos problemas de otimização, o caminho para o objetivo é irrelevante.
- Espaço de Estados = conjunto das configurações completas.
- Algoritmos Iterativos mantém um único estado (corrente) e tentam melhorá-lo.
- Algoritmos de Melhoria Iterativa:
  - Procura Subida da Colina (Hill-Climbing Search)
  - Arrefecimento Simulado (Simulated Annealing)
  - Procura Tabu (Tabu Search)
  - Algoritmos Genéticos (Genetic Algorithms)
  - Colónia de Formigas (Ant Colony Optimization)
  - Enxame de Partículas (Particle Swarm Optimization)

- **Estratégia:** Começar como uma solução inicial do problema e fazer alterações de forma a melhorar a sua qualidade

- **Procura local vs procura global**
  - Algumas meta-heurísticas aplicam métodos de procura local, onde as novas soluções exploradas são "vizinhas" de soluções anteriores (e.g. *Simulated Annealing, Tabu Search*);
  - Outras meta-heurísticas distribuem o processo de procura por todo o espaço de procura (normalmente através de abordagens baseadas em populações).

- **Solução única vs *Population-based***
  - As abordagens de solução única, são iterativas, e orientam o processo de procura através da melhoria da solução anterior;
  - As abordagens baseadas em populações utilizam uma procura em paralelo por parte de vários membros da população, podendo, ou não, existir a troca de informação entre os indivíduos (e.g. *Particle Swarm optimization, Genetic*

Population-Based

- Algoritmos Genéticos
  - Definição do estado como um cromossomo
  - Gerar soluções (cromossomos) a partir de uma população de estado inicial
  - Reprodução, Mutação e Seleção
- Colónia de Formigas (**Ant Colony**)
  - Iniciando vários estados (colónia de formigas)
  - A probabilidade de um caminho ser melhor é determinada pelo número de “formigas” que passam por ele
- Enxame de Partículas (**Particle Swarm**)
  - Vários estados de partida (enxame)
  - A vizinhança é explorada e mantida, a melhor solução e o melhor estado
  - “Partículas” caminham na direção da melhor solução encontrada até agora
  - A velocidade do movimento depende das distâncias para a melhor solução e o melhor estado e a posição do estado

A Escola Evolucionária

- Família de algoritmos de otimização global inspirados na biologia;
- Métodos baseados em população, que fazem evoluir soluções individuais por tentativa e erro;
- Inspirados na teoria da evolução das espécies de Darwin, e em mecanismos biológicos.

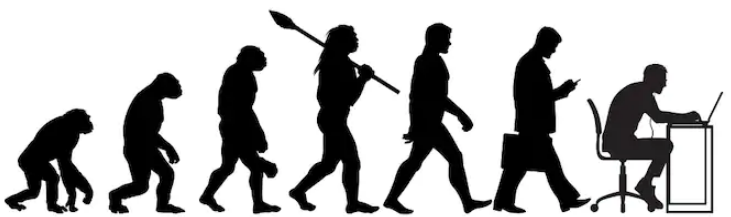

ISLab
Synthetic Intelligence Lab

Perspetiva biológica

- Na biologia:
  - Cada animal da espécie é uma solução para um problema;
  - Há soluções melhores que outras;
  - Melhores soluções têm mais probabilidade de sobreviver, reproduzir-se e passar o seu conteúdo genético para uma nova geração;
  - Soluções mudam de geração em geração:
    - Por cruzamento de material genético dos progenitores;
    - Por mutações aleatórias.
  - Alguns descendentes são melhores, outros são piores;
  - Sem influência externa, a população tende a melhorar com o tempo.

ISLab
Synthetic Intelligence Lab

Perspetiva biológica

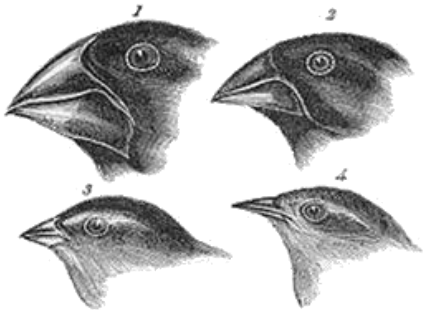

1. Geospiza magnirostris
2. Geospiza fortis
3. Geospiza parvula
4. Certhidea olivacea

ISLab
Synthetic Intelligence Lab

Perspetiva biológica

- Capacidade de adaptação é central
  - Sem ela uma espécie não evolui

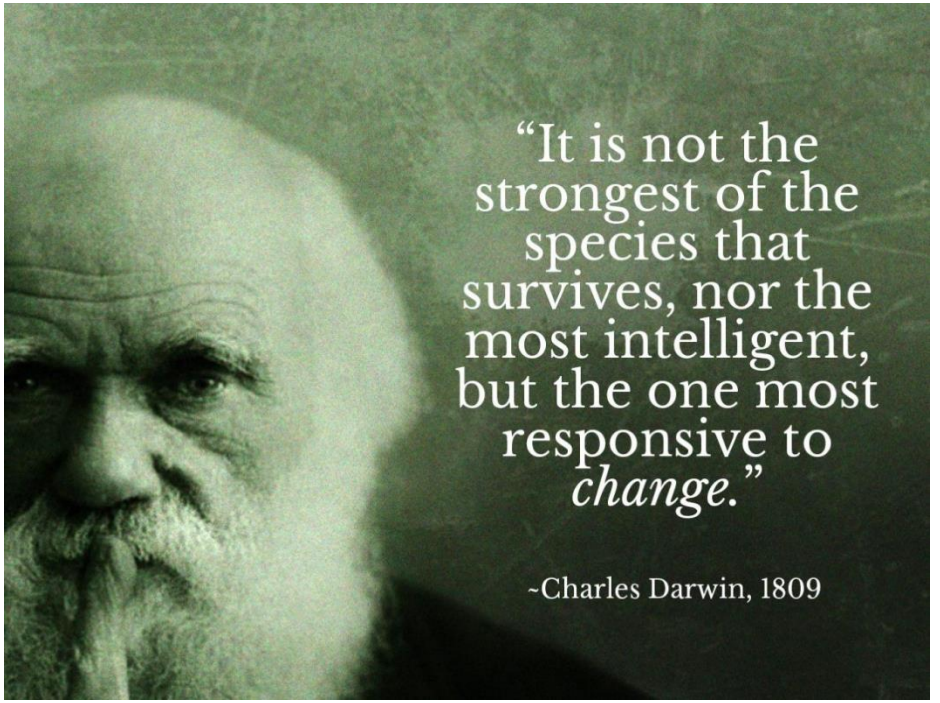

Algoritmos Genéticos

- Algoritmos Genéticos configuram processos adaptativos de procura, num espaço de soluções, por aplicação de operadores modelados de acordo com o conceito de herança, inerente à teoria da evolução das espécies, de Charles Darwin;
- AG's distinguem-se pelo método de procura que utilizam e pelo tratamento específico dos ótimos locais;
- Utilizados para resolver problemas complexos ou que não se sabe bem como resolver;
- Não garantem resultados ótimos;
- Aplicam-se:
  - Em problemas que envolvem a melhoria de soluções (problemas de otimização);
  - Em problemas cujo o cálculo de soluções é difícil ou impossível.

Algoritmos Genéticos

Os algoritmos genéticos diferem dos algoritmos tradicionais de otimização em basicamente quatro aspetos:

- baseiam-se numa codificação do conjunto das soluções possíveis, e não nos parâmetros da otimização em si;
- os resultados são apresentados como uma população de soluções e não como uma solução única;
- não necessitam de nenhum conhecimento derivado do problema, apenas de uma forma de avaliação do resultado;
- usam transições probabilísticas e não regras determinísticas.

- Procedimento iterativo que mantém uma população de estruturas candidatas a soluções, para domínios específicos;
- A cada incremento de tempo (geração), as estruturas da população atual são avaliadas na sua capacidade de serem soluções válidas para o domínio do problema;
- É constituída uma nova população de soluções candidatas, baseada na sua avaliação e pela aplicação de operadores genéticos.

Aplicações de algoritmos genéticos

- Otimização;
- Sistemas de controlo dinâmicos;
- Descoberta de novas topologias conexionistas;
- Criatividade artificial;
- …

ISLab
Synthetic Intelligence Lab

Algoritmos evolutivos

- Os algoritmos genéticos são uma classe particular de algoritmos evolutivos que usam técnicas inspiradas pela biologia evolutiva como:
  - hereditariedade,
  - seleção natural;
  - recombinação;
  - mutação.
- O AG é um processo estocástico no qual os estados sucessores são gerados pela combinação de dois estados pais em vez de modificar um único estado.

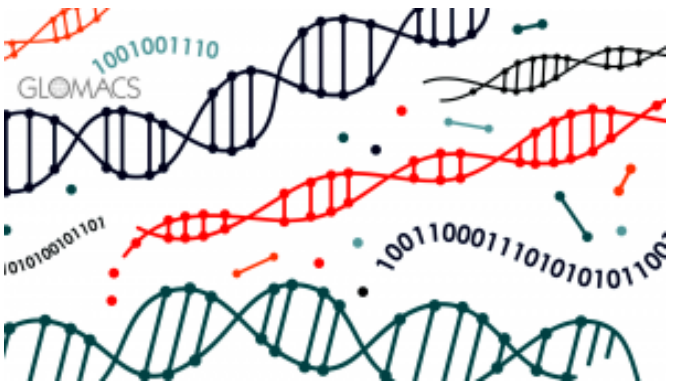

Image Source: http://glomacs.com/articles/genetic-algorithms

Conceitos básicos

- Indivíduo ou Cromossoma
  - Uma solução específica, constituída por um ou mais elementos
- Gene
  - Uma posição no cromossoma (um elemento)
- Alelo
  - O valor de um gene
- População
  - Conjunto de indivíduos
- Geração
  - Conjunto de todos os novos indivíduos "nascidos" a partir de uma mesma população pai
  - Mede a passagem do tempo
- Espaço de procura
  - Os limites dos valores dos Genes

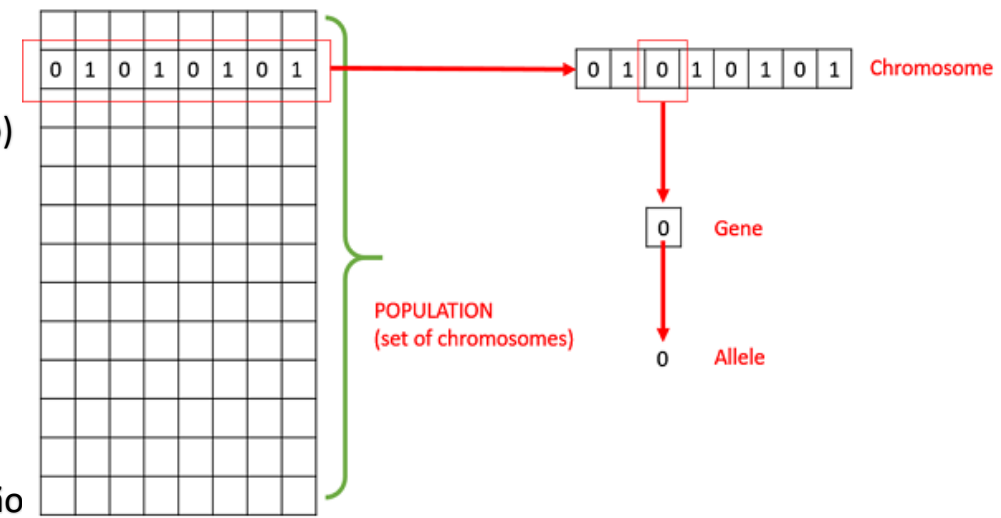

ISLab
Synthetic Intelligence Lab

Modelo de Representação

- O **ambiente**, os **inputs** e os **outputs** são representados por **conjuntos de símbolos**, de **tamanho fixo**, de um dado alfabeto:
  - { 0; 1 }
  - { X; Y; Z }
  - { i; ii; iii; iv; iv; v; … }
  -
  - …

- Codificar candidatos de uma forma que facilite, nomeadamente, a mutação e o cruzamento;
- A representação típica do candidato é uma *string* binária;
- Esta *string* pode ser considerada como o código genético de um candidato – daí o termo "algoritmo genético"!;
- Outras representações são possíveis, mas geralmente dificultam o cruzamento e a mutação.

ISLab
Synthetic Intelligence Lab

Modelo de Representação

- Cada ponto, no domínio do ambiente, pode ser considerado um **indivíduo**, representado por uma sequência (*string*) gerada a partir do alfabeto, constituído na forma:

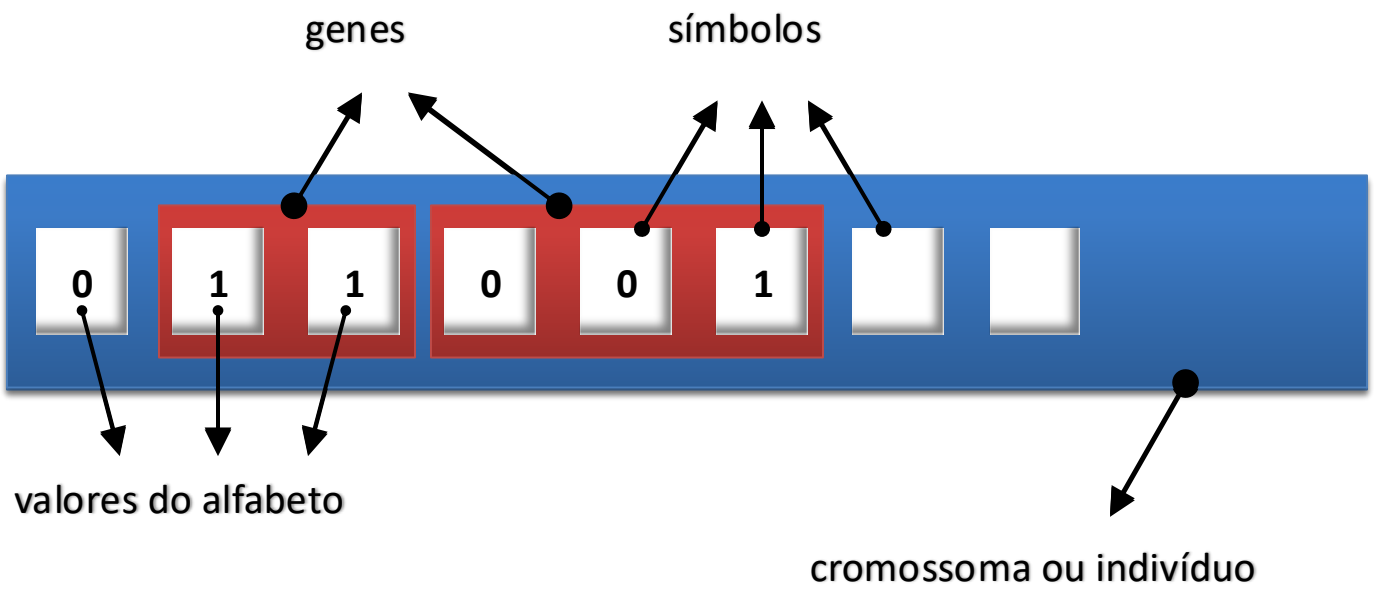

Representação do Problema

- A entidade básica par a representação do conhecimento é o **cromossoma**, composto por **genes**;
- Supondo a utilização de uma codificação binária:
  - Para representar 8 valores (p.ex., as 7 cores do arco íris mais o preto):
    - utilizar 3 símbolos em 1 gene $\rightarrow 2^3 = 8$
  - Para representar 5 valores (ex., para representar os dedos de uma mão ou as cores da íris do olho):
    - utilizar 3 símbolos em 1 gene $\rightarrow 2^3 = 8 > 5$
    - utilizar 2 símbolos em 1 gene $\rightarrow 2^2 = 4 < 5$

ISLab
Synthetic Intelligence Lab

Função de Avaliação

- Conjunto de soluções, torna-se necessário avaliar a adequação de cada uma delas;
- É usada para identificar os indivíduos (cromossomas) mais aptos;
- Será com base nesta avaliação que as melhores soluções serão escolhidas para darem origem à geração seguinte;
- Para isto, é definida a função de fitness
  - A função de fitness aceita como parâmetro uma solução e devolve um valor numérico que representa quão boa uma solução é…
  - Valor não é geralmente absoluto mas relativo:
    - Porque geralmente não conhecemos o melhor/pior caso;
    - Apenas permite comparar as soluções entre si, não sabemos quão longe estamos da melhor solução possível.
  - □(

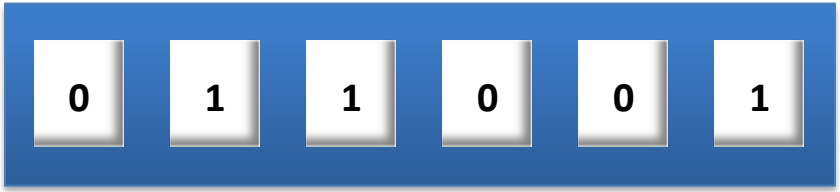

ISLab
Synthetic Intelligence Lab

Avaliação das Soluções

- A **função de avaliação** deve ser **suave** e **regular** no sentido de evitar ao máximo que a procura "caia" frequentemente em máximos ou mínimos locais;

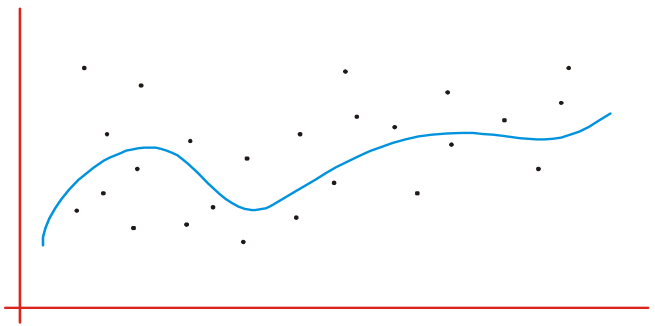

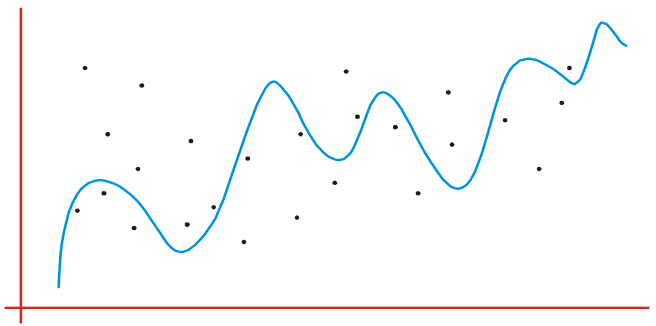

- □(0 1 1 0 0 1) = X

ISLab
Synthetic Intelligence Lab

Avaliação das Soluções

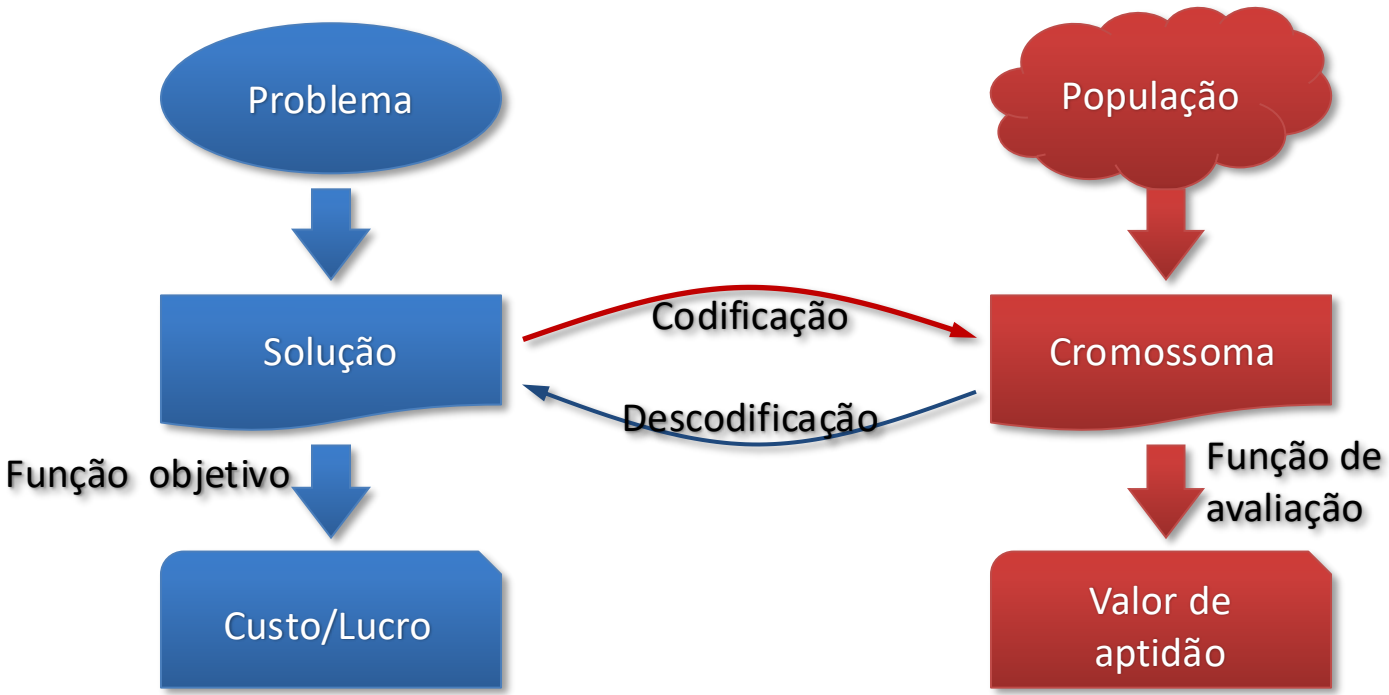

Seleção

- Na fase de seleção, escolhem-se os indivíduos que darão origem à nova geração;
- A Seleção de progenitores para reprodução deve garantir que os indivíduos com maior valor de aptidão tenham, proporcionalmente, mais descendentes;
- Idealmente, cada indivíduo deverá ser representado por um número de descendentes equivalente ao rácio entre o seu valor de aptidão e o valor médio da população;
- Existem diversas estratégias de Seleção:
  - Baseados no Fitness – Utilizar os melhores N elementos da população para gerar a próxima população
  - Baseado na idade – São “expulsas” as N soluções mais antigas
  - Método da Roleta;
  -

Seleção

- Selecionar os melhores indivíduos pode resultar numa convergência prematura. As melhores estratégias de seleção são projetados para manter diversidade na população:
  - Rank - escolher os melhores indivíduos;
  - Roulette wheel: probabilidade de seleção é proporcional à aptidão;
  - Tournament - um número inicialmente grande é selecionado via roleta, então os melhores classificados são escolhidos;
  - Elite - em combinação com outras estratégias de seleção, manter sempre o indivíduo mais apto por perto.

ISLab
Synthetic Intelligence Lab

Seleção

Em geral, usa-se o algoritmo de seleção probabilística, onde os cromossomas são ordenados de acordo com a função-objetivo (fitness) e lhes são atribuídas probabilidades decrescentes de serem escolhidos - probabilidades essas proporcionais à razão entre a adequação do indivíduo e a soma das adequações de todos os indivíduos da população.

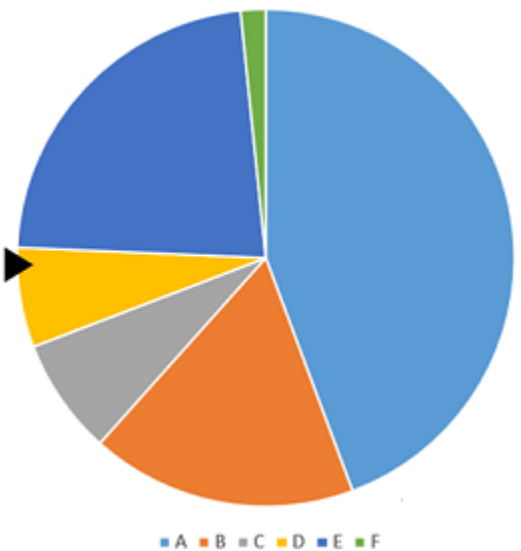

Chromosome	Fitness Value
A	8.2
B	3.2
C	1.4
D	1.2
E	4.2
F	0.3

Reprodução

- A fase de reprodução tem como objetivo criar a nova geração seguinte;
- Cada nova geração é criada através da aplicação de operadores genéticos à geração anterior:
  - Cruzamento;
  - Mutação.
- Tipicamente, é definida na configuração a proporção de aplicação destes operadores:
  - Qual a percentagem da nova geração que deve ser gerada por reprodução, por cruzamento, e qual deve ser mantida inalterada.

ISLab
Synthetic Intelligence Lab

Cruzamento

- O objetivo do cruzamento é o de conseguir, nos descendentes, uma combinação do material genético dos progenitores;
- O operador Cruzamento é aplicado a dois indivíduos da população, produzindo outros dois indivíduos para a população da geração seguinte;
- Existem diferentes formas de implementar o operador:

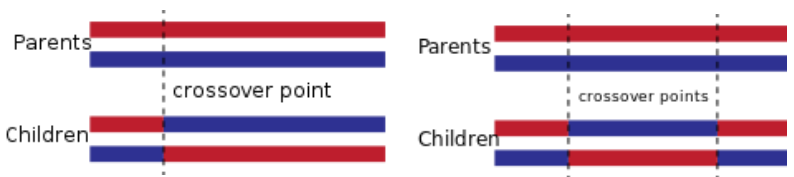

Cruzamento

- **Recombinação ou Crossover**
  - Uma vez selecionados os indivíduos, estes passam, com uma probabilidade pré-estabelecida, pelo processo de cruzamento (crossover), onde partes dos genes dos pais são combinadas para geração de filhos.

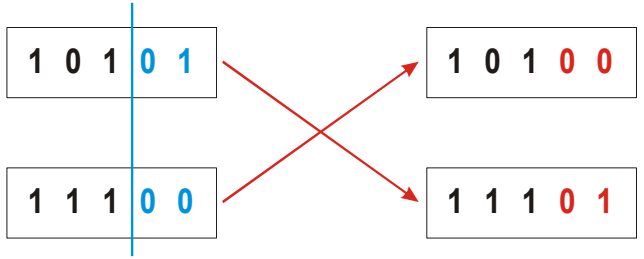

ISLab
Synthetic Intelligence Lab

Mutação

- O operador genético Mutação pretende ser uma analogia com a mutação genética dos seres vivos;
- A mutação actua sobre os indivíduos e efetua algum tipo de alteração na sua estrutura. A importância deste operador reside no fato de garantir que outras alternativas serão exploradas;
- Aplica-se com uma baixa probabilidade;
- Garante que é sempre possível chegar a qualquer posição do problema;
- Previne a perda total de informação pela seleção e/ou eliminação.

Seleção e reprodução

Podem ser utilizadas estratégias de seleção e reprodução muito distintas:

- Selecionar o top 50% e cada solução gera uma nova (por mutação) ou cada par de soluções gera duas novas (por cruzamento);
- Selecionar todas as soluções, gerar novas soluções com base nelas, e depois selecionar as melhores (de acordo com o tamanho da população);
- Cada solução tem uma probabilidade de ser selecionada que é proporcional ao seu valor de fitness;
- ….

Seleção e reprodução

- Os operadores de reprodução devem ainda ser configuráveis através de parâmetros simples, mas que permitam controlar a magnitude das mudanças que introduzem na população.
- Exemplos:
  - Mr – mutation rate
  - Cr – crossover rate

Algoritmos Genéticos

```
function GENETIC-ALGORITHM(population, FITNESS-FN) returns an individual
  inputs: population, a set of individuals
          FITNESS-FN, a function that measures the fitness of an individual

  repeat
    new_population ← empty set
    for i = 1 to SIZE(population) do
      x ← RANDOM-SELECTION(population, FITNESS-FN)
      y ← RANDOM-SELECTION(population, FITNESS-FN)
      child ← REPRODUCE(x, y)
      if (small random probability) then child ← MUTATE(child)
      add child to new_population
    population ← new_population
  until some individual is fit enough, or enough time has elapsed
  return the best individual in population, according to FITNESS-FN

function REPRODUCE(x, y) returns an individual
  inputs: x, y, parent individuals

  n ← LENGTH(x); c ← random number from 1 to n
  return APPEND(SUBSTRING(x, 1, c), SUBSTRING(y, c + 1, n))
```

Fonte: Russell and Norvig, (2009) Artificial Intelligence - A Modern Approach.

Funcionamento

Estrutura de um algoritmo genético básico

1. **[Início]** Gerar uma população aleatória de *n* cromossomas (apropriados para a solução do problema)
2. **[Fitness]** Avaliar cada cromossoma *x* na população através da função de fitness *f(x)*
3. **[Nova População]** Criar uma nova população através da repetição dos seguintes passos até a população estar completa
    - **[Seleção]** Escolher 2 cromossomas da população de acordo com as suas avaliações de fitness (quanto melhor o fitness melhor a sua probabilidade de ser selecionado)
    - **[Recombinação ou Crossover]** Tendo em conta a probabilidade de crossover, combinando 2 cromossomas formando assim um novo cromossoma.
    - **[Mutação]** Tendo em conta a probabilidade de mutação, mutar cromossomas na população).
    - **[Aceitação]** Por o novo cromossoma na nova população
4. **[Substituir]** Use os novos cromossomas criados na população de cromossomas para correr de novo o programa substituindo cromossomas da população anterior
5. **[Testar]** Se a condição de paragem é satisfeita, parar e devolver a melhor solução encontrada na população corrente.
6. **[Loop]** Ir para o passo 2

ISLab
Synthetic Intelligence Lab

Funcionamento

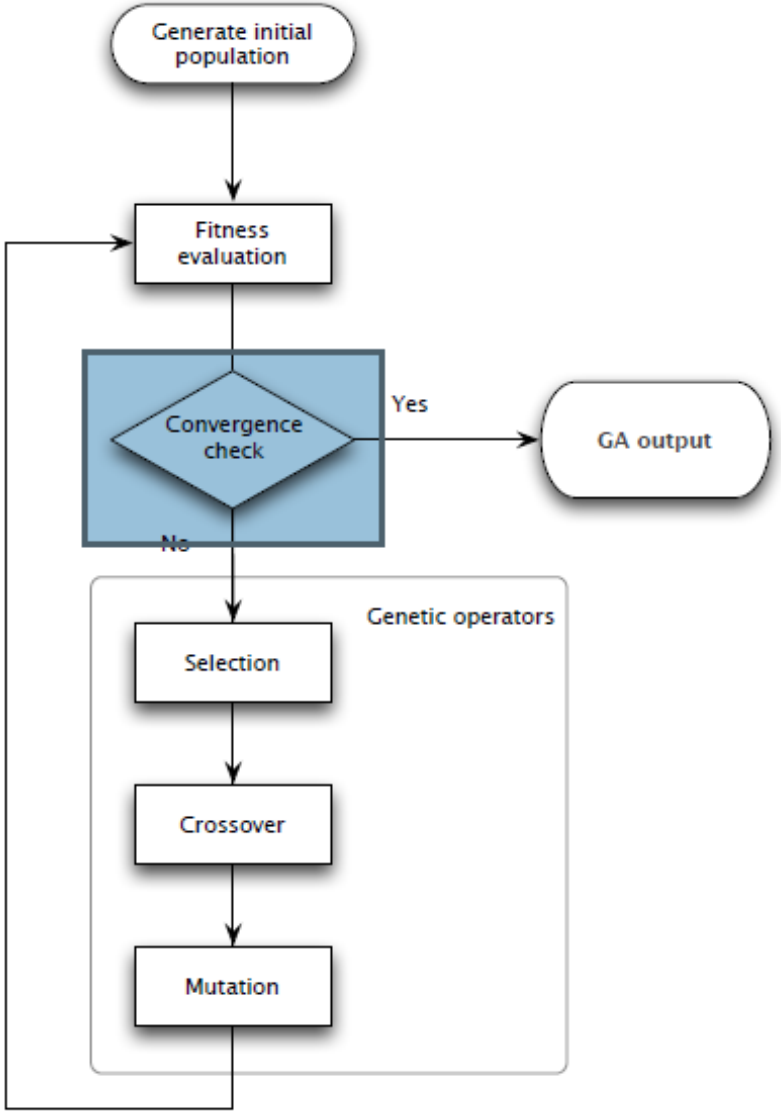

Modelos de população

- Há vários modelos de população diferentes:
  - Steady State:
    - Em cada iteração são gerados N novos indivíduos
    - Estes subsituem N indivíduos da geração anterior
    - Também conhecidos como Algoritmos Genéticos incrementais
    - N deve ser inferior ao tamanho da população
  - Generational:
    - São gerados N novos indivíduos
    - N é igual ao tamanho da população
    - Toda a população é substituída pela nova geração

Configuração

- Não é possível "adivinhar", à partida, quais as melhores decisões na implementação de um Algoritmo Genético;
- Assim, o AG deve ser tão configurável quanto possível, para permitir facilmente testar diferentes configurações;
- Parâmetros frequentes incluem:
  - Tamanho da população
  - Numero máximo de iterações
  - Estratégia de seleção
  - Peso de cada operador genético na reprodução
  - Fator de mutação (e.g. número entre 0 – sem mutação e 1 – completamente aleatório)
  - …

Parâmetros

- Tamanho da População (N):
  - uma **população pequena** pode provocar um mau desempenho, por não cobrir adequadamente o espaço do problema, gerando soluções locais;
  - uma **população grande** pode evitar os problemas anteriores, mas pode afetar a eficiência computacional do sistema.
- Taxa de Cruzamento (Cr):
  - quantidade de cromossomas utilizados para cruzamento: N x Cr.
- Taxa de Mutação (Mr):
  - a mutação é utilizada para aumentar a variabilidade da população;
  - cada gene tem uma probabilidade finita de mudar;
  - uma **baixa taxa** de mutação permite que um gene “gele” num valor;
  - uma **alta taxa** de mutação resulta numa procura aleatória de soluções;
  - sendo L o comprimento do cromossoma, ocorrerão Mr x N x L mutações.

Parâmetros

- Taxa de Substituição (Generation Gap - Gr):
  - controla a percentagem da população a ser substituída em cada geração;
  - são substituídos N x Gr estruturas da população;
  - se Gr = 1, significa que toda a população deve ser substituída durante cada geração.
- Estratégia de Seleção:
  - a reprodução é feita com base na proporção do valor de *fitness* das estruturas da população atual;
  - as estruturas com melhor desempenho são as que passam para a próxima geração.
- Função de Avaliação:
  - serve para manter a diversidade da população durante a evolução;
  - o surgimento de um "super cromossoma" dominante na população deve ser evitado, para que o problema seja eficientemente explorado.

ISLab
Synthetic Intelligence Lab

Critérios de paragem

- Os algoritmos Genéticos não garantem uma solução ótima;
  - Assim, é impossível saber quando parar.
- Torna-se necessário definir um ou mais critérios de paragem:
  - Atingir um número pré-definido de iterações;
  - Atingir um valor de fitness;
  - …
- Quando o algoritmo termina, escolhe-se a melhor solução encontrada ao longo da evolução.
  - Não existe necessariamente na última geração…

Quando

- Funções multimodais;
- Funções discretas ou contínuas;
- Funções multidimensionais, incluindo combinatória;
- Dependência não linear de parâmetros;
- Frequentemente usado para resolver problemas NP;
- Não use AG quando outro método, como hill-climbing, etc., funciona bem ou pelo menos antes de tentar esse tipo de método!

ISLab
Synthetic Intelligence Lab

Knapsack

- O problema da mochila (Knapsack problem) é um problema de otimização combinatória;
- Pretende-se preencher uma mochila com objetos de diferentes pesos e valores;
- O objetivo é que se preencha a mochila com o maior valor possível, não ultrapassando o peso máximo;
- O problema da mochila é um dos 21 problemas NP-completos de Richard Karp, expostos em 1972;
- A formulação do problema é extremamente simples, porém sua solução é complexa;

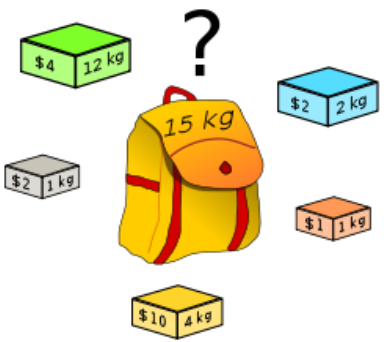

- Exemplo: O problema de mochila unidimensional: que caixas devem ser escolhidas para maximizar a quantidade de dinheiro mantendo o peso total abaixo ou igual a 15 kg?
- Um problema de restrição múltipla poderia considerar tanto o peso quanto o volume das caixas.

Fonte: Luís Paulo Reis, Artificial Intelligence (2019), Universidade do Porto

Knapsack

Exemplo:

N = 8
Capacidade (C) = 50

	1	2	3	4	5	6	7	8
Valor	4	3	6	7	2	9	7	6
Peso	12	16	8	21	16	11	6	12

Objectivo

Maximizar $\sum_i O_i \times v_i$

Restrição $\sum_i O_i \times p_i \leq 50$

?

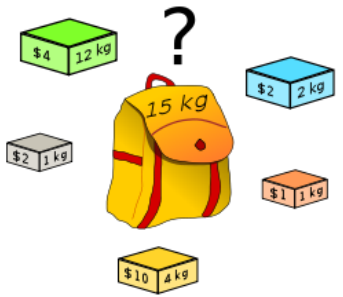

Representação das soluções: Oi

1	1	0	0	0	0	1	0

Soluções Inválidas

Soluções Inválidas: Como resolver?

- Reparar
- Alterar a representação
- Penalizar

Uma função de penalização define em que quantidade a solução X viola a restrição R

Mede a distância a que a solução está de uma região de aceitação

Transforma um problema com restrições num problema sem restrições

ISLab
Synthetic Intelligence Lab

Exemplo - Knapsack

	1	2	3	4	5	6	7	8
Valor	4	3	6	7	2	9	7	6
Peso	12	16	8	21	16	11	6	12

Avaliação

$$f(s) = \begin{cases} \sum_i O_i \times v_i & se\ solução\ válida \\ 0 & se\ solução\ não\ válida \end{cases}$$

$$f(s) = \sum_i O_i \times v_i - p(s)$$

Onde $$p(s) = \begin{cases} \alpha\left(\sum_i O_i \times v_i\right) - C & se\ solução\ não\ válida \\ 0 & se\ solução\ válida \end{cases}$$

A penalização de uma solução válida é zero e é proporcional ao grau de violação das restrições

ISLab
Synthetic Intelligence Lab

Exemplo - Knapsack

	1	2	3	4	5	6	7	8
Valor	4	3	6	7	2	9	7	6
Peso	12	16	8	21	16	11	6	12

Criar e avaliar a população inicial

Solução								Valor	Peso	p(s)	f(s)
1	1	0	0	0	0	1	0	**14**	**34**	**0**	**14**
0	0	0	1	1	0	1	1	**22**	**55**	**5**	**17**
0	1	0	1	0	0	1	0	**17**	**43**	**0**	**17**
1	0	0	0	0	0	1	0	**11**	**18**	**0**	**11**
0	1	1	1	1	0	1	0	**25**	**67**	**17**	**8**
1	0	0	1	0	0	1	1	**24**	**51**	**1**	**23**
0	1	0	1	0	1	1	0	**26**	**54**	**4**	**22**
1	1	0	0	0	0	1	1	**20**	**46**	**0**	**20**

ISLab
Synthetic Intelligence Lab

Recombinação

Recombinar soluções

Combinar o material genético de dois progenitores para gerar novas soluções

Objetivo: Combinar características interessantes de duas soluções

Recombinação por ponto de corte

- Alinhar os dois progenitores
- Selecionar um ponto de corte aleatório
- Combinar secções complementares para obter descendentes

ISLab
Synthetic Intelligence Lab

Recombinação

População inicial

Solução (progenitores)								Valor	Peso	p(s)	f(s)
1	1	0	0	0	0	1	0	14	34	0	14
0	0	0	1	1	0	1	1	22	55	5	17
0	1	0	1	0	0	1	0	17	43	0	17
1	0	0	0	0	0	1	0	11	18	0	11
0	1	1	1	1	0	1	0	25	67	17	8
1	0	0	1	0	0	1	1	24	51	1	23
0	1	0	1	0	1	1	0	26	54	4	22
1	1	0	0	0	0	1	1	20	46	0	20

Recombinação

Solução (filhos)								Valor	Peso	p(s)	f(s)
0	0	0	1	1	0	1	0	16	43	0	16
1	0	0	0	0	0	1	1	17	30	0	17
0	1	0	1	0	0	1	1	23	55	5	18
1	1	0	0	0	1	1	0	23	45	0	23

ISLab
Synthetic Intelligence Lab

Mutação

Alteração do valor de um gene (mutação binária)

Cria variabilidade no conjunto das soluções

Introduz alterações no material genético

Objetivo: Introduzir diversidade na população

População filhos

Solução (filhos)								Valor	Peso	p(s)	f(s)
0	0	0	1	1	0	1	0	16	43	0	16
1	0	0	0	0	0	1	1	17	30	0	17
0	1	0	1	0	0	1	1	23	55	5	18
1	1	0	0	0	1	1	0	23	45	0	23

Mutação

Solução (filhos)								Valor	Peso	p(s)	f(s)
0	0	0	1	1	0	1	0	16	43	0	16
1	0	0	0	0	1	1	1	26	41	0	26
0	1	0	1	0	0	1	1	23	55	5	18
1	1	0	0	0	1	1	0	23	45	0	23

Vantagens

- Não necessita muito conhecimento do domínio;
- É mais rápido e eficiente que alguns métodos tradicionais;
- Pode ser facilmente paralelizável;
- Otimiza funções discretas e contínuas;
- Encontra múltiplas “boas” soluções;
- Encontra sempre uma solução, mesmo que não seja a melhor;
- Útil quando o espaço da solução é muito grande.

ISLab
Synthetic Intelligence Lab

Desvantagens

- Não são aplicáveis a qualquer problema;
- O cálculo repetido da função de fitness pode ser pesado computacionalmente;
- Não garante soluções ótimas nem a qualidade da solução encontrada;
- Se mal implementado, pode não convergir para a solução ótima.

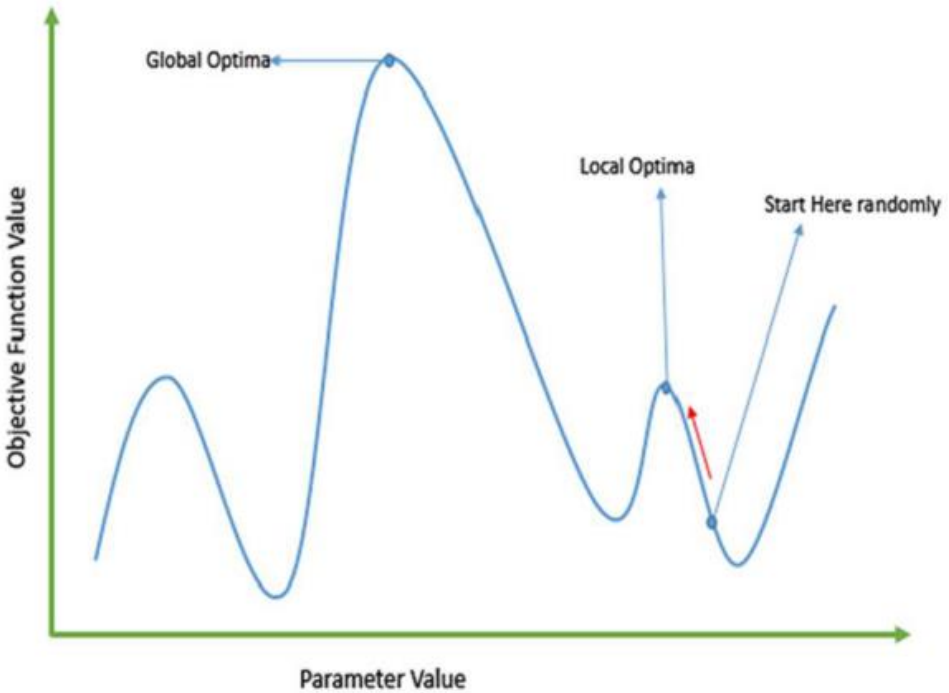

ISLab
Synthetic Intelligence Lab

Outros Exemplos

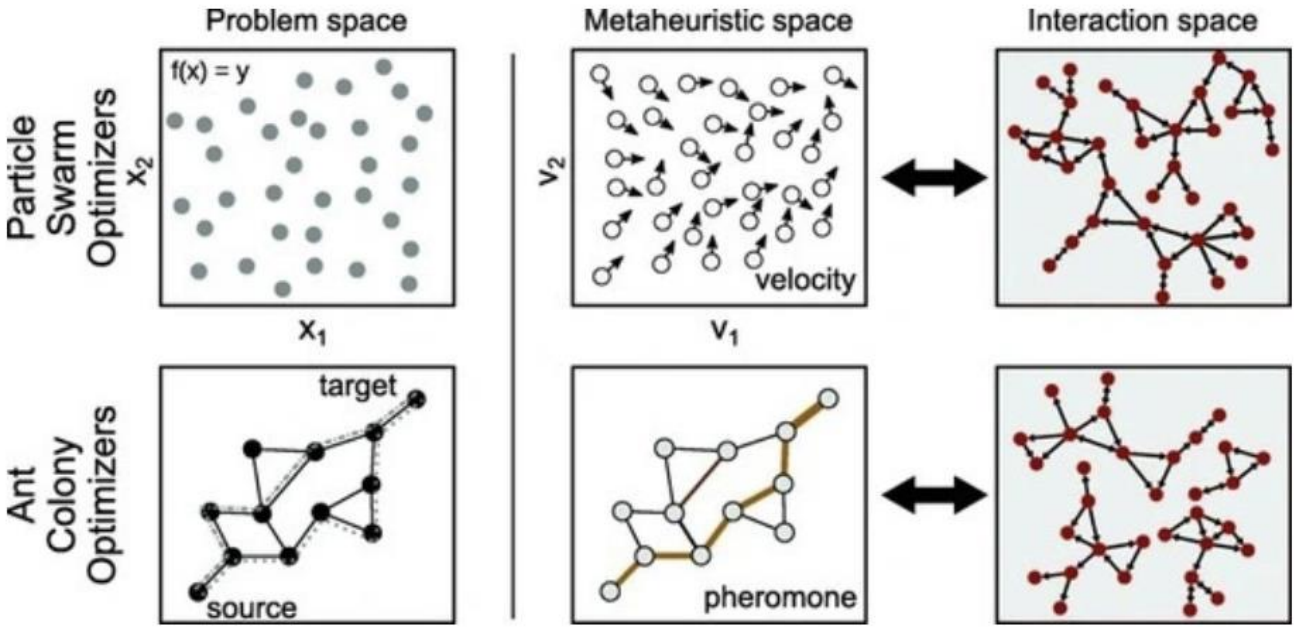

Image source:

Marcos Oliveira, Diego Pinheiro, Mariana Macedo, Carmelo Bastos-Filho & Ronaldo Menezes

Applied Network Science volume 5, Article number: 24 (2020)

ISLab
Synthetic Intelligence Lab

Referências

- Holland, John H. “Genetic Algorithms.” *Scientific American* 267 (1): 66–73, 1992.
- David Goldberg, “Genetic Algorithms in Search, Optimization, and Machine Learning”, Addison Wesley, 1989.
- Russell and Norvig, (2009) Artificial Intelligence - A Modern Approach, 3rd edition, ISBN-13: 9780136042594.
- Michalewicz, Zbigniew. *Genetic Algorithms + Data Structures = Evolution Programs*. Springer Science & Business Media, 2013.
- Yang, Xin-She. *Nature-Inspired Optimization Algorithms*. Elsevier, 2014.
- Miguel Rocha, José Neves, “Computação Genética e Evolucionária”, Universidade do Minho, 2000

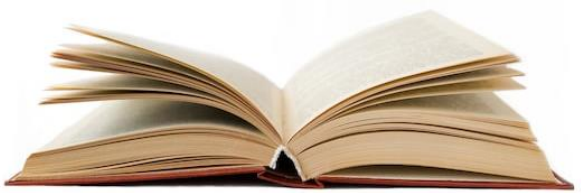

Universidade do Minho
Escola de Engenharia
Departamento de Informática

Otimização e Procura

Algoritmos *Population-based*

LICENCIATURA EM ENGENHARIA INFORMÁTICA
MESTRADO integrado EM ENGENHARIA INFORMÁTICA
Inteligência Artificial
2025/26