

Universidade do Minho

Escola de Engenharia

Licenciatura em Engenharia Informática

Mestrado Integrado em Engenharia Informática

Unidade Curricular de Aprendizagem e Decisão Inteligentes

Ano Letivo de 2025/2026

Conceção de modelos de aprendizagem e decisão

Jorge Rafael Machado Fernandes
A104168

Diogo Teixeira Fernandes
A104260

Hugo Soares
A107293

ADI

Data da Receção	
Responsável	
Avaliação	
Observações	

Conceção de modelos de aprendizagem e decisão

Índice

1. Introdução	1
2. CRISP-DM	2
3. Dataset Atribuído	3
3.1. Business Understanding	3
3.2. Data Understanding	4
3.3. Data Preparation	5
3.4. Configurações Experimentais	6
3.5. Modeling e Evaluation	7
3.5.1. Modeling e Evaluation - Classificação	7
3.5.2. Modeling e Evaluation - Regressão	8
3.6. Análise Crítica	8
3.7. Conclusão do Dataset Atribuído	9
4. Dataset Grupo	10
4.1. Business Understanding	10
4.2. Data Understanding	10
4.3. Data Preparation	13
4.3.1. Remoção de Duplicados	14
4.3.2. Tratamento de Valores em Falta	14
4.3.3. Tratamento de Outliers	14
4.3.4. Seleção de Features para Modelação	15
4.3.5. Normalização	15
4.3.6. Divisão Treino/Teste	15
4.3.7. Balanceamento de Classes	15
4.4. Modelação e Avaliação — Regressão	15
4.4.1. Linear Regression	17
4.4.2. Simple Regression Tree	17
4.4.3. Random Forest (Regressão)	17
4.4.4. Gradient Boosted Trees (Regressão)	17
4.4.5. RProp MLP — Rede Neuronal (Regressão)	17
4.4.6. Resultados Comparativos — Regressão	17
4.5. Modelação e Avaliação — Classificação	17
4.5.1. Decision Tree	18
4.5.2. Random Forest (Classificação)	18
4.5.3. Naive Bayes	18
4.5.4. SVM (SVM Learner)	18
4.5.5. Resultados Comparativos — Classificação	18
4.6. Análise Crítica	18
4.6.1. Regressão	18
4.6.2. Classificação	19
4.7. Conclusão do Dataset Grupo	19

Lista de Figuras

Figura 1	CRISP - DM	2
Figura 2	Missing Values	4
Figura 3	Distribuição inicial dos valores de Productions antes da normalização	4
Figura 4	Data Preparation Workflow	5
Figura 5	Gráfico de análise dos valores fotovoltaicos por hora	5
Figura 6	Branch Except-Photovoltaics - Modelos de classificação	7
Figura 7	Branch Reg-Weather&Time-only - Modelos de regressão	8
Figura 8	Distribuição da variável <code>popularity</code> — histograma obtido com o nodo Histogram no KNIME.	12
Figura 9	Matriz de correlação entre atributos acústicos — nodo Linear Correlation no KNIME.	13
Figura 10	Ramo de preparação de dados no KNIME — desde a leitura do CSV até à divisão treino/teste.	14
Figura 11	Box plot de <code>popularity</code> antes e depois do tratamento de outliers — nodo Numeric Outliers no KNIME.	15
Figura 12	Ramo de regressão no KNIME — cinco modelos com Regression Predictor e Numeric Scorer individuais.	16

1. Introdução

No âmbito da unidade curricular de Aprendizagem e Decisão Inteligentes, foi desenvolvido um projeto prático com o objetivo de aplicar técnicas de análise de dados e modelos de aprendizagem automática sobre dois conjuntos de dados distintos: um dataset atribuído pela equipa docente e um dataset escolhido pelo grupo.

O trabalho foi desenvolvido com recurso à plataforma KNIME, permitindo construir workflows de preparação, transformação, modelação e avaliação dos dados.

Ao longo do projeto, procurou-se não apenas obter bons resultados preditivos, mas também compreender a qualidade dos dados, justificar as decisões de pré-processamento e avaliar criticamente o impacto das variáveis utilizadas nos modelos.

2. CRISP-DM

Para orientar o desenvolvimento do projeto foi seguida a metodologia CRISP-DM, composta pelas fases de **Business Understanding**, **Data Understanding**, **Data Preparation**, **Modeling** e **Evaluation**. A fase de **Deployment** não foi considerada, uma vez que o objetivo do trabalho se centra na análise, preparação, modelação e avaliação dos dados em contexto académico.

Esta metodologia permitiu estruturar o trabalho de forma iterativa: inicialmente foi definido o problema e analisado o domínio dos dados; de seguida, procedeu-se à exploração e identificação de problemas de qualidade; posteriormente, os dados foram preparados e transformados; por fim, foram construídos e avaliados diferentes modelos de Machine Learning, comparando os resultados obtidos e retirando conclusões críticas.




Figura 1: CRISP - DM

3. Dataset Atribuído

3.1. Business Understanding

O dataset atribuído contém informação sobre produção energética e variáveis meteorológicas registadas ao longo do tempo. O objetivo foi estudar a relação entre condições atmosféricas, informação temporal e produção energética.

Foram definidos dois problemas: um de classificação, para prever a classe Productions, e outro de regressão, para prever Photovoltaics (kWh). Como algumas variáveis energéticas podem estar próximas da definição do target Productions, foram criadas diferentes configurações experimentais para comparar modelos explicativos com modelos mais realistas.

3.2. Data Understanding

O dataset original contém 8783 registos e 24 colunas, incluindo variáveis energéticas, meteorológicas, temporais e a classe alvo Productions.

A análise inicial revelou três aspetos relevantes: existência de missing values, inconsistências nos nomes das classes de Productions e problemas na coluna Date/Time. As colunas rain e precipitation apresentavam cerca de 80% de valores em falta, justificando a sua remoção. As restantes variáveis apresentavam, em geral, cerca de 10% de missing values.

A variável Productions continha valores inconsistentes, como Alto, Hgh, Baixo, Lw e MedLow, que foram posteriormente uniformizados. A coluna Date/Time seguia maioritariamente o formato yyyy-MM-dd HH:mm:ss, mas continha algumas datas inválidas e dois registos fora do ano dominante de 2024.

De modo a facilitar a análise exploratória, foram utilizados os nós Statistics, Statistics View e PieChart. Os resultados relativos aos missing values foram posteriormente organizados numa folha Excel, permitindo apresentar a informação de forma mais compacta no relatório.

Coluna	Nº Missing	% Missing
precipitation (mm)	7023	79.96%
rain (mm)	7009	79.80%
cloud_cover (%)	956	10.88%
direct_normal_irradiance (W/m²)	934	10.63%
Wind_Direction_100m	918	10.45%
Wind_Direction_10m	917	10.44%
Cogeneration (kWh)	902	10.27%
Wind (kWh)	895	10.19%
temperature_2m (°C)	888	10.11%
shortwave_radiation (W/m²)	885	10.08%
relative_humidity_2m (%)	884	10.06%
wind_speed_10m (km/h)	877	9.99%
terrestrial_radiation (W/m²)	877	9.99%
snowfall (cm)	874	9.95%
diffuse_radiation (W/m²)	870	9.91%
Distribution Network (kWh)	868	9.88%
wind_speed_100m (km/h)	867	9.87%
Other Technologies (kWh)	862	9.81%
direct_radiation (W/m²)	859	9.78%
Hydro (kWh)	858	9.77%
Photovoltaics (kWh)	830	9.45%
RowID	0	0.00%
Date/Time	0	0.00%
Productions	0	0.00%

Figura 2: Missing Values




Figura 3: Distribuição inicial dos valores de Productions antes da normalização

3.3. Data Preparation

A preparação dos dados incluiu a remoção de colunas sem utilidade preditiva ou com demasiados valores em falta, nomeadamente RowID, rain e precipitation. Os valores NaN foram convertidos para missing values reconhecidos pelo KNIME, e a variável Productions foi normalizada para cinco classes finais.

Foram também convertidas para numérico algumas colunas inicialmente representadas como texto. A coluna Date/Time foi transformada para o tipo Date&Time, permitindo remover datas inválidas e extrair novas variáveis temporais, tais como “Hour”, “Day of Month”, “Month”, “Day of Week”, “is_Weekend” e “Season”.

As variáveis temporais foram usadas por poderem captar padrões horários e sazonais, especialmente relevantes para a produção fotovoltaica.

De forma resumida, o workflow seguiu a sequência: leitura dos dados, limpeza inicial, normalização de Productions, conversão de tipos, tratamento de Date/Time, extração temporal, criação das branches, divisão treino/teste, imputação e avaliação dos modelos.



Figura 4: Data Preparation Workflow




Figura 5: Gráfico de análise dos valores fotovoltaicos por hora

A análise da produção fotovoltaica média por hora evidencia um padrão diário claro, com valores baixos ou nulos durante a noite e valores mais elevados nas horas de maior radiação solar. Este comportamento justifica a extração da variável Hour e a sua utilização na regressão de Photovoltaics (kWh).

3.4. Configurações Experimentais

Para avaliar melhor o comportamento dos modelos, foram criadas várias branches com diferentes conjuntos de variáveis. Esta decisão permitiu comparar modelos com maior capacidade explicativa com modelos mais realistas do ponto de vista preditivo.

Branch	Target	Variáveis usadas	Objetivo
Except-Photovoltaics	Productions	Todas as variáveis excluindo Photovoltaics (kWh).	Avaliar o desempenho dos modelos sem usar diretamente a produção fotovoltaica.
Energy-only	Productions	Apenas variáveis de produção energética.	Verificar se as variáveis energéticas conseguem explicar quase diretamente a classe Productions.
Distribution-only	Productions	Apenas Distribution Network (kWh).	Testar se uma única variável energética está demasiado próxima do target.
Weather&Time-only	Productions	Variáveis meteorológicas e temporais.	Avaliar um cenário mais realista, sem variáveis de produção direta.
Reg-Weather&Time-only	Photovoltaics (kWh)	Variáveis meteorológicas e temporais.	Prever a produção fotovoltaica com base nas condições atmosféricas e temporais.

Tabela 1: Configurações experimentais

3.5. Modeling e Evaluation

3.5.1. Modeling e Evaluation - Classificação

Para o problema de classificação, o target utilizado foi `Productions`. Foram testados quatro modelos: Decision Tree, Random Forest, Gradient Boosted Trees e uma rede neuronal. A Decision Tree foi usada como modelo base, pela sua simplicidade e interpretabilidade. O Random Forest e o Gradient Boosted Trees foram usados para comparar duas abordagens ensemble: árvores independentes e árvores sequenciais.

A rede neuronal foi testada apenas na branch `Weather&Time-only`, por esta representar o cenário mais realista, sem variáveis energéticas diretas. Para este modelo foram usadas apenas variáveis meteorológicas e temporais numéricas, com normalização dos dados antes do treino. A configuração final usou 10 neurónios e 100 iterações, tendo obtido uma accuracy aproximada de 45%.

Os dados foram divididos em treino e teste com uma partição 70%-30%, usando amostragem estratificada pela variável `Productions`. A imputação dos missing values foi feita apenas no conjunto de treino e aplicada posteriormente ao conjunto de teste, evitando fuga de informação.




Figura 6: Branch Except-Photovoltaics - Modelos de classificação

Branch	Modelo	Accuracy	Cohen's Kappa
Except-Photovoltaics	Decision Tree	0,897	0,867
Except-Photovoltaics	Random Forest	0,927	0,906
Except-Photovoltaics	Gradient Boosted Trees	0,934	0,915
Energy-only	Decision Tree	0,899	0,869
Energy-only	Random Forest	0,936	0,917
Distribution-only	Decision Tree	0,884	0,849
Weather&Time-only	Decision Tree	0,491	0,337
Weather&Time-only	Random Forest	0,637	0,526
Weather&Time-only	Neural Network	0,445	0,275

Tabela 2: Resultados dos modelos de classificação

A branch **Except-Photovoltaics** foi usada para comparar os modelos principais num cenário com variáveis energéticas, meteorológicas e temporais, excluindo apenas **Photovoltaics (kWh)**. Os resultados desta branch foram depois comparados com as restantes configurações experimentais, especialmente **Energy-only**, **Distribution-only** e **Weather&Time-only**, de modo a avaliar o impacto das variáveis utilizadas no treino.

3.5.2. Modeling e Evaluation - Regressão

Para o problema de regressão, o target escolhido foi **Photovoltaics (kWh)**. O objetivo foi prever a produção fotovoltaica com base em variáveis meteorológicas e temporais, sem usar outras variáveis energéticas diretas.

Foram utilizados os modelos Linear Regression e Simple Regression Tree. A Linear Regression foi usada como baseline, por ser simples e interpretável. A Simple Regression Tree foi usada para avaliar se uma estrutura não linear conseguiria captar melhor padrões associados à hora do dia, radiação solar e cobertura de nuvens.

Na preparação desta branch, foram removidas as restantes variáveis energéticas e a classe **Productions**. Também foram removidas as linhas em que **Photovoltaics (kWh)** estava em falta, uma vez que esta variável é o target do modelo.




Figura 7: Branch Reg-Weather&Time-only - Modelos de regressão

Modelo	R^2	MAE	MSE	RMSE	Comentário
Linear Regression	0,836	3 508,103	25 046 133,015	5 004,611	Maior R^2 e menor RMSE. Melhor desempenho global.
Simple Regression Tree	0,815	2 645,895	28 350 168,168	5 324,488	Menor MAE. Captou melhor alguns erros absolutos.

Tabela 3: Resultados obtidos na análise da regressão

A Linear Regression apresentou o melhor desempenho global, obtendo maior R^2 e menores valores de MSE e RMSE. No entanto, a Simple Regression Tree obteve menor MAE, indicando que, em média, os seus erros absolutos foram ligeiramente inferiores. Ainda assim, o RMSE mais elevado sugere que a árvore cometeu alguns erros de maior dimensão, penalizando o seu desempenho global.

3.6. Análise Crítica

Os resultados mostram que as branches que incluem variáveis energéticas apresentam desempenhos muito elevados. Em particular, a branch **Energy-only** obteve resultados próximos ou superiores à branch **Except-Photovoltaics**, o que sugere uma forte proximidade entre estas variáveis e o target **Productions**.

A branch Distribution-only também apresentou uma accuracy elevada usando apenas Distribution Network (kWh), reforçando a hipótese de que algumas variáveis energéticas estão demasiado próximas da definição da classe alvo. Por este motivo, os resultados das branches com variáveis energéticas devem ser interpretados sobretudo como explicativos.

Por outro lado, a branch Weather&Time-only representa um cenário mais realista, por utilizar apenas variáveis meteorológicas e temporais. Nesta configuração, o desempenho baixou consideravelmente, sendo o Random Forest o melhor modelo entre os testados. A rede neuronal apresentou desempenho inferior, sugerindo que, para este dataset tabular e com a configuração usada, os modelos baseados em árvores foram mais adequados.

Na regressão, a previsão de Photovoltaics (kWh) com variáveis meteorológicas e temporais revelou-se coerente com o domínio do problema. A análise por hora mostrou que a produção fotovoltaica depende fortemente da hora do dia, da radiação e das condições atmosféricas.

3.7. Conclusão do Dataset Atribuído

A análise do dataset atribuído permitiu desenvolver modelos de classificação e regressão, cumprindo os objetivos definidos para esta tarefa. A preparação dos dados foi essencial para tratar missing values, inconsistências na variável Productions, datas inválidas e tipos incorretos.

Na classificação, os modelos ensemble apresentaram os melhores resultados nas branches com variáveis energéticas. No entanto, a comparação com a branch Weather&Time-only mostrou que parte desse desempenho está associada à proximidade entre algumas variáveis energéticas e o target. Nesta branch mais realista, o Random Forest obteve o melhor resultado, enquanto a rede neuronal apresentou desempenho inferior.

Na regressão, a previsão de Photovoltaics (kWh) com variáveis meteorológicas e temporais mostrou-se adequada, destacando-se a Linear Regression pelo melhor desempenho global em R^2 , MSE e RMSE, embora a Simple Regression Tree tenha obtido menor MAE.

4. Dataset Grupo

4.1. Business Understanding

No âmbito da Tarefa Dataset Grupo, foi selecionado o dataset **Spotify Dataset for ML Practice**, disponibilizado publicamente no Kaggle¹, por reunir um conjunto extenso e preparado para aprendizagem automática com 114 000 faixas musicais do Spotify, distribuídas por 125 géneros distintos. A riqueza do feature engineering já aplicado (158 colunas) e a possibilidade de aplicar os três paradigmas de aprendizagem automática — regressão, classificação e análise exploratória — tornam este dataset particularmente adequado para os objetivos da tarefa.

O dataset é composto por dois ficheiros complementares: o dataset original (114 000 linhas × 24 colunas) com atributos acústicos brutos extraídos da API do Spotify, e um dataset com feature engineering já aplicado (113 999 linhas × 158 colunas), que inclui transformações, variáveis derivadas, codificações e clusters pré-computados. A utilização deste segundo ficheiro permitiu centrar o trabalho na fase de modelação, complementando com os passos de preparação realizados em KNIME.

O problema foi dividido em dois eixos: **regressão**, para prever a variável contínua `popularity` (normalizada, intervalo aproximado -1,5 a 3, correspondente à escala Z-Score da popularidade original 0–100); e **classificação**, para prever a variável binária `is_dance_hit`, que indica se uma faixa tem simultaneamente `danceability` ≥ 0.7 e `energy` ≥ 0.6 .

4.2. Data Understanding

O dataset original contém 114 000 registos e 24 colunas de atributos acústicos e metadados. O dataset com feature engineering expande este conjunto para 158 colunas, adicionando variáveis derivadas, codificações e transformações estatísticas.

¹<https://www.kaggle.com/datasets/rudraprasadbhuyan/spotify-dataset-for-ml-practice>

Atributo original	Tipo	Descrição
popularity	Float Z-Score	Popularidade global da faixa (normalizada) — variável-alvo da regressão
danceability	Float 0–1	Adequação para dançar, com base em ritmo, batida e regularidade
energy	Float 0–1	Intensidade e atividade percebida da faixa
loudness	Float dB	Volume médio da faixa em decibéis
speechiness	Float 0–1	Presença de palavras faladas na faixa
acousticness	Float 0–1	Confiança de que a faixa é acústica
instrumentalness	Float 0–1	Probabilidade de ausência de voz
liveness	Float 0–1	Deteção de audiência ao vivo
valence	Float 0–1	Positividade musical transmitida
tempo	Float BPM	Tempo estimado em batidas por minuto
duration_ms	Int ms	Duração da faixa em milissegundos
key	Int 0–11	Tom musical (C=0, C#=1, ..., B=11)
mode	Int 0/1	Modalidade: maior (1) ou menor (0)
explicit	Bool	Indica se a faixa tem conteúdo explícito
track_genre	String	Gênero musical da faixa (125 gêneros distintos)

Tabela 4: Atributos originais do dataset Spotify (24 colunas base).

O dataset com feature engineering acrescenta variáveis em vários grupos:

Grupo de features	Exemplos e descrição
One-hot encoding de gêneros	114 colunas binárias <code>track_genre_acoustic</code> , <code>track_genre_pop</code> , ... — uma por gênero
Classificações por intervalos	<code>duration_class_short/normal/long/very_long</code> , <code>loudness_level</code> , <code>tempo_class</code> , <code>popularity_level</code>
Contexto do artista	<code>artist_song_count</code> (nº músicas do artista), <code>album_freq</code> , <code>artists_avg_popularity</code>
Interações entre features	<code>happy_dance</code> = <code>valence</code> × <code>danceability</code> ; <code>loud_energy_ratio</code> ; <code>acoustics_instrumental</code>
Transformações cíclicas	<code>key_sin</code> , <code>key_cos</code> — encoding circular do tom musical, preservando a sua natureza periódica
Transformações estatísticas	<code>duration_log</code> , <code>duration_log_z</code> , <code>loudness_yeo</code> (Yeo-Johnson), <code>temp_zscore</code>
Features de ranking	<code>energy_rank_pct</code> (percentil de energy), <code>tempo_vs_genre</code> (desvio do tempo médio do gênero)
Clusters pré-computados	<code>mood_cluster</code> , <code>acoustic_valence_mood_cluster</code> , <code>mood_pca</code> (1ª componente principal de mood)
Variáveis binárias derivadas	<code>is_dance_hit</code> , <code>is_instrumental</code> , <code>time_signature_class_boolean</code>
Encoding numérico	<code>track_genre_le</code> — Label Encoding do gênero musical

Tabela 5: Grupos de features derivadas no dataset com feature engineering (158 colunas no total).

A análise exploratória inicial, realizada com os nodos `Statistics`, `Histogram`, `Scatter Plot` e `Linear Correlation` em KNIME, revelou os seguintes aspetos:

- A distribuição de `popularity` (na escala normalizada) é assimétrica à direita, com muitas faixas concentradas em valores negativos, correspondendo a músicas sem streaming significativo.
- A variável `is_dance_hit` apresenta forte desequilíbrio de classes — a grande maioria das faixas pertence à classe 0, exigindo tratamento explícito de balanceamento antes da modelação.
- Existe correlação positiva entre `energy` e `loudness`, e correlação negativa entre `acousticness` e `energy`, confirmando padrões acústicos intuitivos.
- O género musical tem impacto significativo nas features acústicas, justificando a sua inclusão como variável preditora via `track_genre_le`.




Figura 8: Distribuição da variável `popularity` — histograma obtido com o nodo `Histogram` no KNIME.




Figura 9: Matriz de correlação entre atributos acústicos — nodo Linear Correlation no KNIME.

4.3. Data Preparation

A preparação dos dados foi realizada em KNIME com o workflow ilustrado abaixo. Uma vez que o dataset com feature engineering já incluía a maioria das transformações e variáveis derivadas, os passos de preparação focaram-se na limpeza, remoção de duplicados, tratamento de valores em falta e outliers, normalização e divisão treino/teste.




Figura 10: Ramo de preparação de dados no KNIME — desde a leitura do CSV até à divisão treino/teste.

4.3.1. Remoção de Duplicados

O nodo **Duplicate Row Filter** foi configurado para detetar e remover registos duplicados. O dataset original apresenta faixas associadas a múltiplos géneros — a mesma música pode aparecer em várias linhas com géneros distintos. Este passo resultou na passagem de 114 000 para 113 999 registos, garantindo que cada faixa fosse representada apenas uma vez.

4.3.2. Tratamento de Valores em Falta

O nodo **Missing Value** foi aplicado em duas passagens:

- **Primeira passagem:** colunas numéricas com distribuição simétrica imputadas pela média; colunas assimétricas (`tempo` , `loudness`) pela mediana; colunas de texto pelo valor mais frequente.
- **Segunda passagem:** com configuração por defeito, garantindo que nenhum valor em falta subsiste após o tratamento de outliers.

4.3.3. Tratamento de Outliers

O nodo **Numeric Outliers** foi configurado com o método IQR (multiplicador 1,5), aplicado a `tempo` , `loudness` , `popularity` e `duration_ms` . A estratégia adotada foi a substituição pelos valores limite (**boundary replacement**), preservando o número total de registos e evitando a perda de informação.




Figura 11: Box plot de `popularity` antes e depois do tratamento de outliers — nodo Numeric Outliers no KNIME.

4.3.4. Seleção de Features para Modelação

Das 158 colunas disponíveis, foram selecionadas para os modelos as features acústicas originais, as principais features derivadas e `track_genre_le`. As 114 colunas de one-hot encoding dos géneros foram excluídas dos Learners por introduzirem esparsidade excessiva, sem benefício preditivo proporcional face ao label encoding já disponível.

4.3.5. Normalização

O nodo `Normalizer` foi aplicado com o método Z-Score às colunas numéricas selecionadas, excluindo as variáveis-alvo. Note-se que a variável `popularity` no dataset com feature engineering já se encontra normalizada (Z-Score), apresentando um intervalo aproximado de $-1,5$ a 3 . No ramo do `RProp MLP Learner`, foi adicionado um `Normalizer Min-Max` exclusivamente para `popularity`, uma vez que este nodo exige que o target esteja no intervalo $[0,1]$, com o respetivo `Normalizer Apply` no ramo de teste.

4.3.6. Divisão Treino/Teste

Os dados foram divididos com `Table Partitioner` em 70% treino e 30% teste, com amostragem estratificada por `track_genre_le` e semente aleatória 42, garantindo reprodutibilidade e representatividade proporcional de todos os géneros em ambas as partições.

4.3.7. Balanceamento de Classes

Para o ramo de classificação, a variável `is_dance_hit` foi convertida para formato nominal com `Number to String`. O nodo `Equal Size Sampling` foi aplicado antes dos Learners para equilibrar as classes no conjunto de treino, mitigando o efeito do forte desequilíbrio existente na variável-alvo.

4.4. Modelação e Avaliação — Regressão

O objetivo do ramo de regressão foi prever o valor numérico de `popularity` (na escala normalizada). Foram testados cinco modelos com diferentes abordagens, avaliados com as métricas R^2 , MAE e RMSE.




Figura 12: Ramo de regressão no KNIME — cinco modelos com Regression Predictor e Numeric Scorer individuais.

4.4.1. Linear Regression

Modelo linear usado como baseline. Assume uma relação linear entre as features e `popularity`, ajustando um hiperplano que minimiza a soma dos quadrados dos resíduos. Configuração: `Include constant term = true`. Obteve $R^2 = 0,723$ e $RMSE = 0,495$, servindo de referência para os modelos seguintes.

4.4.2. Simple Regression Tree

Árvore de regressão que divide recursivamente o espaço de features com regras condicionais, minimizando o erro quadrático em cada nó. Parâmetros: `Max depth = 10`, `Min records per node = 5`, `Pruning = MDL`. Apresentou o pior desempenho entre os modelos de árvore, com $R^2 = 0,531$ e $RMSE = 0,644$, evidenciando overfitting ou insuficiente capacidade de generalização face aos modelos ensemble.

4.4.3. Random Forest (Regressão)

Ensemble de 100 árvores treinadas com bagging e amostragem aleatória de features. A previsão final é a média das previsões individuais. Parâmetros: `Number of trees = 100`, `Max depth = 10`, `Features per split = sqrt`, `Seed = 42`. Obteve $R^2 = 0,687$ e $RMSE = 0,526$. A porta de Feature Importance foi ligada a um `Table View` para identificar as variáveis com maior impacto preditivo.

4.4.4. Gradient Boosted Trees (Regressão)

Ensemble sequencial em que cada árvore corrige os resíduos da anterior, usando gradiente descendente no espaço funcional. Parâmetros: `Number of trees = 100`, `Learning rate = 0.1`, `Max depth = 5`. Obteve o melhor desempenho global, com $R^2 = 0,725$ e $RMSE = 0,493$, superando marginalmente a Regressão Linear e o Random Forest.

4.4.5. RProp MLP — Rede Neuronal (Regressão)

Rede neuronal multicamada treinada com o algoritmo Resilient Propagation (RProp). O nodo exige que o target esteja no intervalo $[0,1]$, pelo que foi necessário adicionar um `Normalizer Min-Max` antes do Learner e um `Normalizer Apply` no ramo de teste. Parâmetros: `Hidden layers = 2`, `Neurons per layer = 50`, `Max iterations = 500`, `Seed = 42`. Apresentou resultados muito fracos ($R^2 = 0,039$, $RMSE = 0,922$), indicando que a rede não convergiu adequadamente ou que os hiperparâmetros utilizados não são adequados para este dataset.

4.4.6. Resultados Comparativos — Regressão

Modelo	R^2	MAE	RMSE
Linear Regression	0.723	0.259	0.495
Simple Regression Tree	0.531	0.349	0.644
Random Forest	0.687	0.344	0.526
Gradient Boosted Trees	0.725	0.249	0.493
RProp MLP	0.039	0.768	0.922

Tabela 6: Resultados dos modelos de regressão — valores extraídos do Numeric Scorer no KNIME.

4.5. Modelação e Avaliação — Classificação

O objetivo do ramo de classificação foi prever se uma faixa é `is_dance_hit = 1`. Foram testados quatro modelos, avaliados com Accuracy, Error Rate e Cohen's Kappa. Dado o desequilíbrio de classes original, o

Kappa é a métrica mais informativa, pois mede a concordância entre previsões e valores reais corrigida para o acaso.

4.5.1. Decision Tree

Árvore de decisão com critério Gini Index. Parâmetros: Max depth = 7, Min records per node = 10, Pruning = MDL, Append class probabilities = true (necessário para ROC Curve). Obteve Accuracy = 99,981% e Kappa = 0,947, demonstrando elevada capacidade de separação das classes após o balanceamento.

4.5.2. Random Forest (Classificação)

Ensemble de 100 árvores com votação majoritária. Parâmetros: Number of trees = 100, Max depth = 10, Features per split = sqrt, Seed = 42, Append class probabilities = true. Obteve Accuracy = 100% e Kappa = 1,0 — classificação perfeita no conjunto de teste, o que pode indicar que as features `danceability` e `energy` (que definem diretamente `is_dance_hit`) não foram excluídas do conjunto de features preditoras.

4.5.3. Naive Bayes

Classificador probabilístico baseado no Teorema de Bayes com suposição de independência condicional entre features. Parâmetros: Laplace correction = true, Append class probabilities = true. Obteve Accuracy = 95,635% mas Kappa = 0,072, revelando que, apesar da accuracy razoável, a capacidade preditiva real é muito limitada — o classificador comporta-se quase como um classificador aleatório em termos de concordância ajustada.

4.5.4. SVM (SVM Learner)

Support Vector Machine com kernel RBF. Parâmetros: Type = C-SVC, C = 1.0, Gamma = 0.1, Probability estimates = true. Obteve Accuracy = 99,819% mas Kappa = 0,0, o que indica que, apesar da accuracy elevada, o modelo prevê sistematicamente a classe majoritária e não tem poder discriminativo real sobre a classe `is_dance_hit` = 1.

4.5.5. Resultados Comparativos — Classificação

Modelo	Accuracy (%)	Error (%)	Kappa
Decision Tree	99.981	0.019	0.947
Random Forest	100.000	0.000	1.000
Naive Bayes	95.635	4.365	0.072
SVM	99.819	0.181	0.000

Tabela 7: Resultados dos modelos de classificação — valores extraídos do Scorer no KNIME.

4.6. Análise Crítica

4.6.1. Regressão

Os resultados da regressão revelam um padrão interessante: a Regressão Linear ($R^2 = 0,723$) e o Gradient Boosted Trees ($R^2 = 0,725$) obtiveram desempenhos muito semelhantes e superiores ao Random Forest ($R^2 = 0,687$) e à Simple Regression Tree ($R^2 = 0,531$). Este resultado sugere que, após o feature engineering aplicado no dataset, as relações entre as features e `popularity` são em grande medida lineares ou aproximadamente lineares — o que explica por que razão o modelo mais simples (regressão linear) é tão competitivo quanto os modelos ensemble.

O desempenho fraco do RProp MLP ($R^2 = 0,039$, $RMSE = 0,922$) é o resultado mais crítico e relevante de analisar. Este resultado está provavelmente relacionado com a necessidade de normalização Min-Max do target para o intervalo $[0,1]$, exigida pelo nodo no KNIME. Mesmo com esta normalização aplicada, os hiperparâmetros utilizados (2 camadas, 50 neurónios, 500 iterações) podem ser insuficientes para um dataset desta dimensão, ou a rede pode ter ficado presa num mínimo local. Em contexto real, este modelo exigiria uma pesquisa mais exaustiva de hiperparâmetros para ser competitivo.

O MAE do Gradient Boosted Trees (0,249) é o mais baixo de todos os modelos, indicando que, em média, as previsões erram menos de 0,25 unidades na escala Z-Score de popularidade — o que corresponde a aproximadamente 5,5 pontos na escala original 0–100, um erro razoável dado o carácter subjetivo e contextual da popularidade musical.

4.6.2. Classificação

Os resultados da classificação apresentam uma dicotomia clara entre modelos com Kappa elevado (Decision Tree = 0,947, Random Forest = 1,0) e modelos com Kappa próximo de zero (Naive Bayes = 0,072, SVM = 0,0), apesar de todos apresentarem accuracy superior a 95%.

O Random Forest com Accuracy = 100% e Kappa = 1,0 é um resultado que merece atenção crítica: uma classificação perfeita é possível quando as features `danceability` e `energy` — que definem diretamente a variável `is_dance_hit` (`danceability ≥ 0.7 AND energy ≥ 0.6`) — estão incluídas como preditoras. Se estas features não foram excluídas do `Column Filter`, o modelo aprendeu trivialmente a regra de definição da variável-alvo, o que constitui data leakage. Ainda assim, demonstra que os modelos baseados em árvores conseguem capturar regras de limiar de forma eficiente.

O Kappa nulo do SVM (0,0) com Accuracy = 99,819% é um indicador claro de que o modelo prevê sempre a classe maioritária — provavelmente `is_dance_hit = 0` — sem qualquer capacidade discriminativa real. Este comportamento é típico de SVMs quando o kernel e os hiperparâmetros não estão bem ajustados para datasets desbalanceados, mesmo após `Equal Size Sampling` no treino.

O Naive Bayes, com Kappa = 0,072, apresenta um comportamento semelhante: a suposição de independência entre `danceability` e `energy` — duas variáveis altamente correlacionadas que definem `is_dance_hit` — limita estruturalmente a sua capacidade preditiva neste contexto específico.

4.7. Conclusão do Dataset Grupo

A exploração do dataset Spotify permitiu desenvolver um workflow completo em KNIME, integrando preparação de dados, análise exploratória, regressão e classificação sobre 113 999 faixas musicais com 158 features. O uso do dataset com feature engineering pré-aplicado permitiu centrar o esforço na fase de modelação e comparação de modelos.

Na regressão, o Gradient Boosted Trees revelou-se o modelo mais equilibrado ($R^2 = 0,725$, $MAE = 0,249$), seguido de perto pela Regressão Linear — resultado que evidencia a linearidade das relações após normalização. O RProp MLP apresentou desempenho claramente inferior, sublinhando a necessidade de configuração cuidadosa de redes neuronais em KNIME.

Na classificação, a Decision Tree e o Random Forest obtiveram resultados quase perfeitos, enquanto o SVM e o Naive Bayes revelaram limitações estruturais: o SVM previu sistematicamente a classe maioritária (Kappa = 0,0) e o Naive Bayes foi penalizado pela correlação entre as features que definem `is_dance_hit`. O Kappa é, neste contexto, a métrica mais informativa, uma vez que a Accuracy é enganadoramente elevada devido ao desequilíbrio de classes original.