**Universidade do Minho**
Departamento de Informática

# Preparação e Exploração avançada de dados com KNIME

**LEI @ 2025/2026, 2º sem**

# Agenda

- Preparação de Dados
  - Join, Concatenation, Sorter, Filter and Aggregations
- Preparação e Exploração Avançada de Dados
  - Missing Values Treatment, Binning, Feature Scaling, Outlier Detection
  - Feature Selection, Nominal Value Discretization, Feature Engineering
- Experimentação (*hands on*)

# A Machine Learning Pipeline

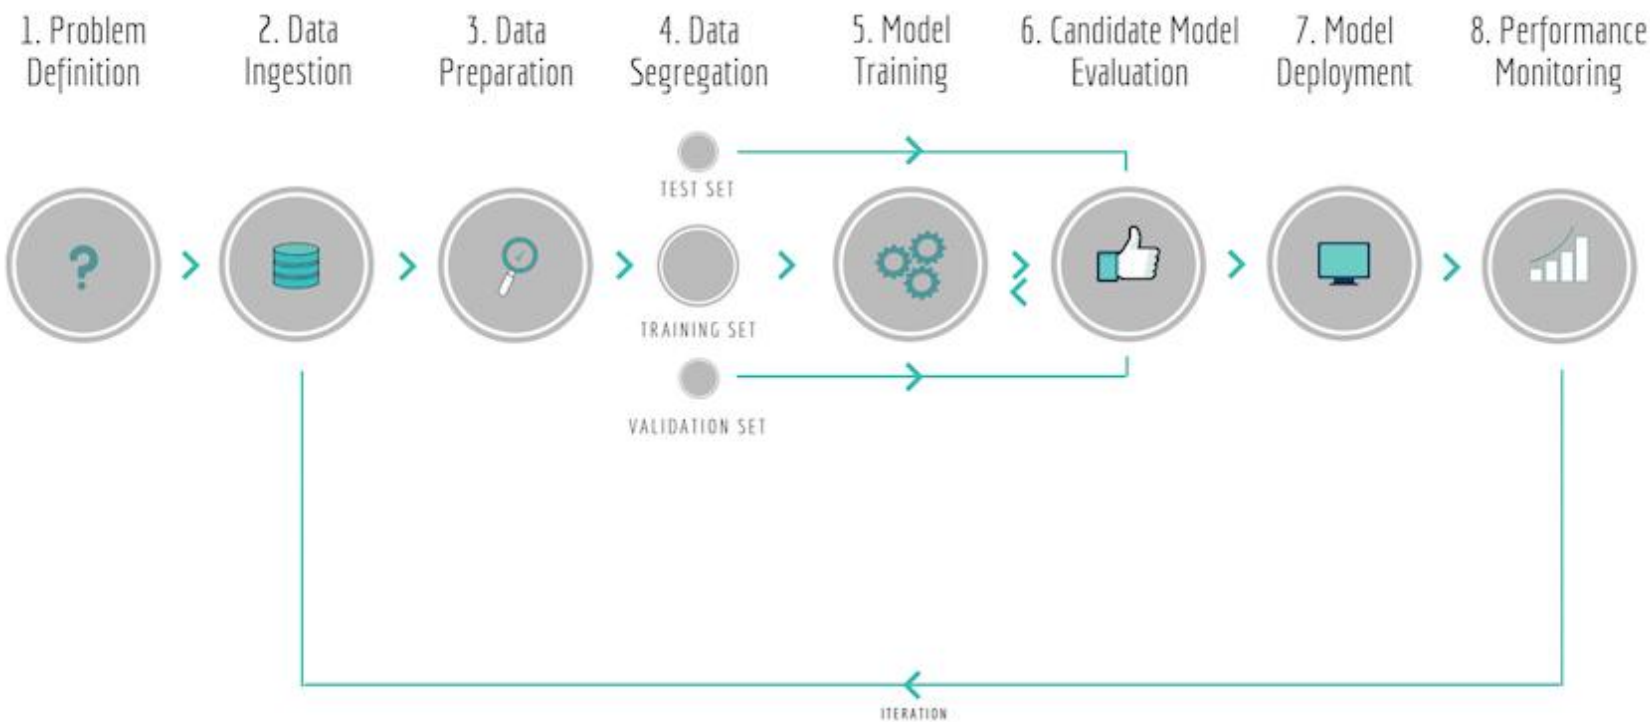


(https://towardsdatascience.com/architecting-a-machine-learning-pipeline-a847f094d1c7)

# Fluxo de Trabalho Típico @ Knime

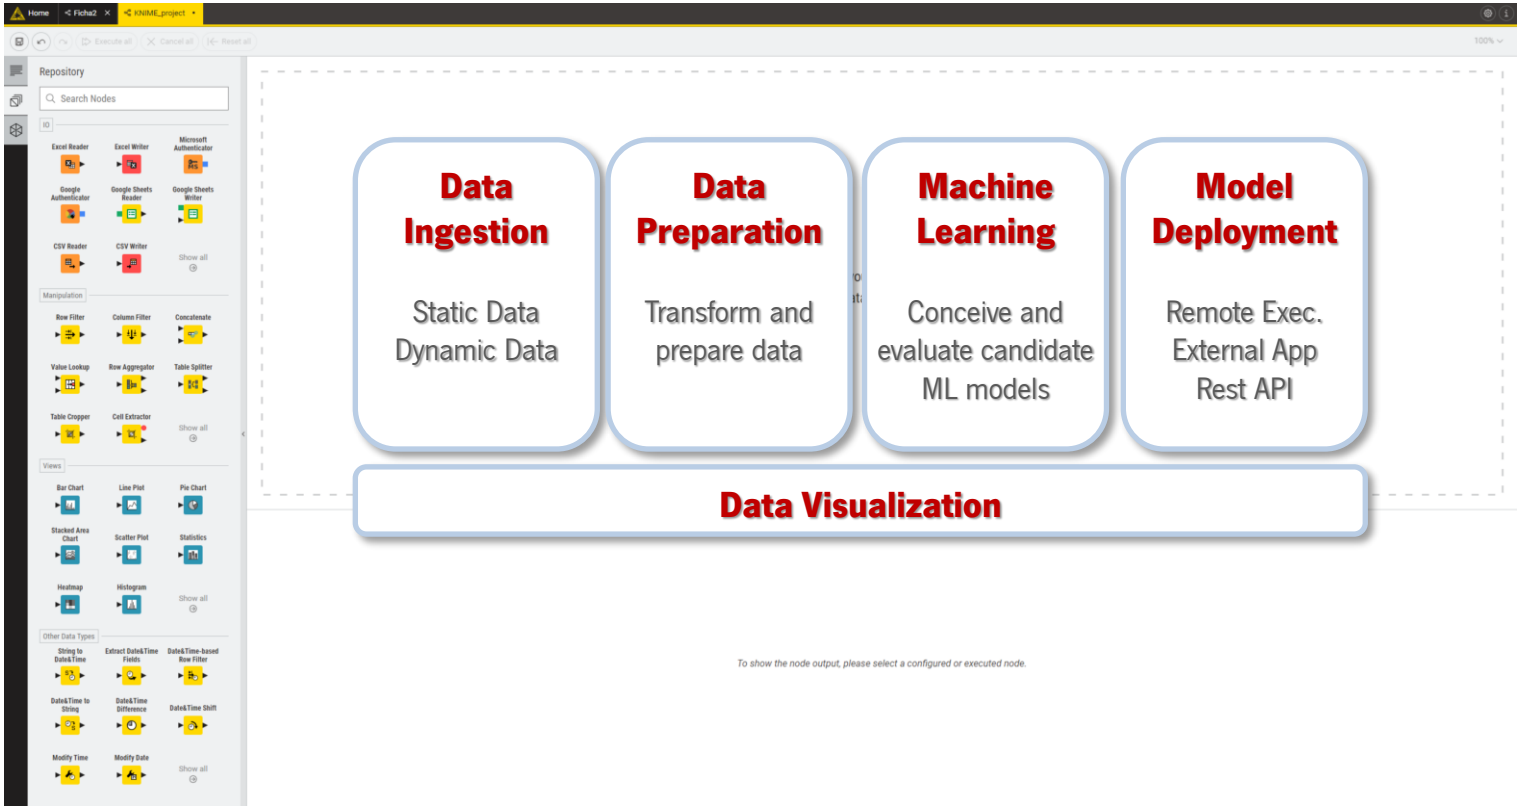

# Junção
## *Join*

- Uma operação JOIN combina dados de diferentes fontes:

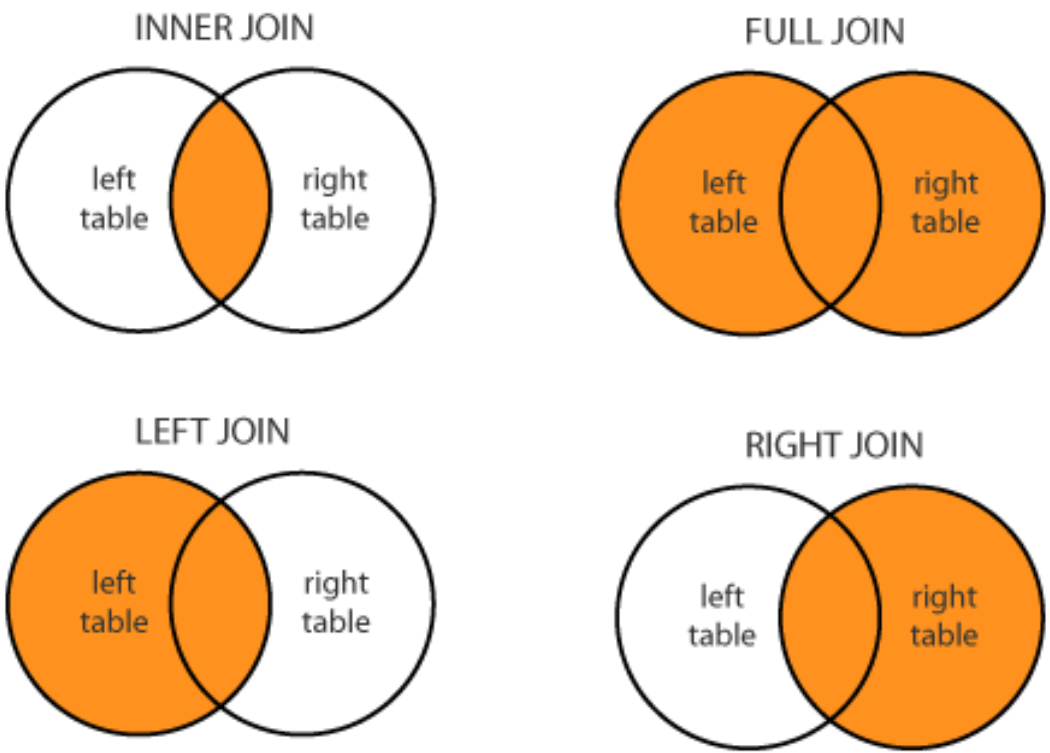

# Junção
## *Join*

- No KNIME estão disponíveis diversas combinações no nodo JOINER:

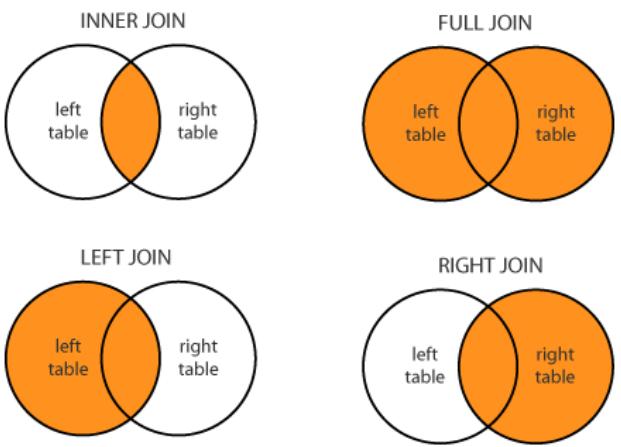


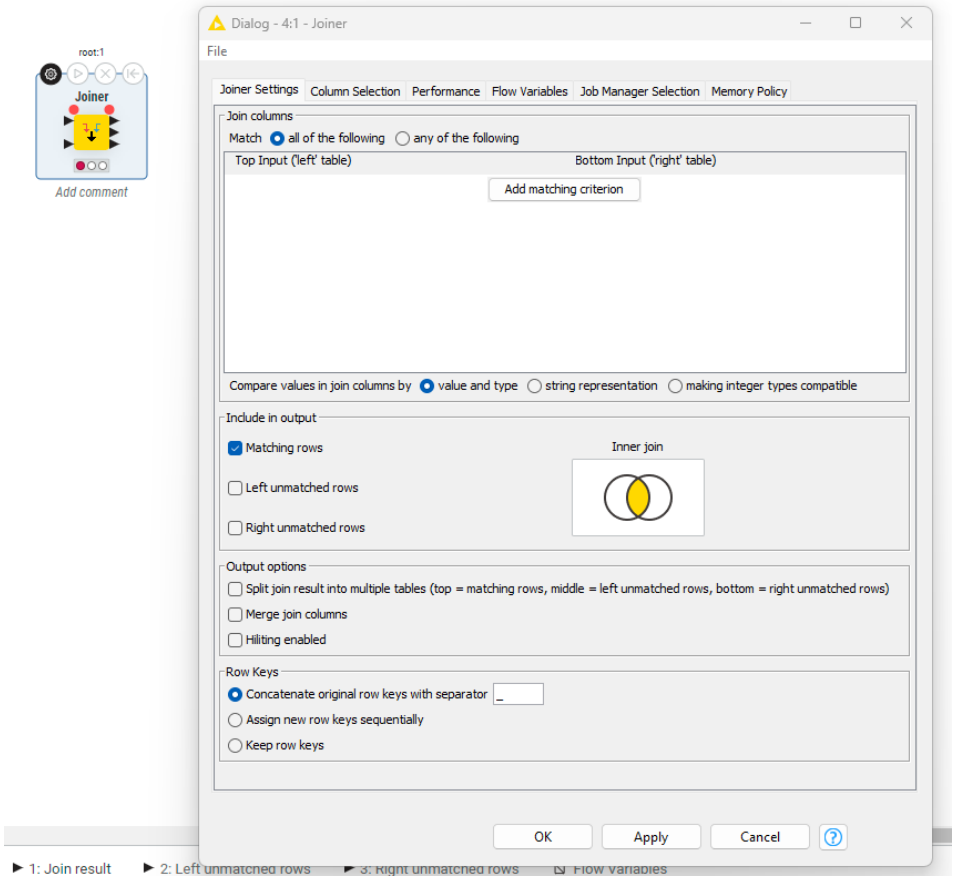

# Concatenação
# *Concatenation*

- União de colunas: CONCATENATE

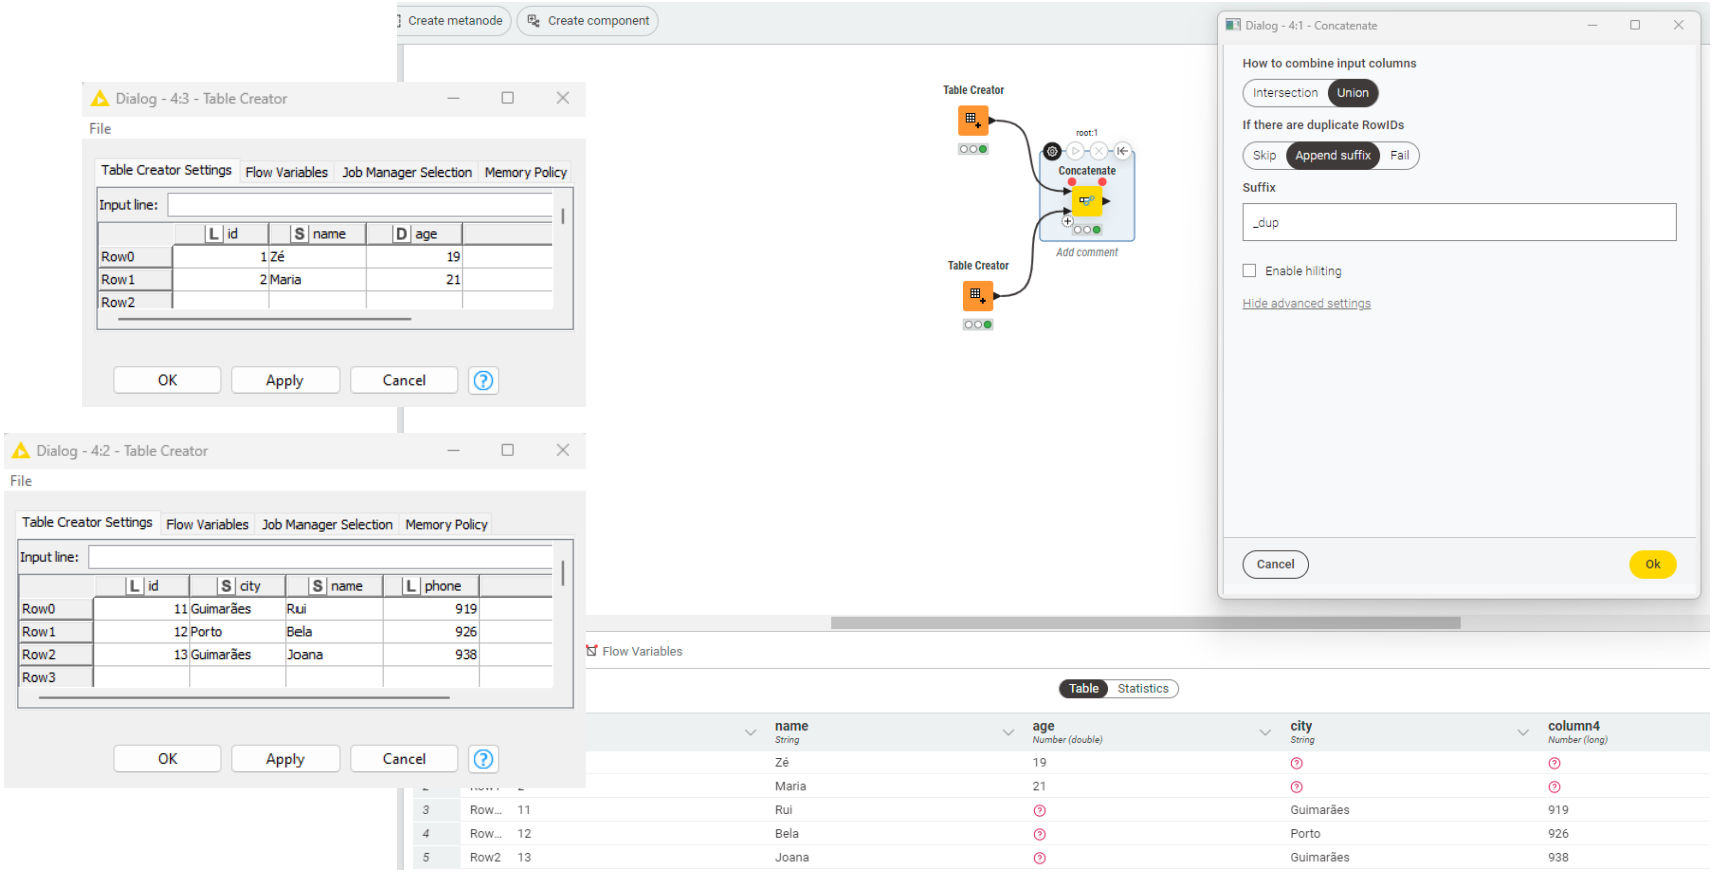

# Ordenação
## *Sorter*

- Altera a ordem das colunas de *input*, com base na definição dos parâmetros;

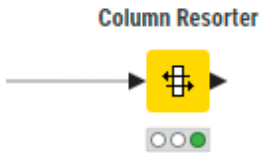


- Ordena as linhas com base na definição dos parâmetros;

- Permite que as linhas sejam classificadas a partir da tabela da base de dados de entrada;

# Filtros
## *Filter*

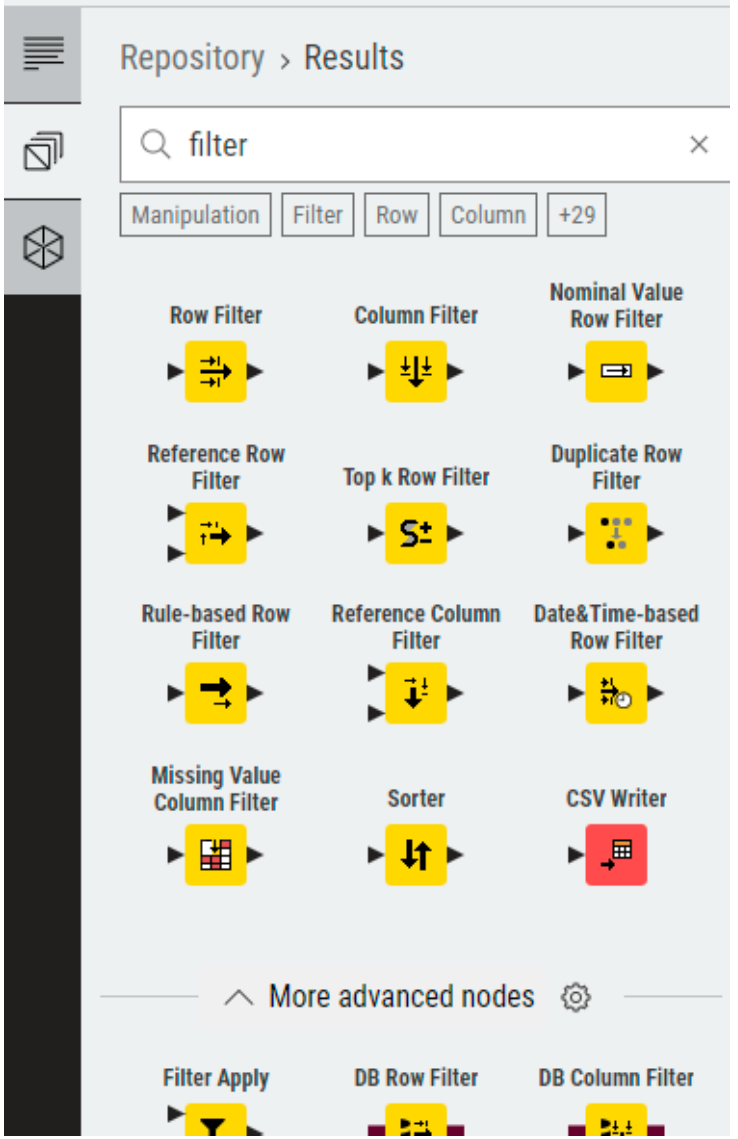

# Filtro de Colunas
## *Column Filter*

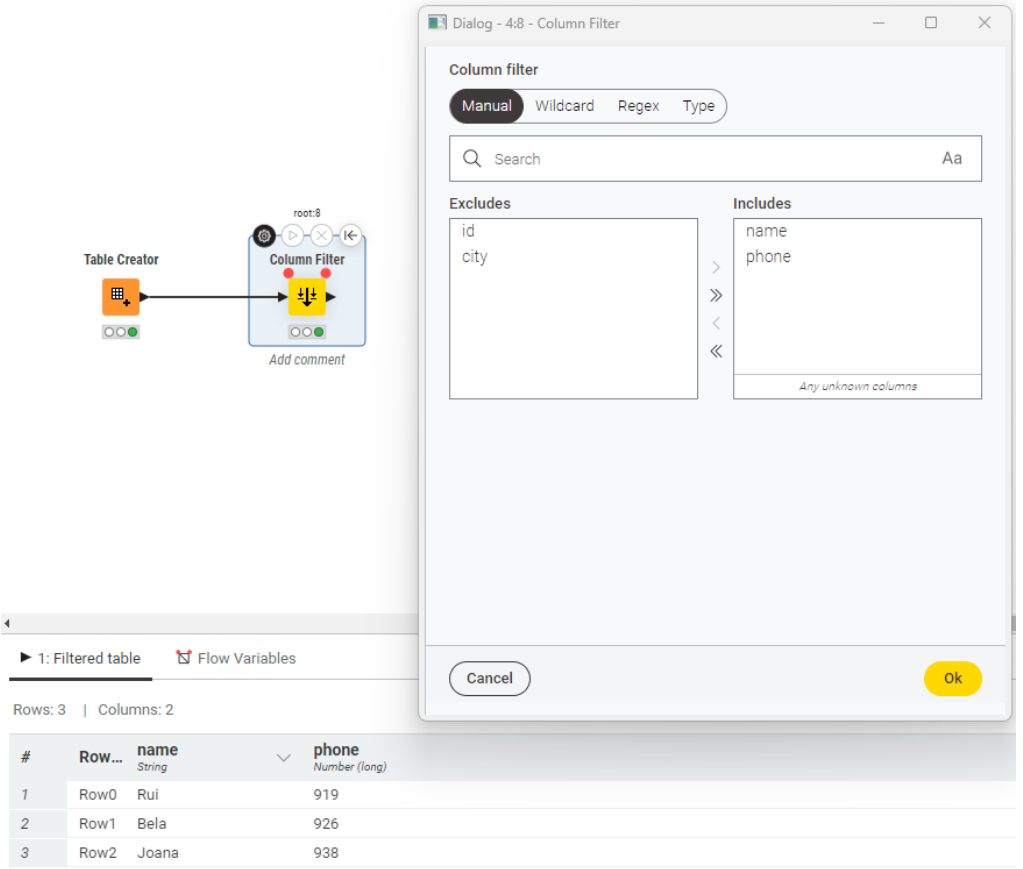

# Filtro de Linhas
## *Row Filter*

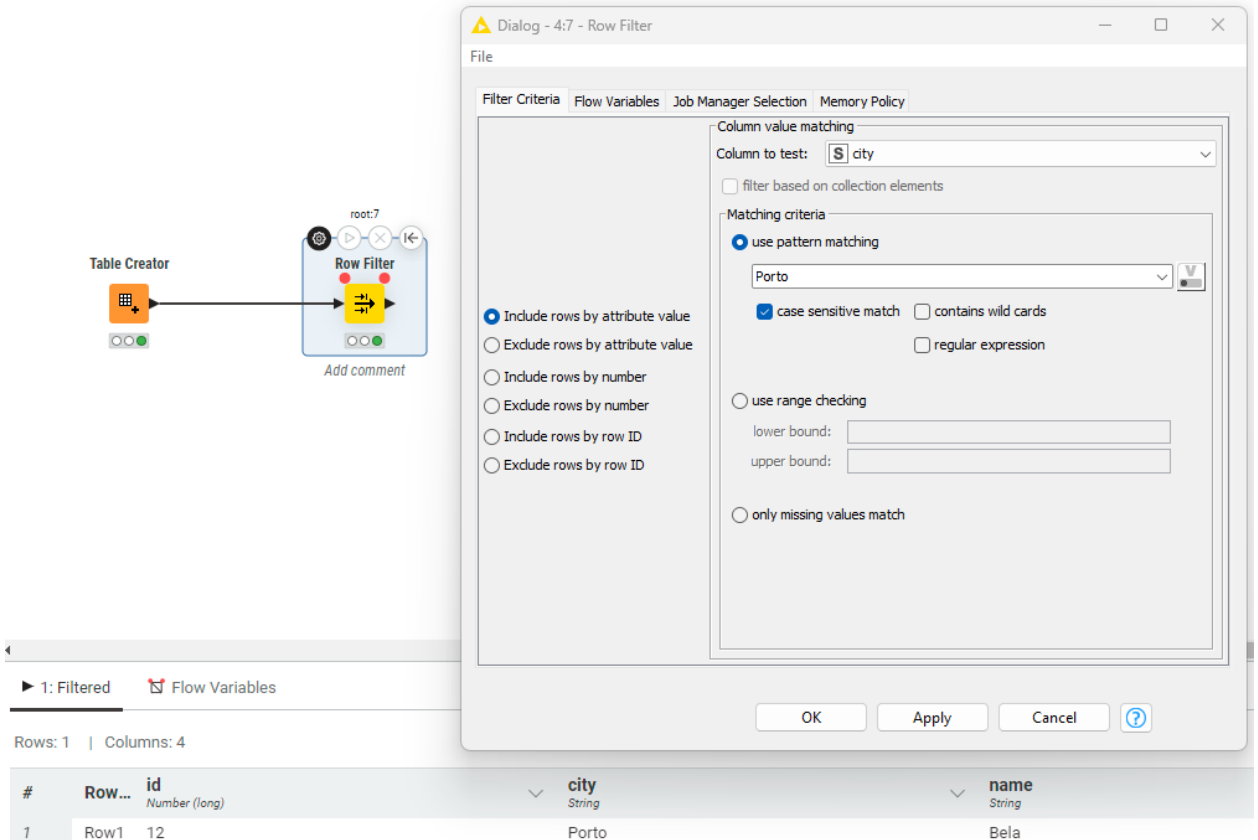

# Filtro de Linhas de Valores Nominais

## *Nominal Value Row Filter*

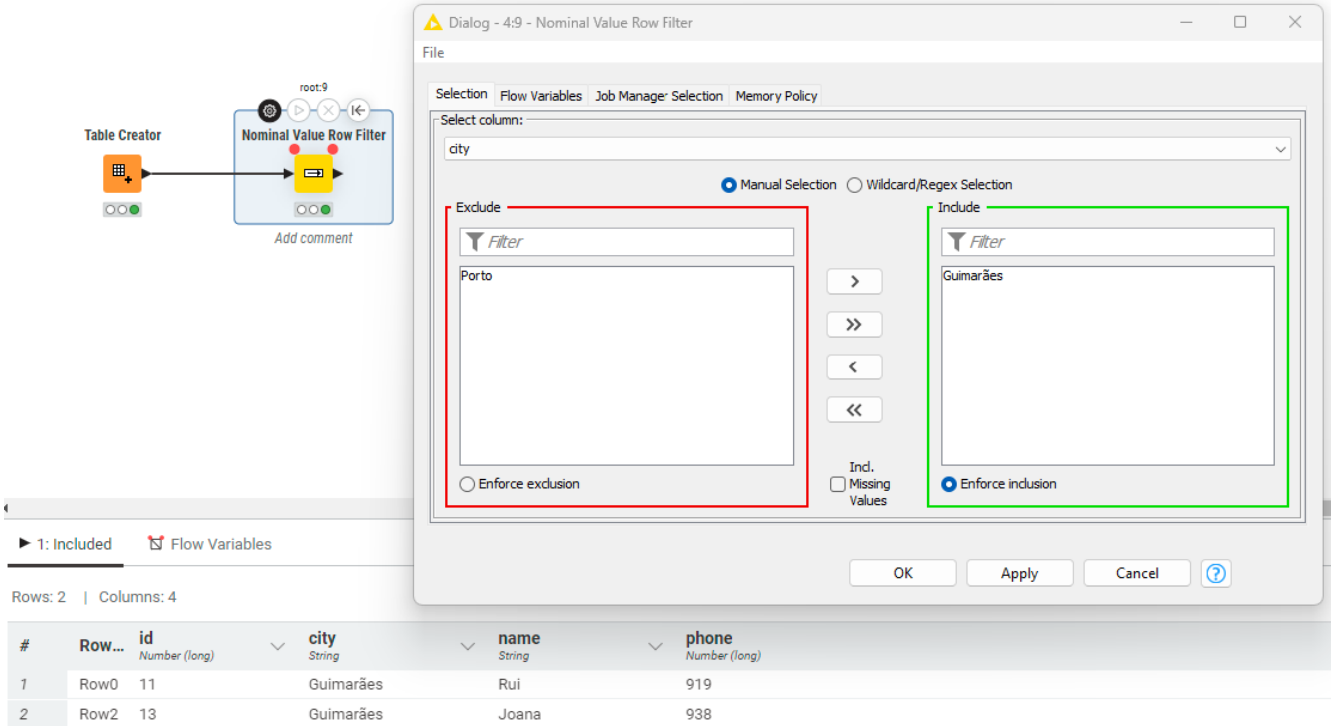

# Filtro de Linhas Baseado em Regras

## *Rule-based Row Filter*

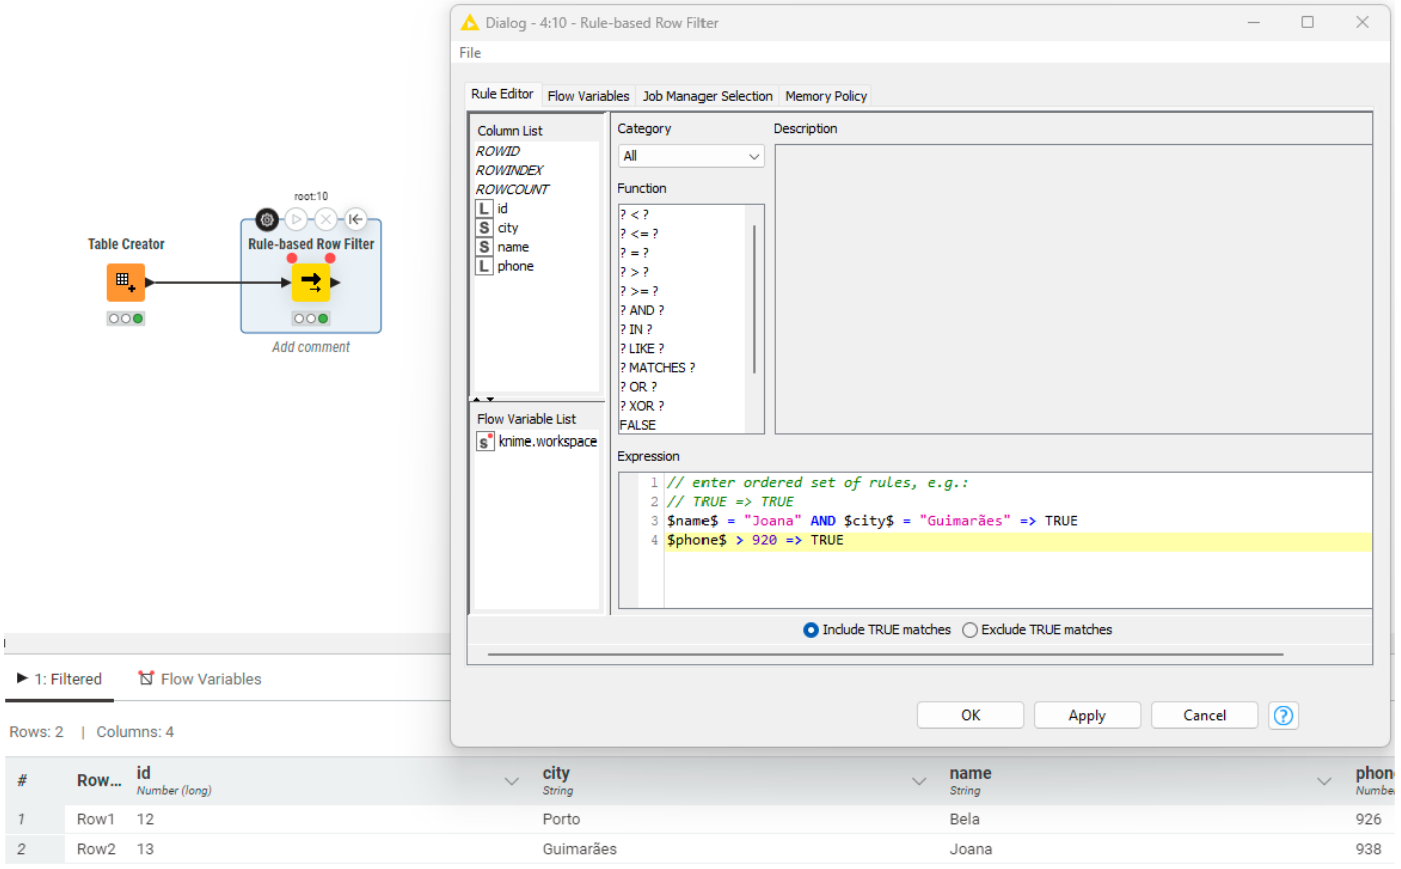

# Filtro de Linhas em JAVA *Snippet*
# JAVA *Snippet Row Filter*

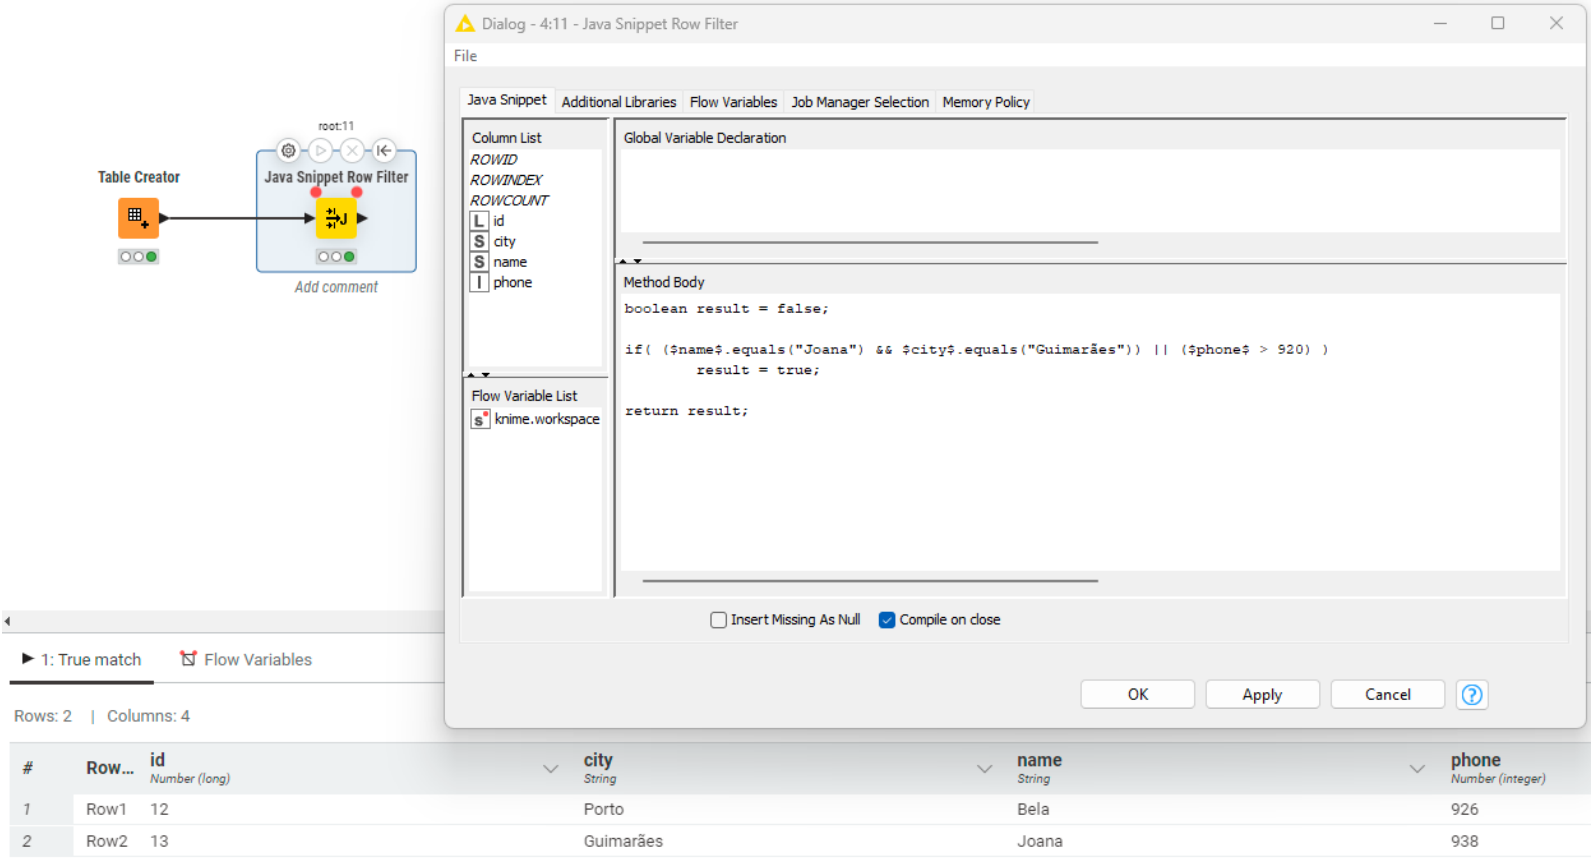

# Operações de Agregação
## *Count and Percent*

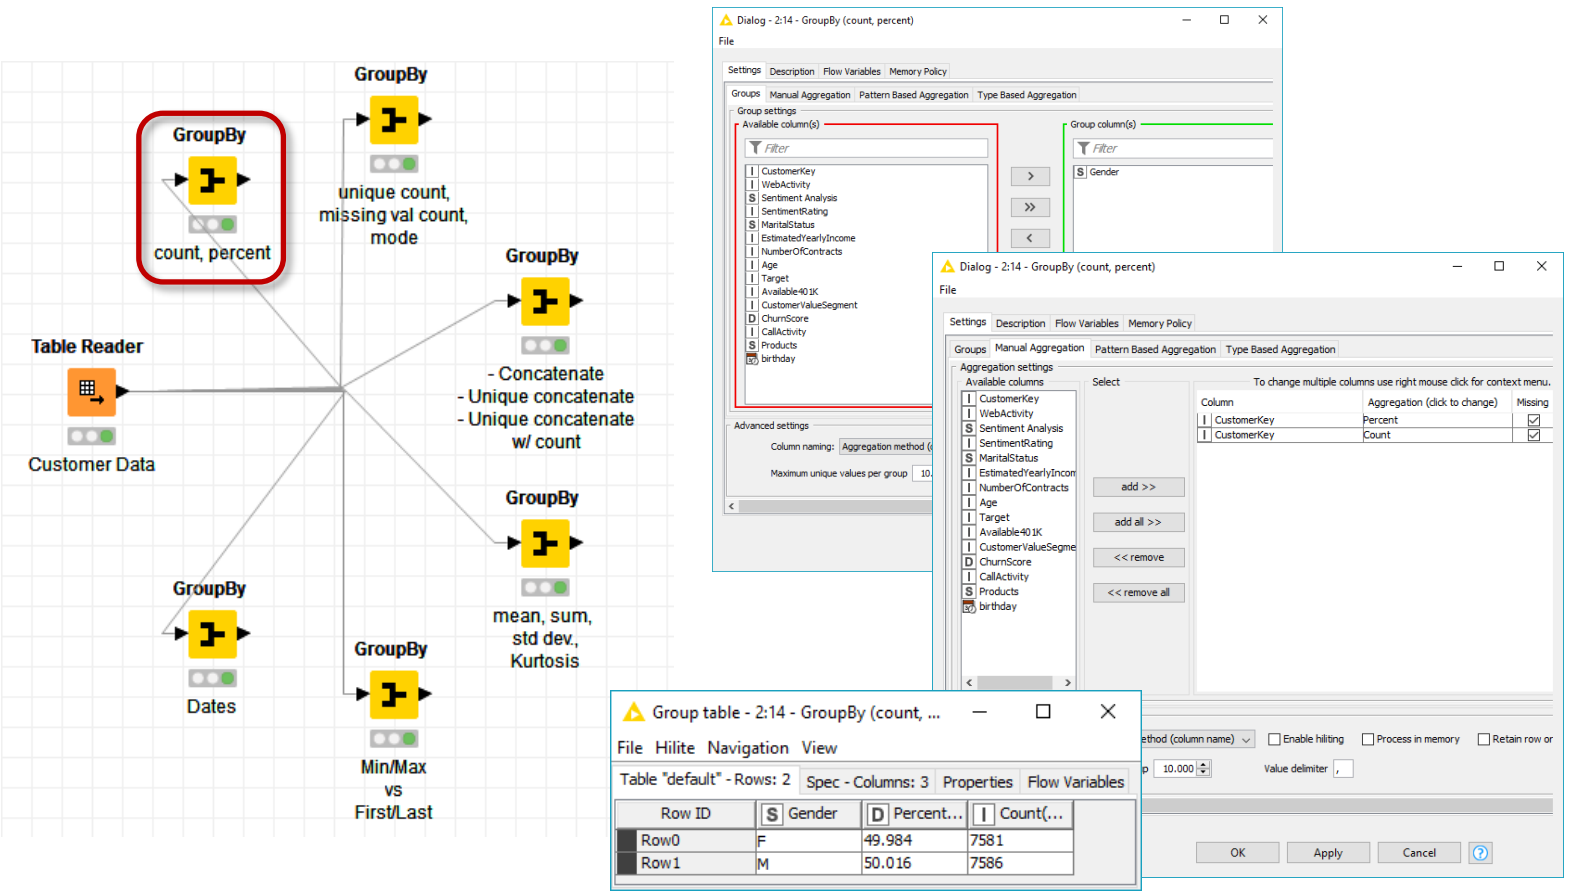

# Operações de Agregação

## *Unique Count, Missing Values Count and Mode*

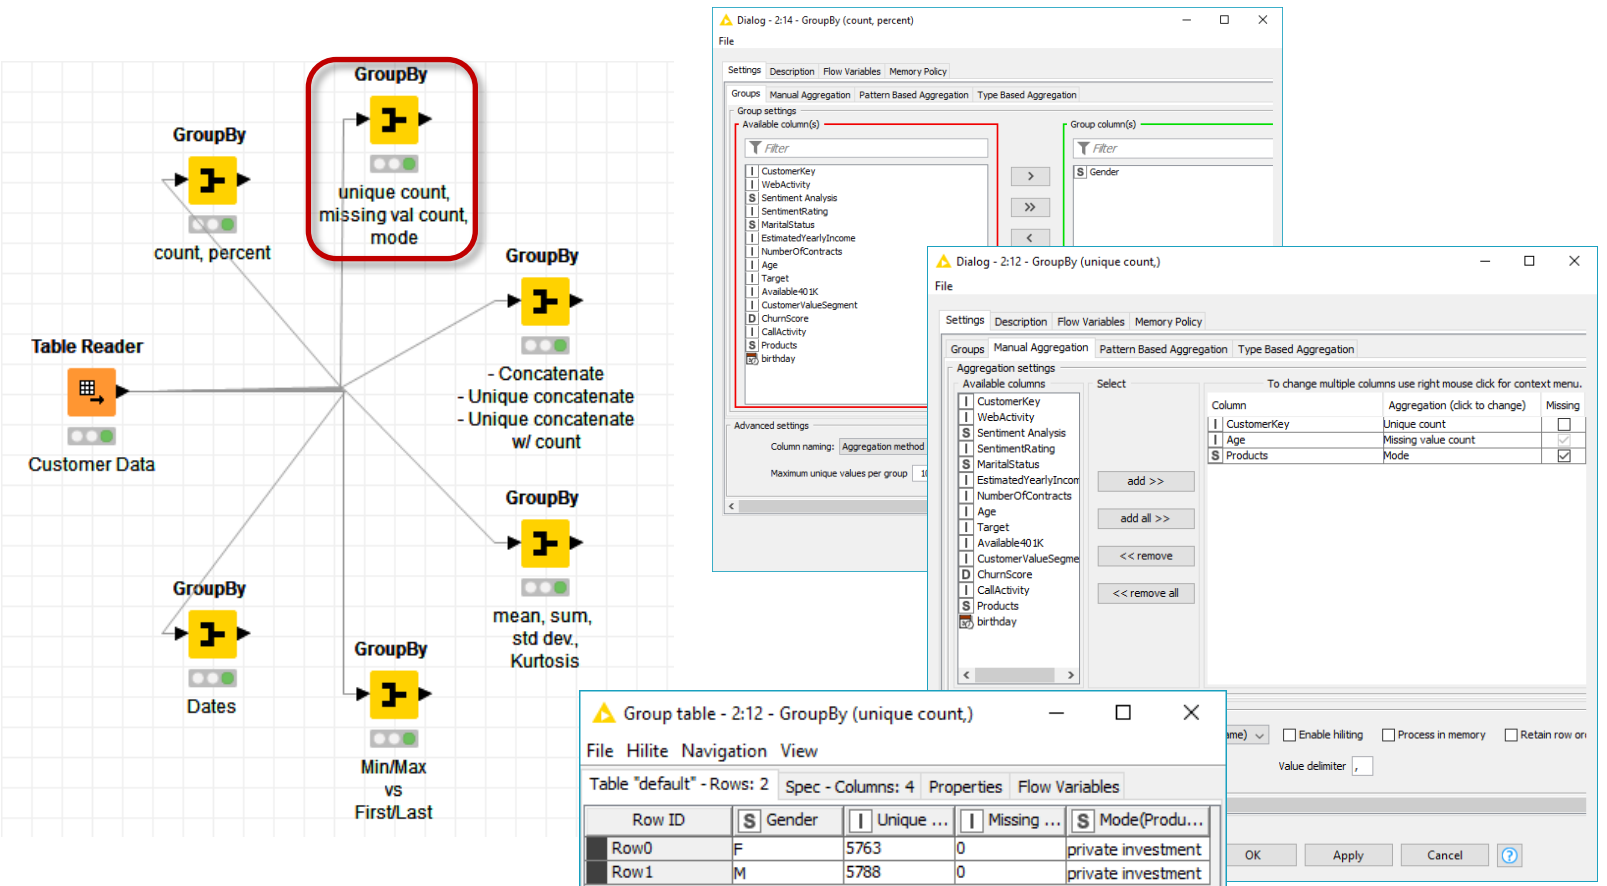

# Operações de Agregação
## *Concatenate*

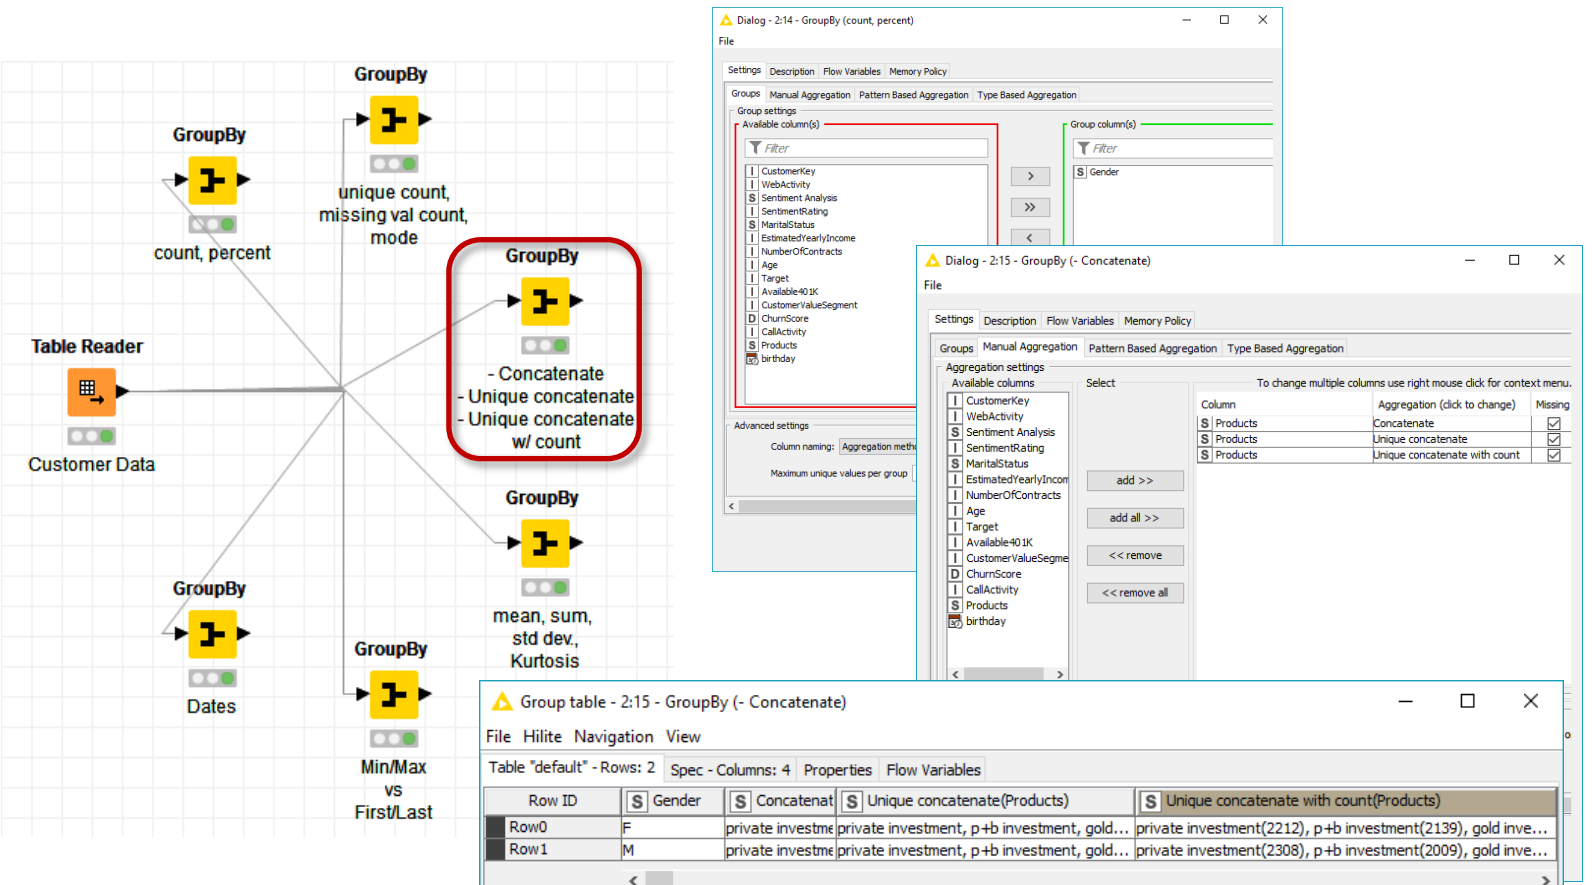

# Operações de Agregação

## *Mean, Sum, Standard Deviation and Kurtosis*

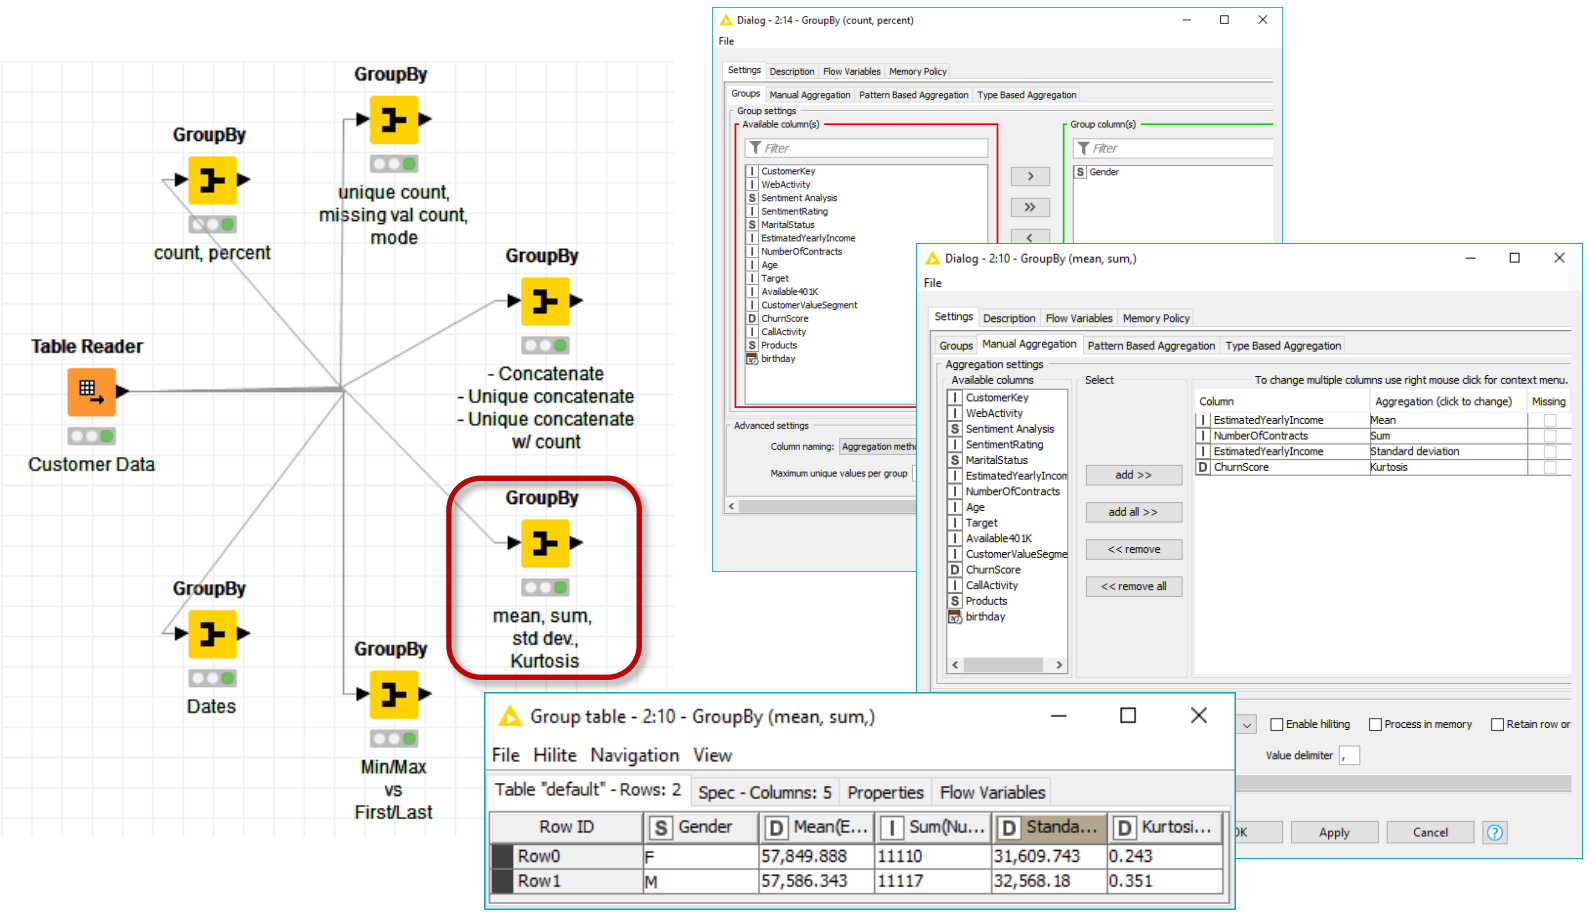

# Operações de Agregação
## *Min/Max vs First/Last*

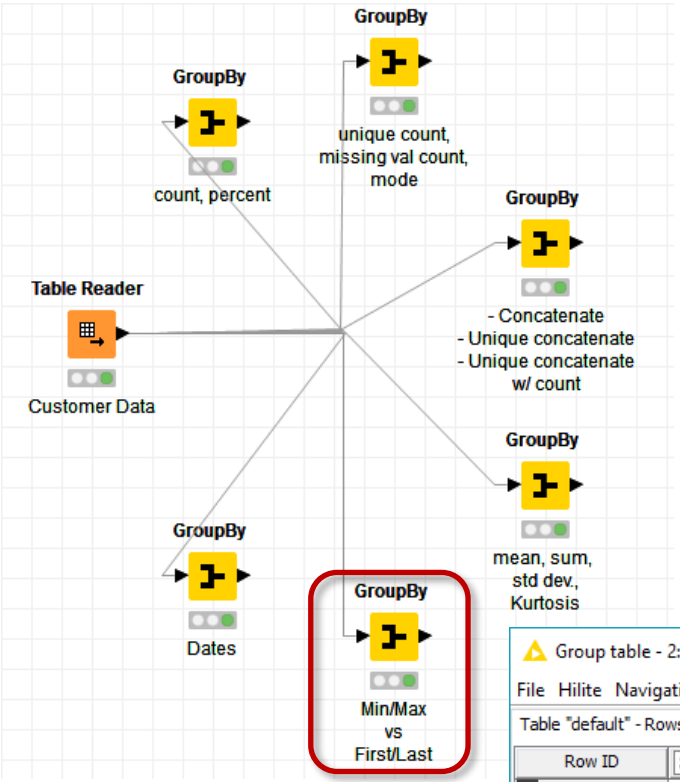


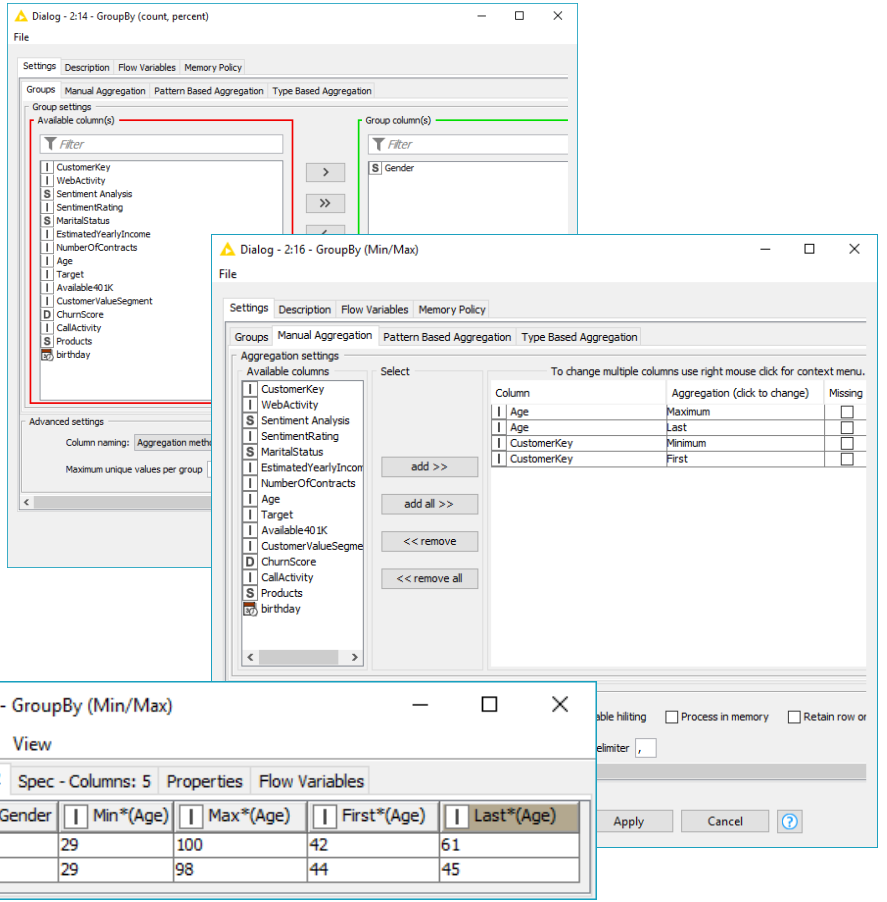

# Operações de Agregação
## *Dates*

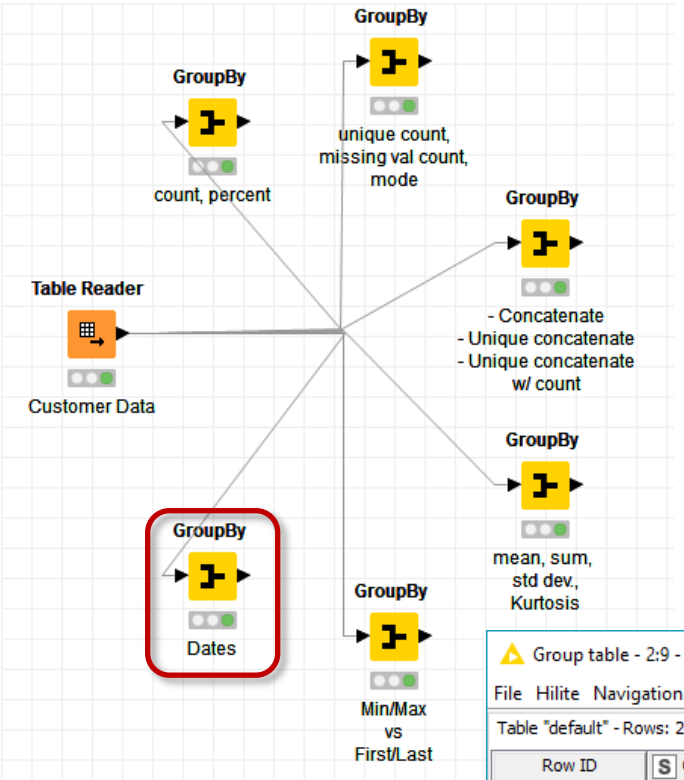


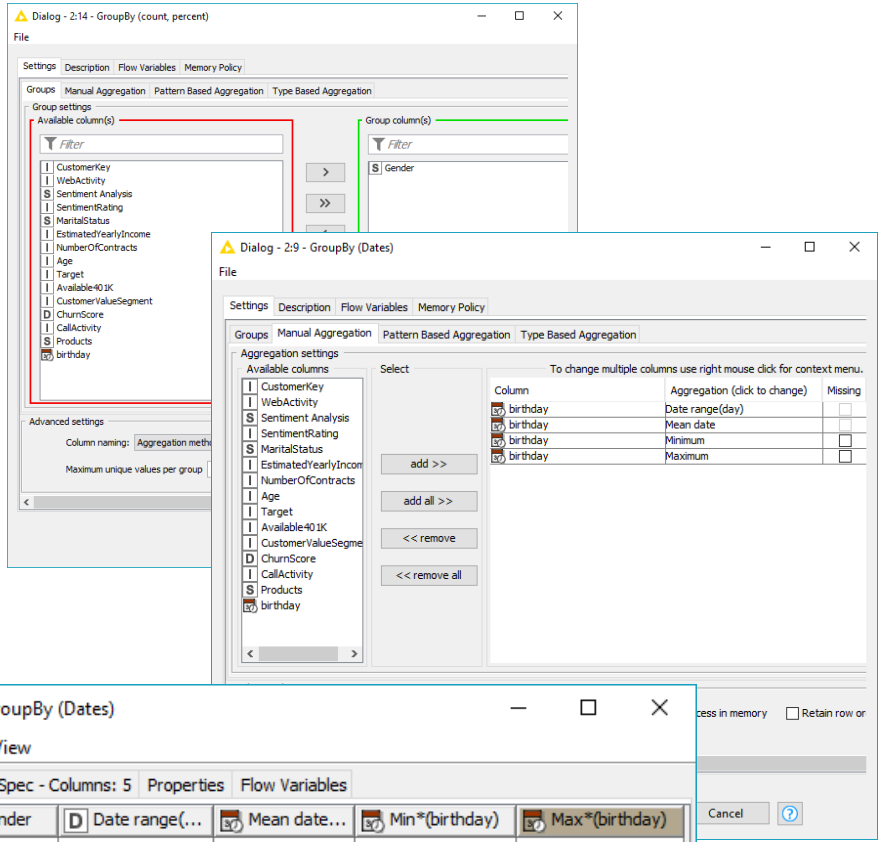

# Operações Avançadas de Agregação
## *Pattern Based*

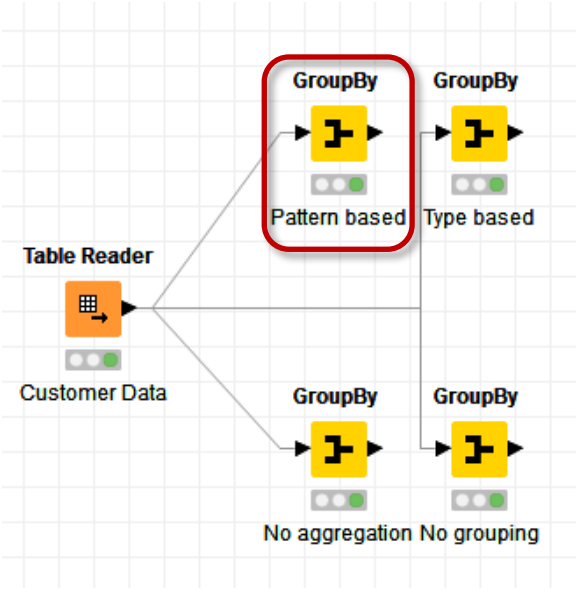


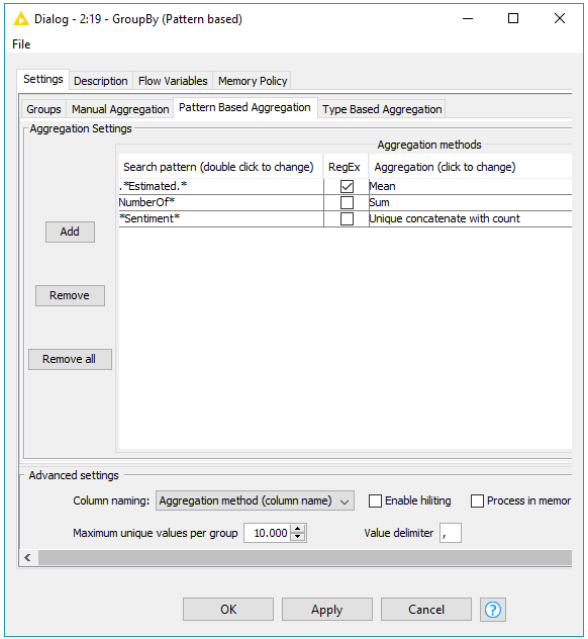


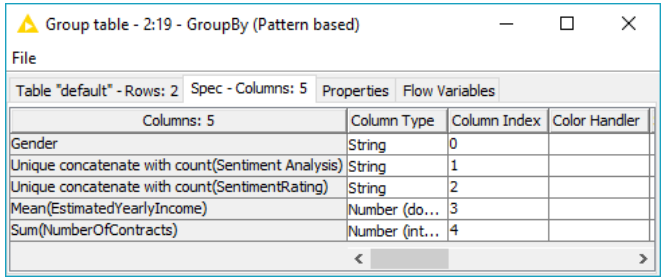


| Columns: 5 | Column Type | Column Index | Color Handler |
|---|---|---|---|
| Gender | String | 0 | |
| Unique concatenate with count(Sentiment Analysis) | String | 1 | |
| Unique concatenate with count(SentimentRating) | String | 2 | |
| Mean(EstimatedYearlyIncome) | Number (do... | 3 | |
| Sum(NumberOfContracts) | Number (int... | 4 | |

# Operações Avançadas de Agregação
## *Data Type Based*

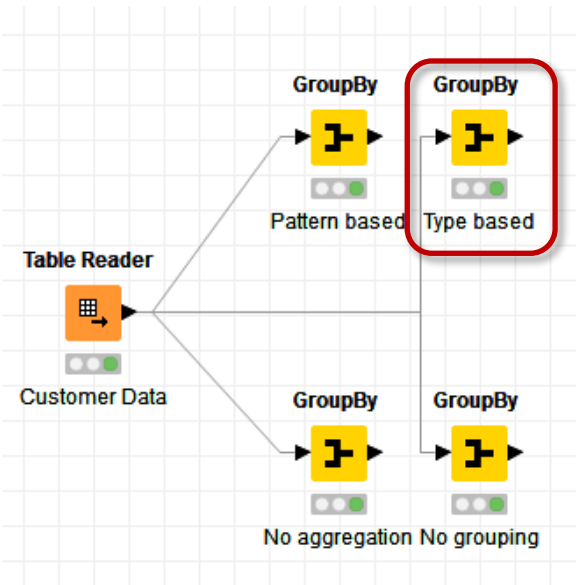


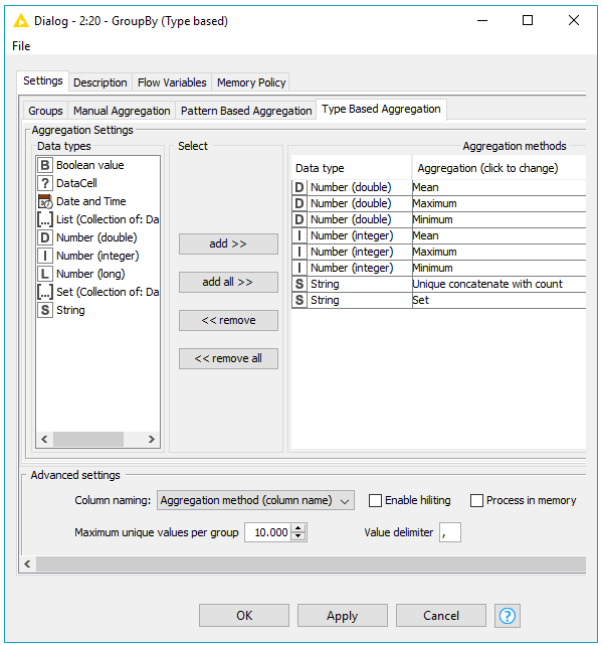


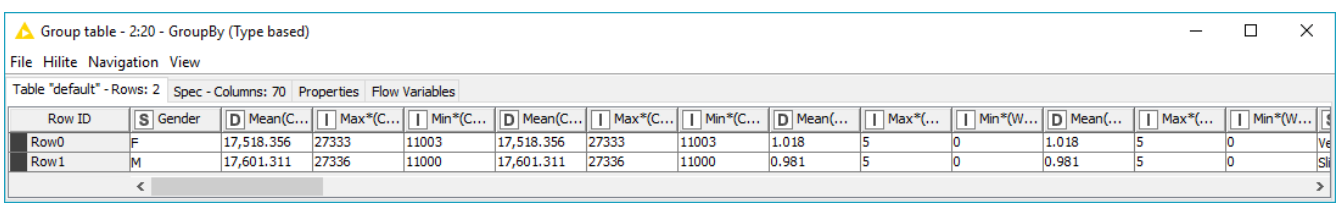


| Row ID | Gender | Mean(C... | Max*(C... | Min*(C... | Mean(C... | Max*(C... | Min*(C... | Mean(... | Max*(... | Min*(W... | Mean(... | Max*(... | Min*(W... |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| Row0 | F | 17,518.356 | 27333 | 11003 | 17,518.356 | 27333 | 11003 | 1.018 | 5 | 0 | 1.018 | 5 | 0 |
| Row1 | M | 17,601.311 | 27336 | 11000 | 17,601.311 | 27336 | 11000 | 0.981 | 5 | 0 | 0.981 | 5 | 0 |

# Operações Avançadas de Agregação
## *No Aggregation vs No Grouping*

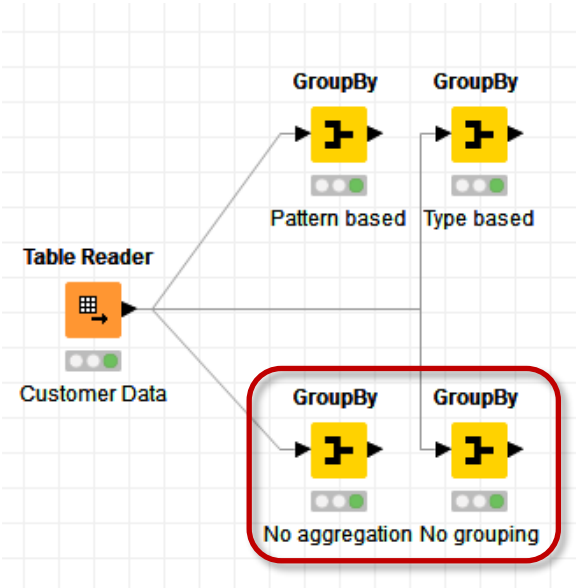


Group table - 2:...

File Hilite Navigation View

Properties | Flow Variables

Table "default" - Rows: 12 | Spec - Columns: 2

| Row ID | S Gen... | S Sentim... |
|---|---|---|
| Row1 | M | Negative |
| Row3 | M | Positive |
| Row5 | M | Slightly Neg... |
| Row7 | M | Slightly Posit... |
| Row9 | M | Very Negative |
| Row11 | M | Very Positive |
| Row0 | F | Negative |
| Row2 | F | Positive |
| Row4 | F | Slightly Neg... |
| Row6 | F | Slightly Posit... |
| Row8 | F | Very Negative |
| Row10 | F | Very Positive |

Group table - 2:18 - GroupBy (No grouping)

File Hilite Navigation View

Table "default" - Rows: 1 | Spec - Columns: 3 | Properties | Flow Variables

| Row ID | D Mean(A... | I Sum(Nu... | S Unique concatenate with count(Sentiment Analysis) |
|---|---|---|---|
| Row0 | 48.203 | 22227 | Slightly Negative(3023), Slightly Positive(1690), Very Negative(4173), Very Positive(1199), Positive(1960), Negative(3122) |

# Preparação Avançada de Dados

- Redimensionamento de atributos/ *Feature scaling*
- Deteção de valores atípicos/ *Outlier detection*
- Seleção de atributos/ *Feature selection*
- Tratamento de valores em falta/ *Missing values treatment*
- Enumeração de valores nominais/ *Nominal value discretization*
- Divisão em intervalos/ *Binning*
- Engenharia de atributos/ *Feature engineering*

# Redimensionamento de atributos
## *Feature scaling*

- Normalizar a gama de valores de atributos;
- Muitos classificadores usam métricas de distância (ex.: distância euclidiana) e, se um atributo tiver uma gama alargada de valores, a distância será definida por esse atributo em particular. Por isso, a gama de valores deve ser normalizada para que cada atributo possa contribuir proporcionalmente para a distância final.

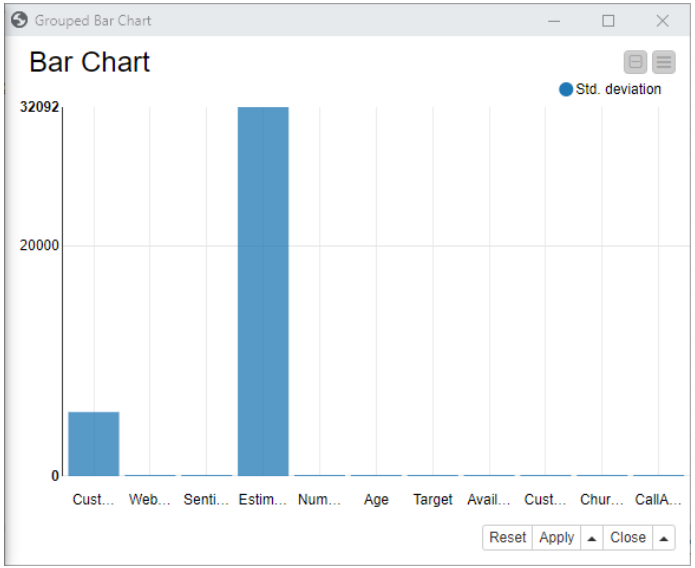


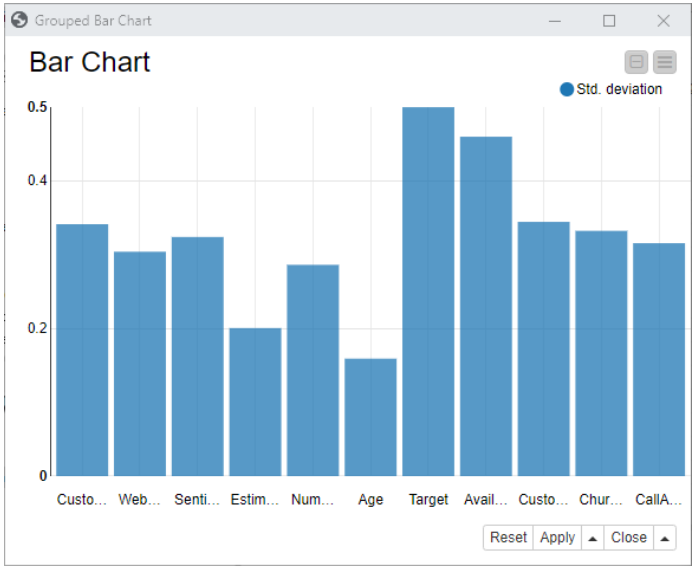

# Redimensionamento de atributos
## *Feature scaling*

- Normalizar a gama de valores de atributos:
  - Normalização:
    Redimensionar os dados para que todos os valores caiam no intervalo de 0 e 1, por exemplo.

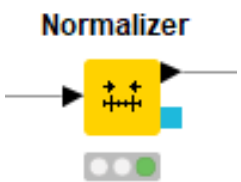


$$z = (b - a)\frac{x - \min(x)}{\max(x) - \min(x)} + a$$

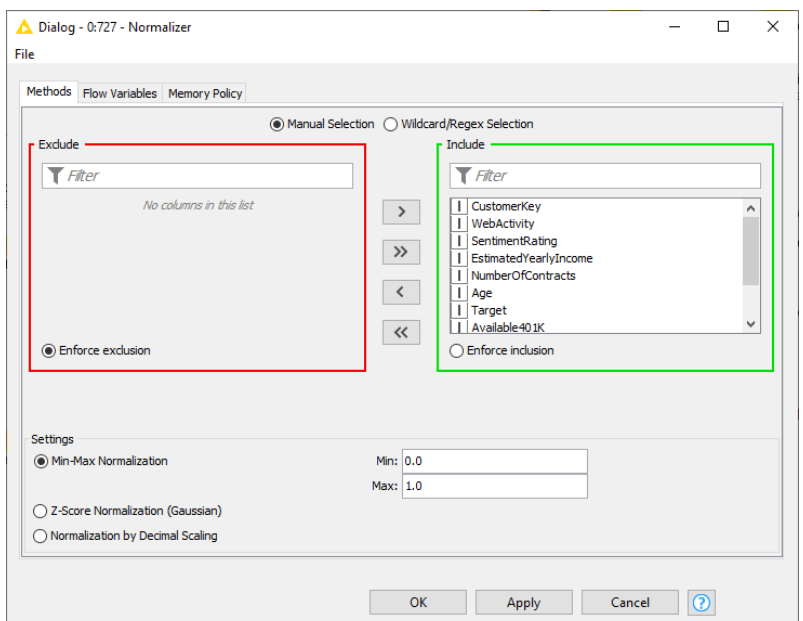

# Redimensionamento de atributos
## *Feature scaling*

- Normalizar a gama de valores de atributos:
  - *Standardization* (ou Z-score *Normalization*):
    Redimensionar a distribuição de valores para que a média dos valores observados seja 0 e o desvio padrão seja 1.
    Assume que os dados se ajustam a uma distribuição gaussiana com média e desvio padrão bem comportados, o que nem sempre é o caso.

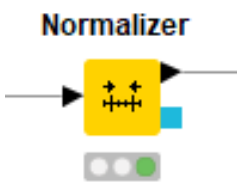


$$z = \frac{x_i - \mu}{\sigma}$$

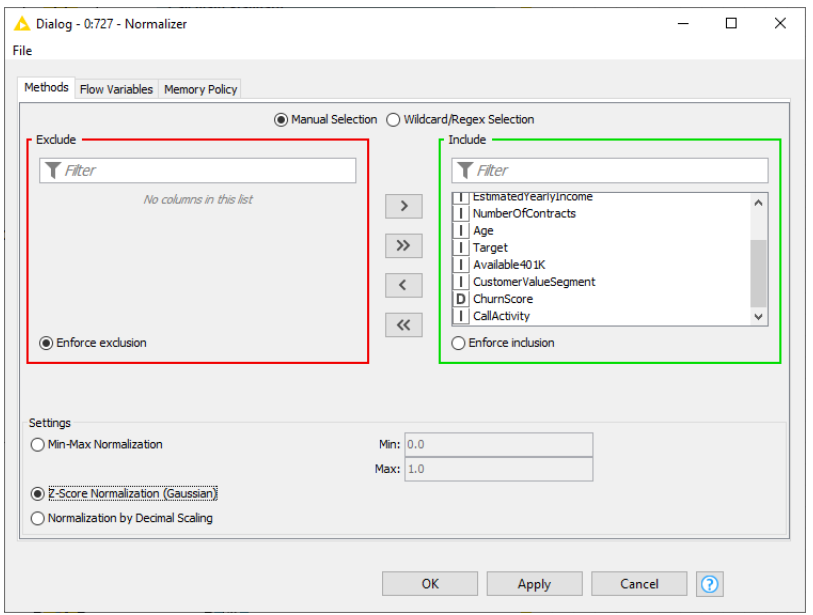

# Deteção de valores atípicos
## *Outlier Detection*

- Deteção de valores atípicos (*outliers*):
  - Estratégias baseadas em estatística:
    - Box Plots
    - Z-Score (std. dev)

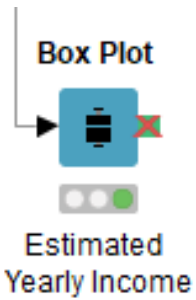


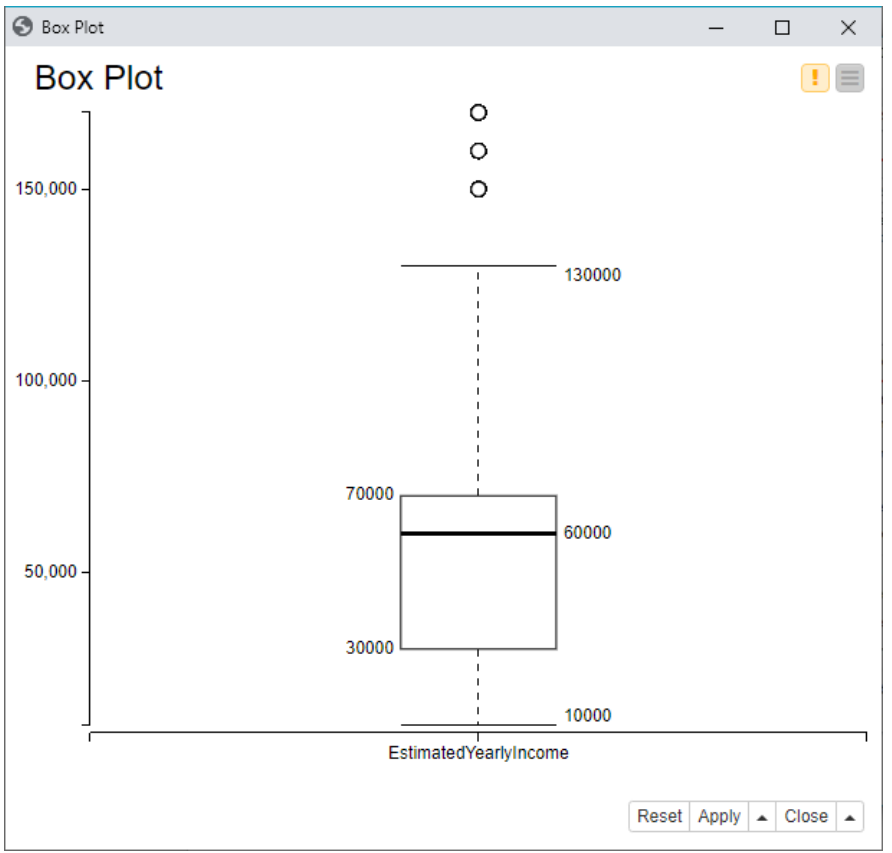

# Deteção de valores atípicos
## *Outlier Detection*

- Deteção de valores atípicos (*outliers*):
  - Estratégias baseadas em conhecimento

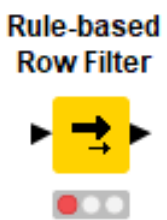


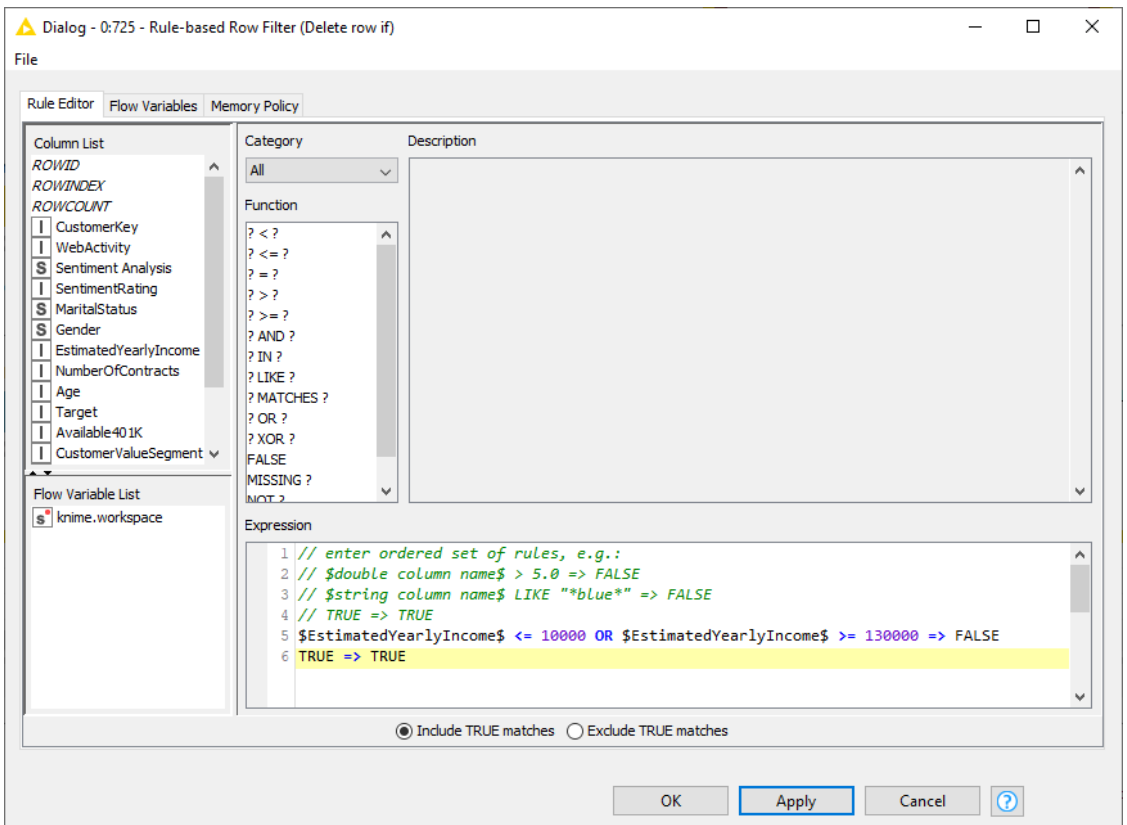

# Deteção de valores atípicos
## *Outlier Detection*

- Deteção de valores atípicos (*outliers*):
  - Estratégias baseadas em conhecimento

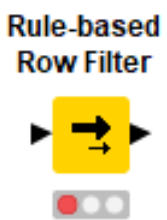


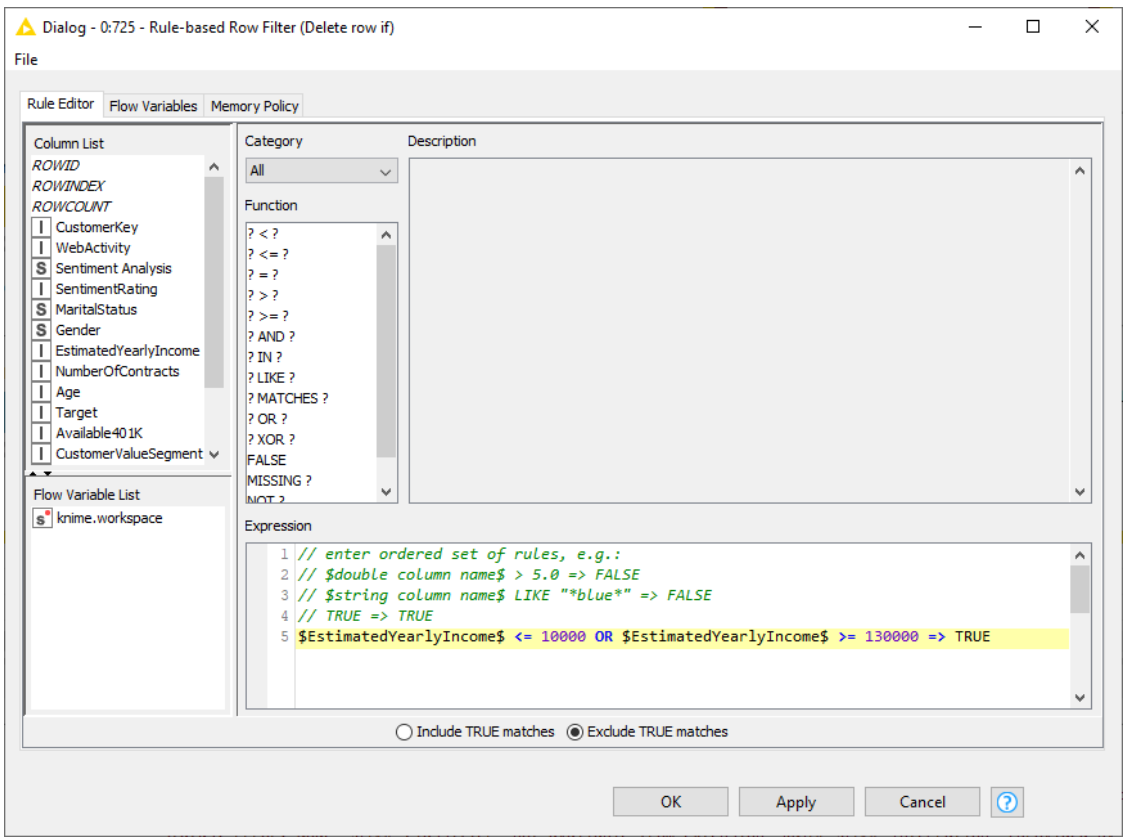

# Deteção de valores atípicos
## *Outlier Detection*

- Deteção de valores atípicos (*outliers*):
  - Estratégias baseadas em modelos:
    - Isolation Forest
    - One-Class SVM
    - Minimum Covariance Determinant
    - ...

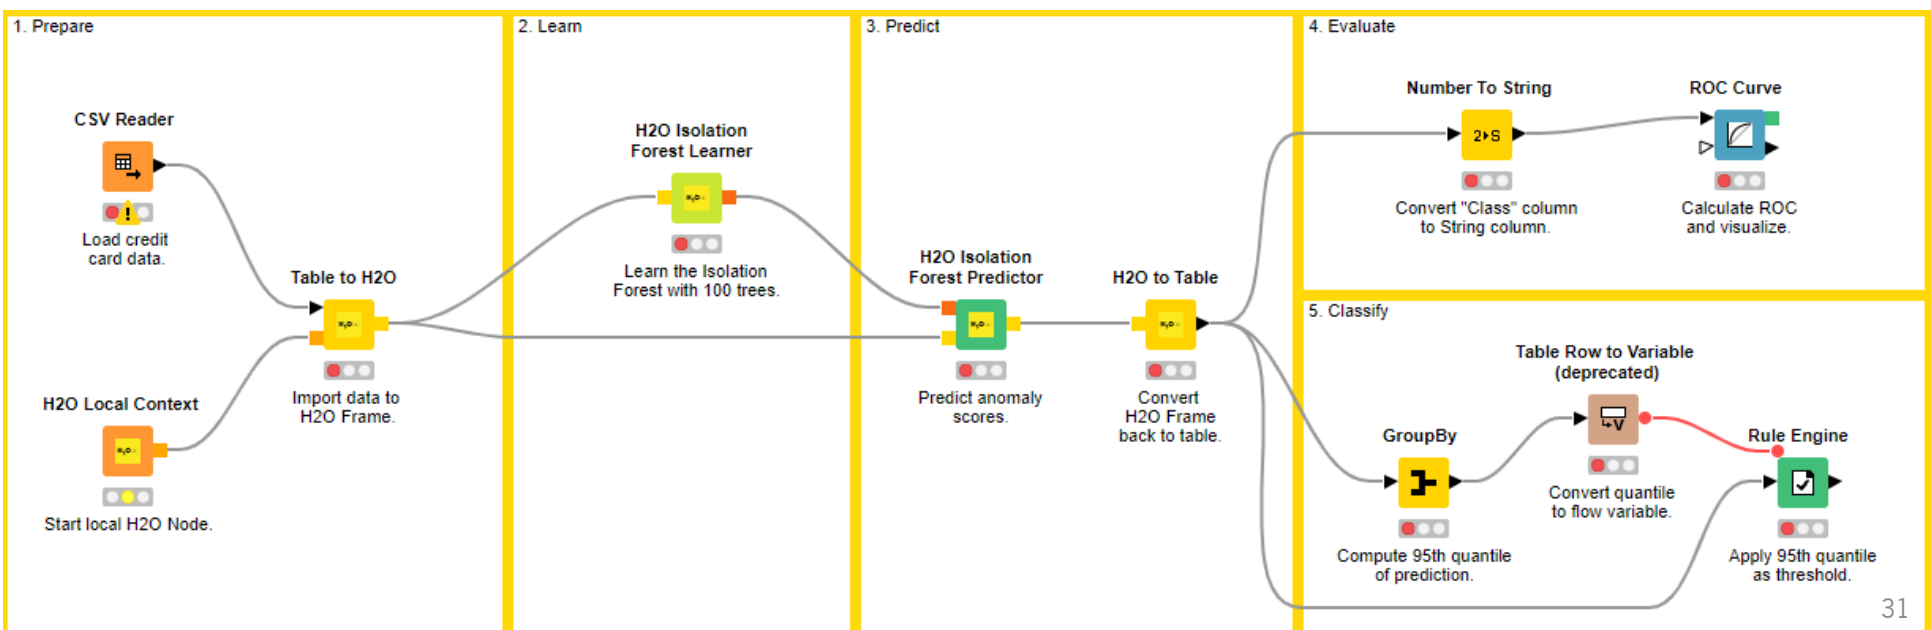

# Seleção de Atributos
## *Feature Selection*

- Seleção de atributos:
  - Que atributos devem ser usados para criar um modelo de previsão?
    - Selecionar um subconjunto de atributos mais importantes para reduzir a dimensionalidade;
  - A remoção de atributos pouco importantes:
    - Pode afetar significativamente o desempenho de um modelo;
    - Reduz o *overfitting* (menor probabilidade de tomar decisões com base em ruído);
    - Melhora a precisão;
    - Ajuda a reduzir a complexidade de um modelo (reduz o tempo de treino);
  - O que podemos remover:
    - Atributos redundantes (duplicados);
    - Atributos irrelevantes e desnecessários (não úteis);
  - Métodos de seleção de atributos:
    - Métodos de filtro;
    - Métodos *wrapper*;
    - Métodos embebidos;

- Métodos de Filtro:
  - Remover uma *feature* se a percentagem de *missing values* for superior a um determinado valor estabelecido;

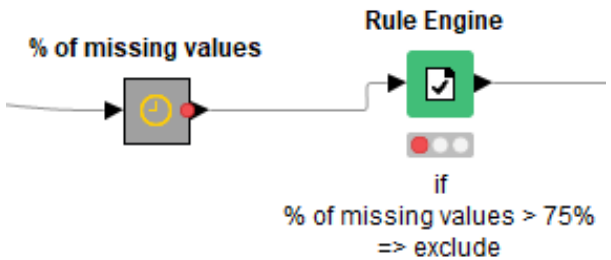


  - Usar o teste "chi-square" para medir o grau de dependência entre uma *feature* e o *target*:
    - Para cada *feature* calcular $X^2$;
    - Normalizar $X^2$ e ordenar de forma decrescente;
    - Selecionar 'n' *features* com maior importância;
      (ou as que estão acima de um determinado limite)

# Seleção de Atributos
## *Feature Selection*

- Métodos de Filtro:
  - ...
  - Remover uma *feature* se o valor do desvio padrão for baixo;
  - Remover uma *feature* se o valor de *skew* for elevado;
  - Remover *features* com alta correlação;

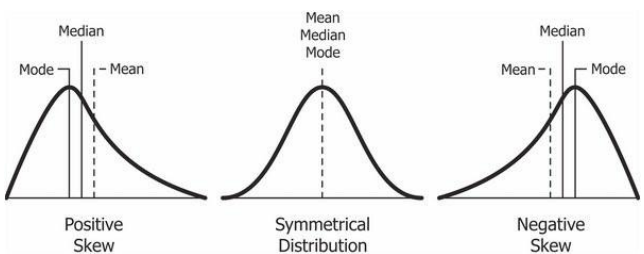


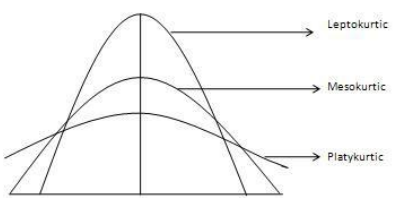


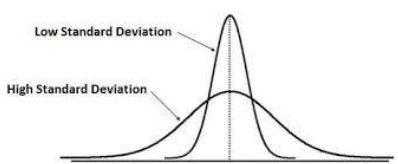


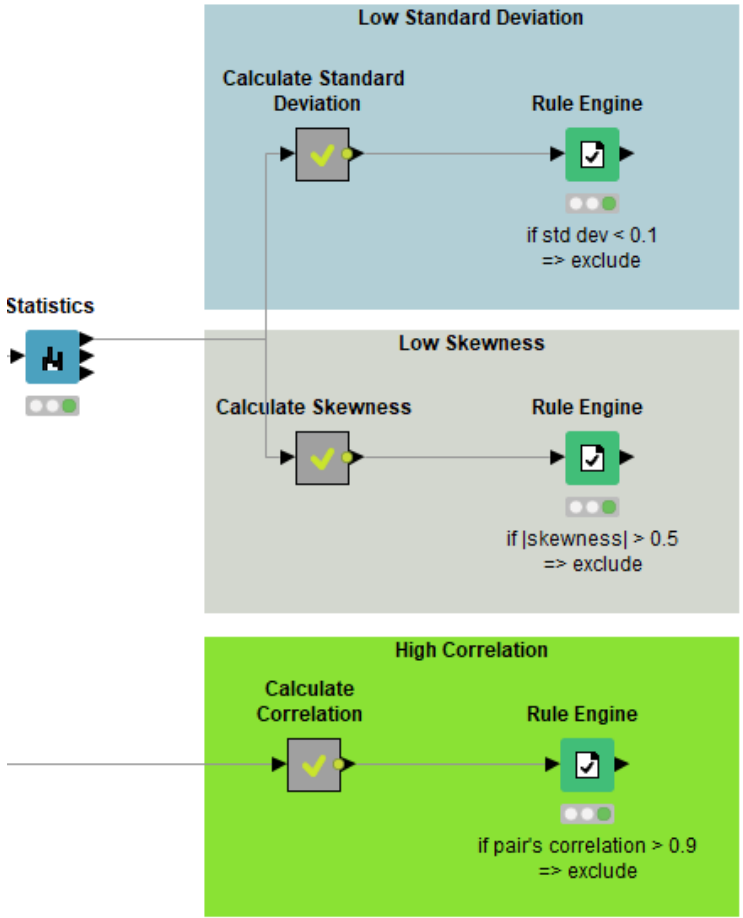

- Métodos de Filtro:
  - ...
  - Principal Component Analysis (PCA):
    - Técnica usada para reduzir a dimensão do espaço de *features*;
    - O objetivo é reduzir o número de *features* sem perder (demasiado) conhecimento;
    - Uma aplicação comum de PCA é para visualização de dados de grande dimensão;

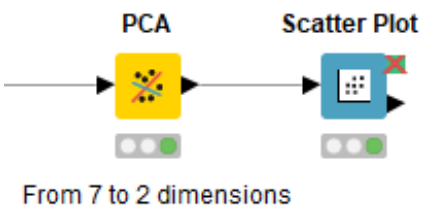


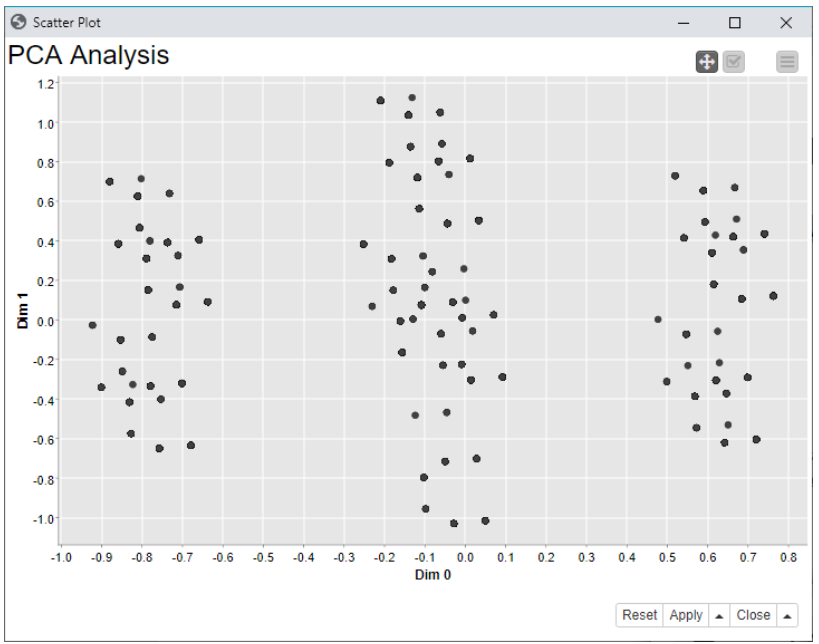

- Métodos *wrapper*:
  - Utilizar técnicas de *machine learning* para selecionar as *features* mais importantes;
    - Selecionar um conjunto de *features* como um problema de pesquisa;
    - Preparar diferentes combinações;
    - Avaliar e comparar as diferentes combinações;
    - Medir a "utilidade" das *features* com base no desempenho do classificador;
  - *Sequential Forward Selection*

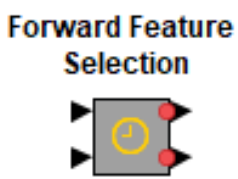


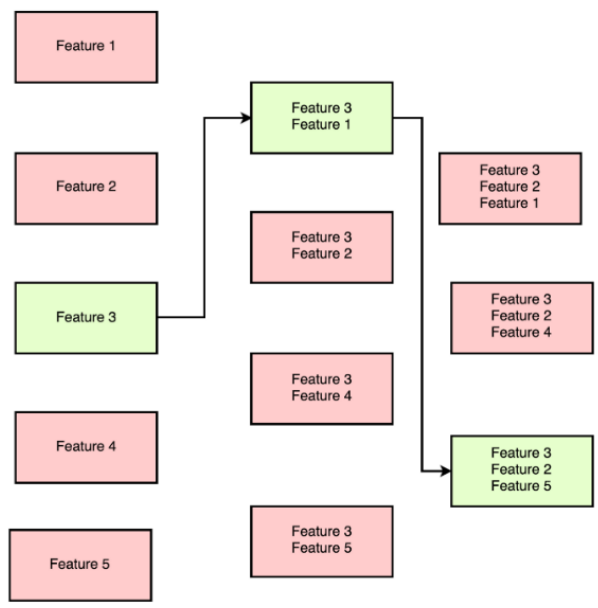

- Métodos *wrapper*:
  - Utilizar técnicas de *machine learning* para selecionar as *features* mais importantes;
    - Selecionar um conjunto de *features* como um problema de pesquisa;
    - Preparar diferentes combinações;
    - Avaliar e comparar as diferentes combinações;
    - Medir a "utilidade" das *features* com base no desempenho do classificador;
  - *Backward Feature Elimination*

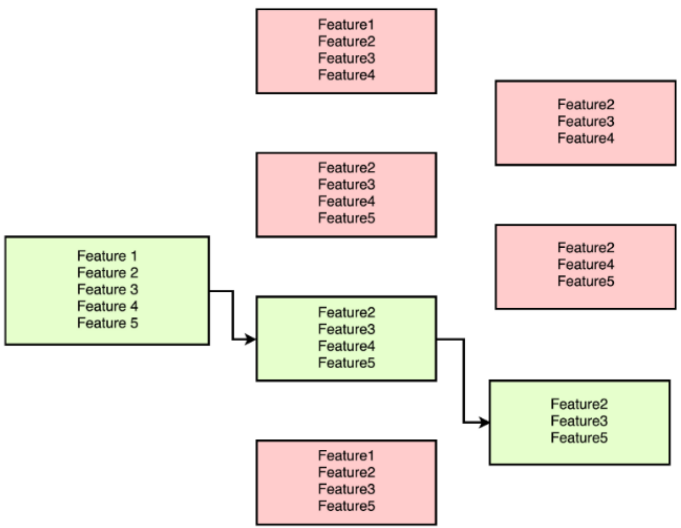

# Tratamento de Valores em Falta
## *Missing Values*

- Tratamento de valores em falta:
  - Analisar cada atributo em relação ao número e proporção de valores em falta;
  - Decidir o que fazer:
    - Remover;
    - Calcular a média;
    - Interpolação linear;
    - Criar máscaras;
    - ...

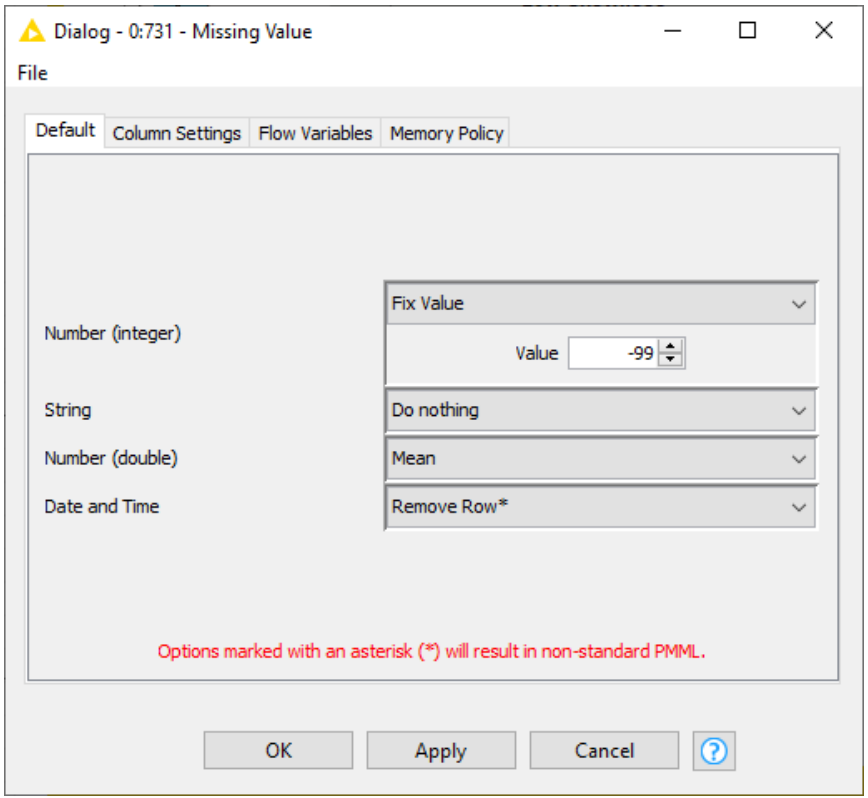

# Enumeração de Valores Nominais
## *Nominal Value Discretization/Encoding*

- Enumeração de valores nominais:
  - Os dados categóricos/nominais contêm valores de "etiquetas" em vez de valores numéricos;
  - Podem ser aplicados vários métodos:
    - *Label Encoding*;
    - *One-Hot Encoding*;
    - *Binary Encoding*;

# Enumeração de Valores Nominais
## *Nominal Value Discretization/Encoding*

| Movie | Genre |
|---|---|
| Jumanji | Adventure |
| American Pie | Comedy |
| Braveheart | Drama |
| … | … |

# Enumeração de Valores Nominais
## *Nominal Value Discretization/Encoding*

| Movie | Genre |
|---|---|
| Jumanji | Adventure |
| American Pie | Comedy |
| Braveheart | Drama |
| … | … |

**Label Encoded**

| Movie | Genre | Category |
|---|---|---|
| Jumanji | Adventure | 0 |
| American Pie | Comedy | 1 |
| Braveheart | Drama | 2 |
| … | … | |

# Enumeração de Valores Nominais
## *Nominal Value Discretization/Encoding*

| Movie | Genre |
|---|---|
| Jumanji | Adventure |
| American Pie | Comedy |
| Braveheart | Drama |
| … | … |

**One-Hot Encoded**

| Movie | Adventure | Comedy | Drama |
|---|---|---|---|
| Jumanji | 1 | 0 | 0 |
| American Pie | 0 | 1 | 0 |
| Braveheart | 0 | 0 | 1 |
| … | … | | |

# Enumeração de Valores Nominais
## *Nominal Value Discretization/Encoding*

| Movie | Genre |
|---|---|
| Jumanji | Adventure |
| American Pie | Comedy |
| Braveheart | Drama |
| … | … |

**Label Encoded**

| Movie | Genre | Category |
|---|---|---|
| Jumanji | Adventure | 0 |
| American Pie | Comedy | 1 |
| Braveheart | Drama | 2 |
| … | … | |

Integer values have a natural ordered relationship between each other. ML models may be able to understand such relationships.

**One-Hot Encoded**

| Movie | Adventure | Comedy | Drama |
|---|---|---|---|
| Jumanji | 1 | 0 | 0 |
| American Pie | 0 | 1 | 0 |
| Braveheart | 0 | 0 | 1 |
| … | … | | |

Categorical features where no such ordinal relationship exists. However, for a huge number of categories…

# Enumeração de Valores Nominais
## *Nominal Value Discretization/Encoding*

- Enumeração de valores nominais:

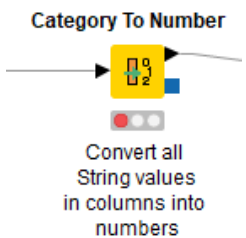


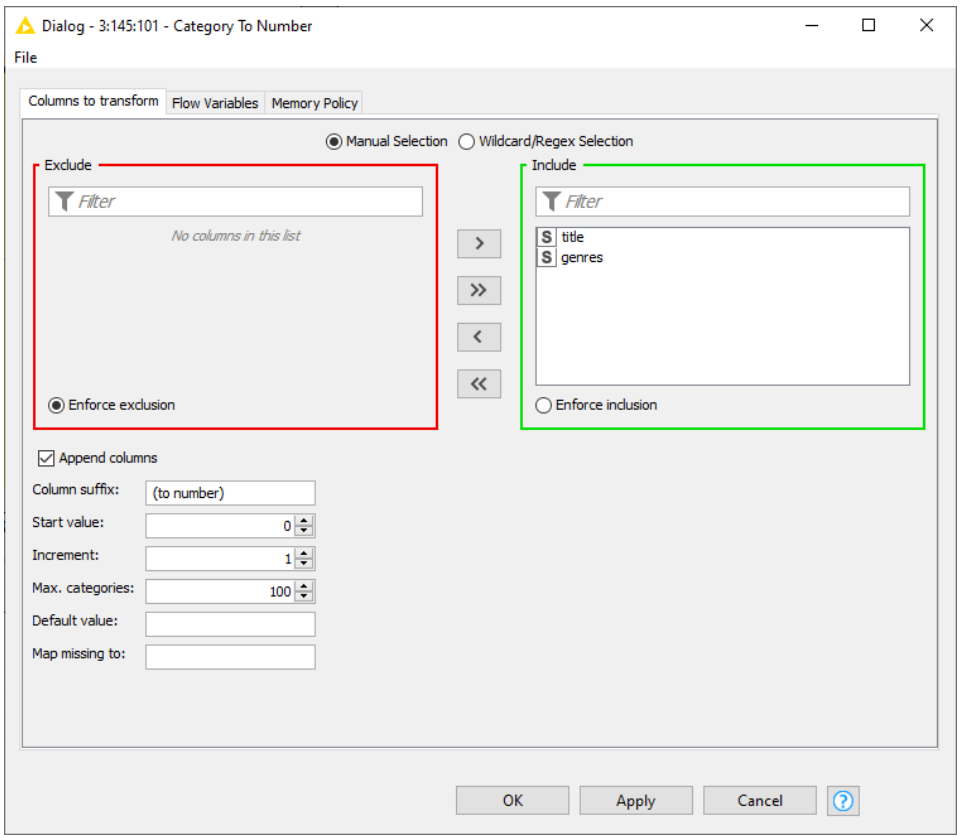

# Enumeração de Valores Nominais
## *Nominal Value Discretization/Encoding*

- Enumeração de valores nominais:

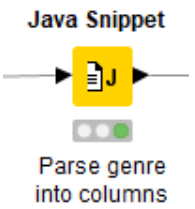


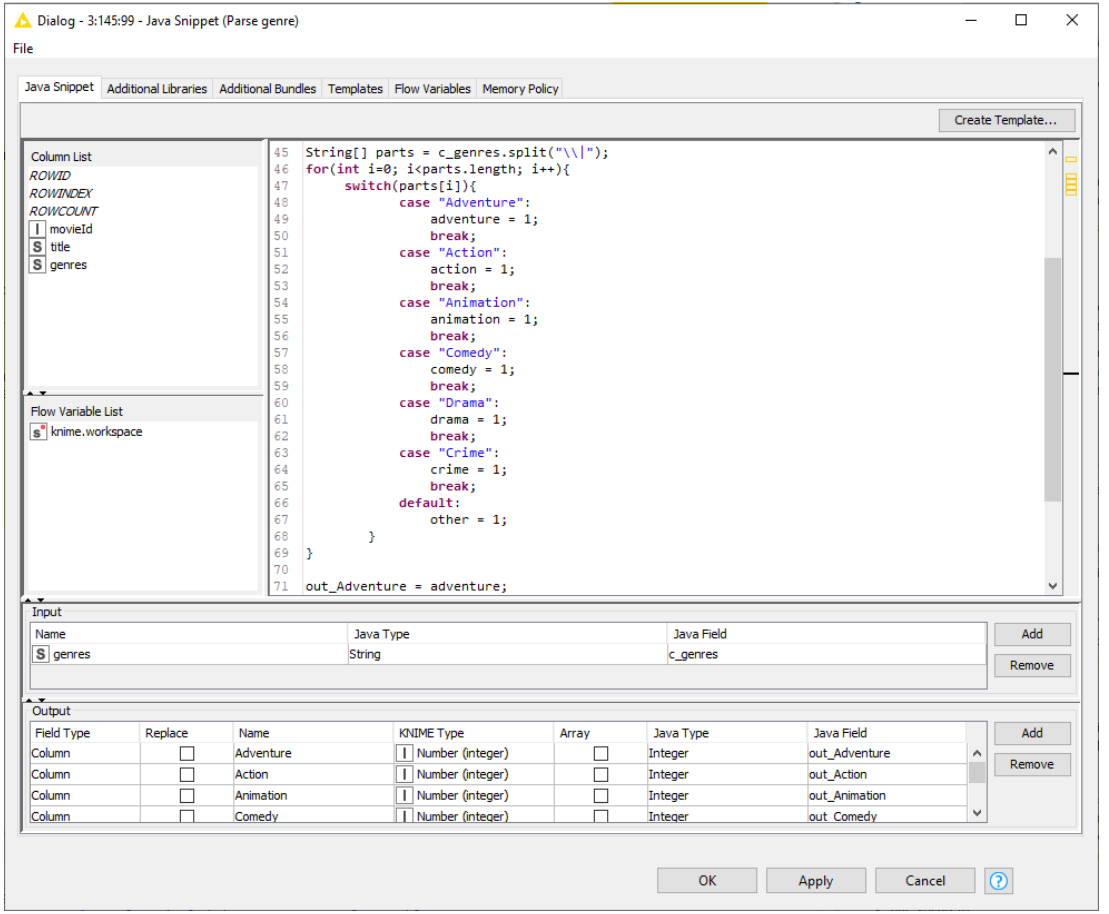

# Divisão em Intervalos
## *Binning*

- Divisão em intervalos:
  - Transformação de valores contínuos em discretos (*bins*):
    - Torna o modelo mais robusto e evita o *overfitting*;
    - Penaliza o desempenho do modelo, uma vez que, sempre que se descartam dados, perde-se conhecimento;

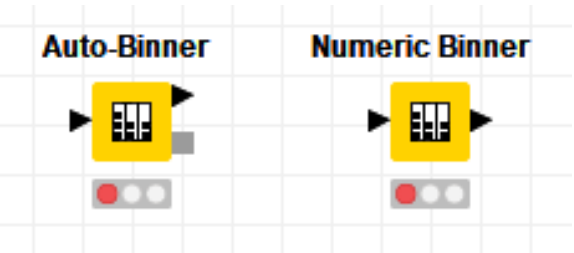


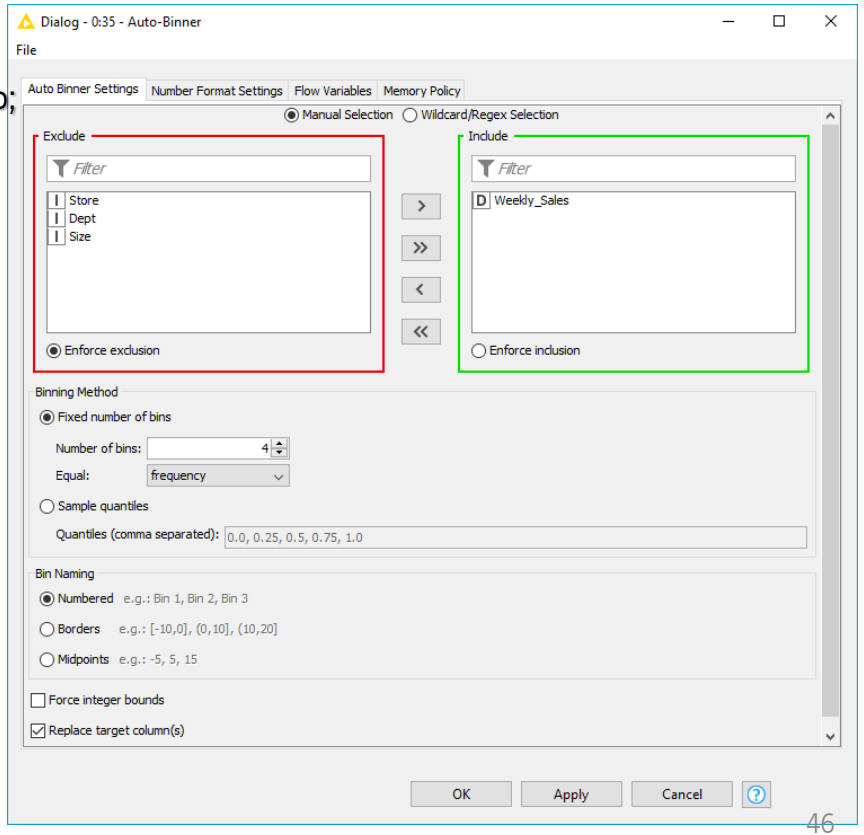

# Divisão em Intervalos
## *Binning*

- Divisão em intervalos:
  - Transformação de valores contínuos em discretos (*bins*)
    - Torna o modelo mais robusto e evita o *overfitting*;
    - Penaliza o desempenho do modelo, uma vez que sempre que se descartam dados, perde-se conhecimento;

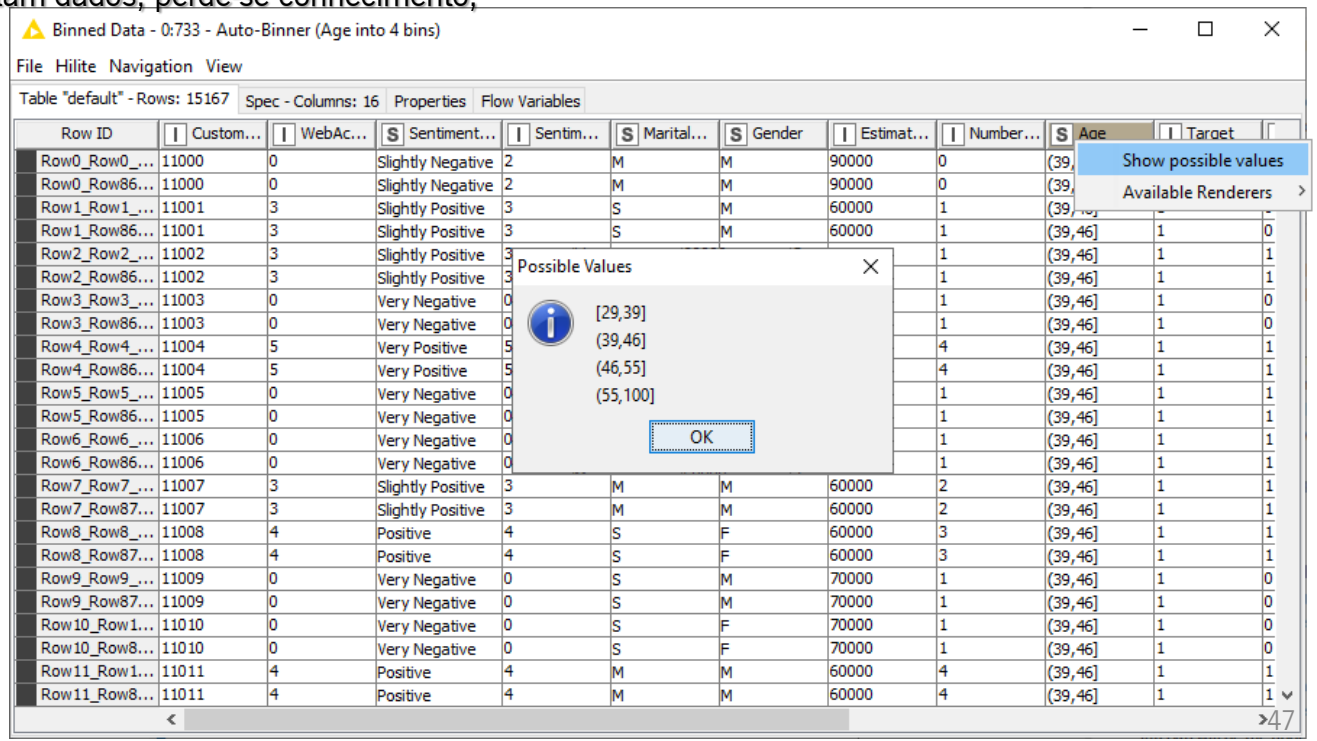


| Row ID | Custom... | WebAc... | Sentiment... | Sentim... | Marital... | Gender | Estimat... | Number... | Age | Target |
|---|---|---|---|---|---|---|---|---|---|---|
| Row0_Row0_... | 11000 | 0 | Slightly Negative | 2 | M | M | 90000 | 0 | (39, | |
| Row0_Row86... | 11000 | 0 | Slightly Negative | 2 | M | M | 90000 | 0 | (39, | |
| Row1_Row1_... | 11001 | 3 | Slightly Positive | 3 | S | M | 60000 | 1 | (39, | |
| Row1_Row86... | 11001 | 3 | Slightly Positive | 3 | S | M | 60000 | 1 | (39,46] | 1 |
| Row2_Row2_... | 11002 | 3 | Slightly Positive | 3 | | | | 1 | (39,46] | 1 |
| Row2_Row86... | 11002 | 3 | Slightly Positive | 3 | | | | 1 | (39,46] | 1 |
| Row3_Row3_... | 11003 | 0 | Very Negative | 0 | | | | 1 | (39,46] | 1 |
| Row3_Row86... | 11003 | 0 | Very Negative | 0 | | | | 1 | (39,46] | 1 |
| Row4_Row4_... | 11004 | 5 | Very Positive | 5 | | | | 4 | (39,46] | 1 |
| Row4_Row86... | 11004 | 5 | Very Positive | 5 | | | | 4 | (39,46] | 1 |
| Row5_Row5_... | 11005 | 0 | Very Negative | 0 | | | | 1 | (39,46] | 1 |
| Row5_Row86... | 11005 | 0 | Very Negative | 0 | | | | 1 | (39,46] | 1 |
| Row6_Row6_... | 11006 | 0 | Very Negative | 0 | | | | 1 | (39,46] | 1 |
| Row6_Row86... | 11006 | 0 | Very Negative | 0 | | | | 1 | (39,46] | 1 |
| Row7_Row7_... | 11007 | 3 | Slightly Positive | 3 | M | M | 60000 | 2 | (39,46] | 1 |
| Row7_Row87... | 11007 | 3 | Slightly Positive | 3 | M | M | 60000 | 2 | (39,46] | 1 |
| Row8_Row8_... | 11008 | 4 | Positive | 4 | S | F | 60000 | 3 | (39,46] | 1 |
| Row8_Row87... | 11008 | 4 | Positive | 4 | S | F | 60000 | 3 | (39,46] | 1 |
| Row9_Row9_... | 11009 | 0 | Very Negative | 0 | S | M | 70000 | 1 | (39,46] | 1 |
| Row9_Row87... | 11009 | 0 | Very Negative | 0 | S | M | 70000 | 1 | (39,46] | 1 |
| Row10_Row1... | 11010 | 0 | Very Negative | 0 | S | F | 70000 | 1 | (39,46] | 1 |
| Row10_Row8... | 11010 | 0 | Very Negative | 0 | S | F | 70000 | 1 | (39,46] | 1 |
| Row11_Row1... | 11011 | 4 | Positive | 4 | M | M | 60000 | 4 | (39,46] | 1 |
| Row11_Row8... | 11011 | 4 | Positive | 4 | M | M | 60000 | 4 | (39,46] | 1 |

# Engenharia de Atributos
## *Feature Engineering*

- Engenharia de atributos:
  - Processo de criação de novos atributos (*features*);
  - Aumentar o conhecimento/aumentar o desempenho dos modelos;

- De um atributo do tipo "data", que conhecimento se pode extrair?
  - 2020/10/29 16:30

# Engenharia de Atributos
## *Feature Engineering*

- Engenharia de atributos:
  - Processo de criação de novos atributos (*features*);
  - Aumentar o conhecimento/aumentar o desempenho dos modelos;

- De um atributo do tipo "data", que conhecimento se pode extrair?
  - 2020/10/29 16:30
    - Ano, mês, dia
    - Horas, minutos, segundos
    - Dia da semana (quinta-feira)
    - Dia útil ou fim de semana?
    - Dia útil ou feriado?
    - ...

# Engenharia de Atributos
## *Feature Engineering*

- Engenharia de atributos:
  - Processo de criação de novos atributos (*features*);
  - Aumentar o conhecimento/aumentar o desempenho dos modelos;

- De um atributo do tipo "data", que conhecimento se pode extrair?
  - 2020/10/29 16:30

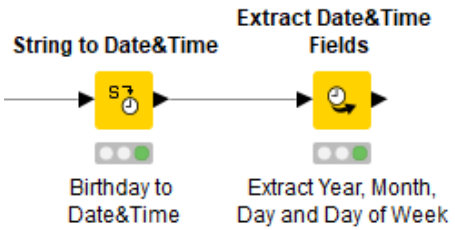


Output table - 0:734 - Extract Date&Time Fields (Extract Year, Month,)

File Hilite Navigation View

Table "default" - Rows: 15167 | Spec - Columns: 20 | Properties | Flow Variables

| Row ID | .. | D ChurnS... | I CallActi... | S Products | birthday | I Year | I Month (number) | I Day of year | S Day of week (name) |
|---|---|---|---|---|---|---|---|---|---|
| Row0_Row0_... | | 0.1 | 4 | private investment | 1972-01-14 | 1972 | 1 | 14 | Sexta-feira |
| Row0_Row86... | | 0.1 | 4 | private investment | 1971-08-28 | 1971 | 8 | 240 | Sábado |
| Row1_Row1_... | | 0 | 4 | private investment | 1970-06-26 | 1970 | 6 | 177 | Sexta-feira |
| Row1_Row86... | | 0 | 4 | private investment | 1971-02-11 | 1971 | 2 | 42 | Quinta-feira |
| Row2_Row2_... | | 0.2 | 4 | private investment | 1971-01-27 | 1971 | 1 | 27 | Quarta-feira |
| Row2_Row86... | | 0.2 | 4 | private investment | 1971-02-17 | 1971 | 2 | 48 | Quarta-feira |
| Row3_Row3_... | | 0.5 | 4 | private investment | 1973-11-07 | 1973 | 11 | 311 | Quarta-feira |
| Row3_Row86... | | 0.5 | 4 | private investment | 1974-02-14 | 1974 | 2 | 45 | Quinta-feira |
| Row4_Row4_... | | 0.1 | 4 | private investment | 1973-09-21 | 1973 | 9 | 264 | Sexta-feira |
| Row4_Row86... | | 0.1 | 4 | private investment | 1974-01-02 | 1974 | 1 | 2 | Quarta-feira |
| Row5_Row5_... | | 0.5 | 4 | private investment | 1970-06-05 | 1970 | 6 | 156 | Sexta-feira |
| Row5_Row86... | | 0.5 | 4 | private investment | 1970-05-06 | 1970 | 5 | 126 | Quarta-feira |
| Row6_Row6_... | | 0.5 | 4 | private investment | 1971-07-29 | 1971 | 7 | 210 | Quinta-feira |
| Row6_Row86... | | 0.5 | 4 | private investment | 1972-01-19 | 1972 | 1 | 19 | Quarta-feira |
| Row7_Row7_... | | 0 | 4 | private investment | 1970-01-03 | 1970 | 1 | 3 | Sábado |
| Row7_Row87... | | 0 | 4 | private investment | 1970-02-07 | 1970 | 2 | 38 | Sábado |
| Row8_Row8_... | | 1 | 4 | private investment | 1970-03-12 | 1970 | 3 | 71 | Quinta-feira |
| Row8_Row87... | | 1 | 4 | private investment | 1969-08-04 | 1969 | 8 | 216 | Segunda-feira |
| Row9_Row9_... | | 0.5 | 4 | private investment | 1969-07-21 | 1969 | 7 | 202 | Segunda-feira |
| Row9_Row87... | | 0.5 | 4 | private investment | 1969-10-28 | 1969 | 10 | 301 | Terça-feira |
| Row10_Row1... | | 0.5 | 4 | private investment | 1969-11-06 | 1969 | 11 | 310 | Quinta-feira |

# Engenharia de Atributos
## *Feature Engineering*

- Engenharia de atributos:
  - Processo de criação de novos atributos (*features*);
  - Aumentar o conhecimento/aumentar o desempenho dos modelos;

- De um atributo com coordenadas geográficas?
  - 41.561859, -8.397455

    - Localização urbana ou rural?
    - Terra ou mar?
    - Quais as ruas na vizinhança deste ponto?
    - Há escolas/mercados/serviços nas imediações?
    - ...

# Outros Nodos

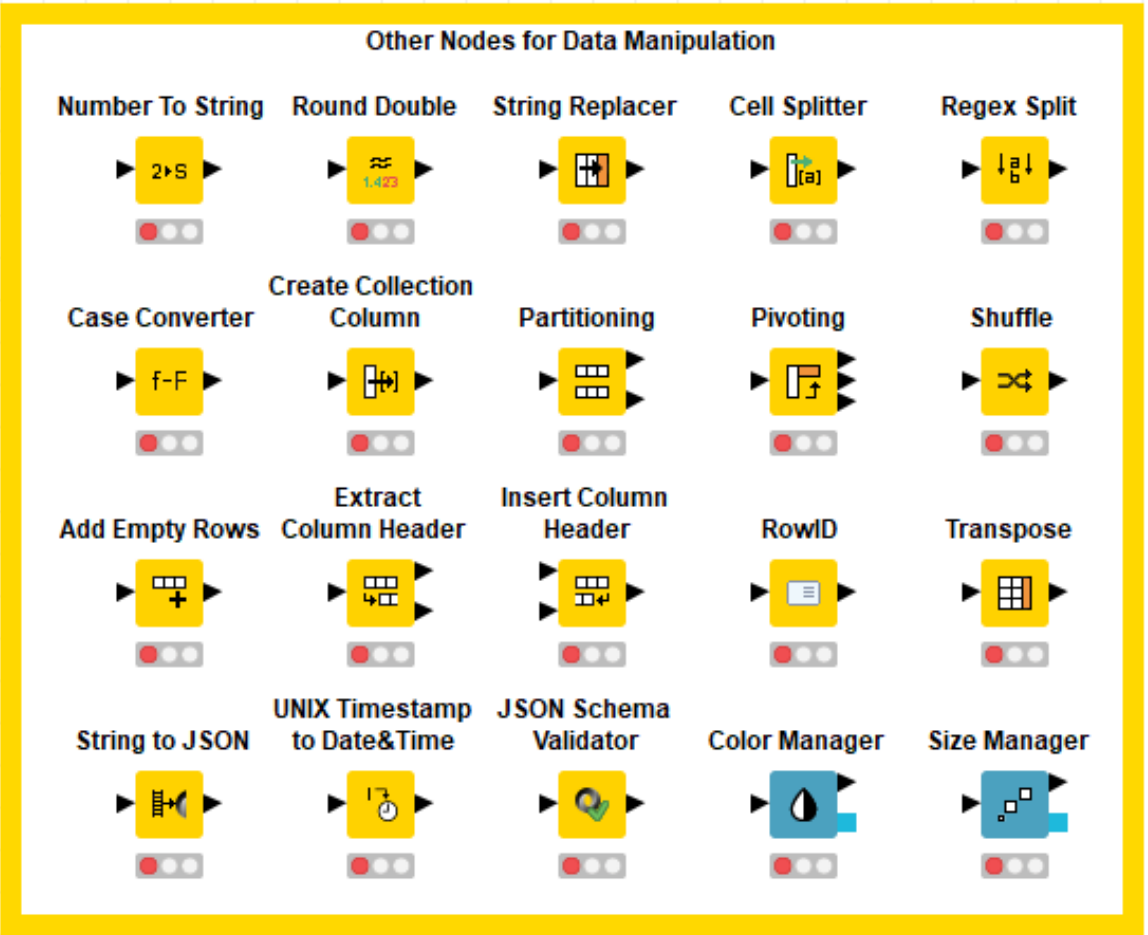

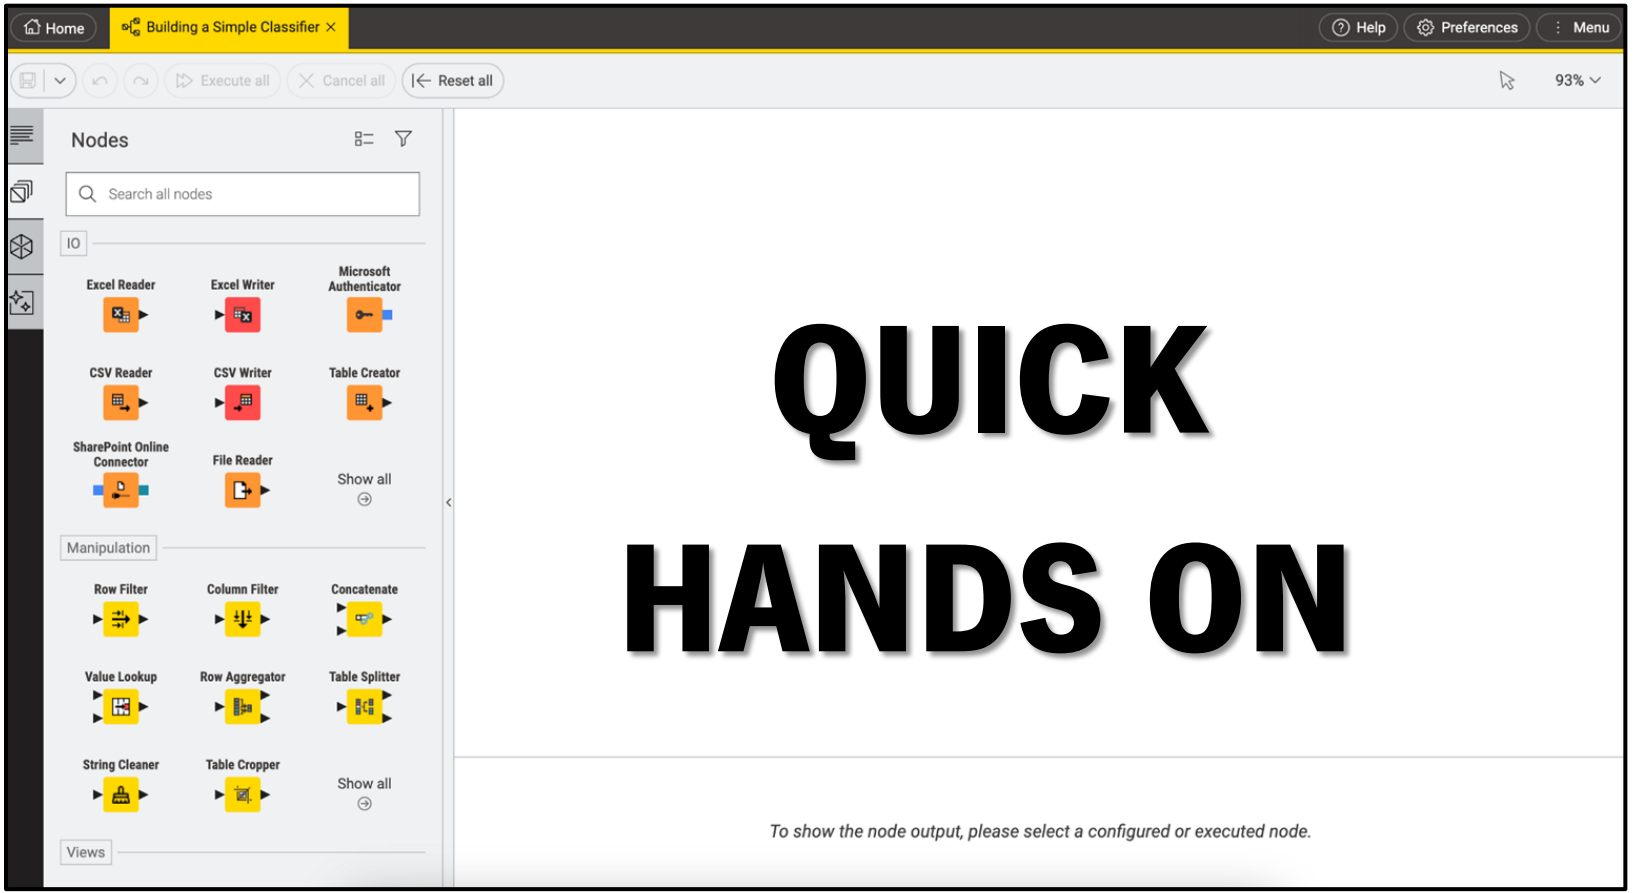


# QUICK HANDS ON

**Universidade do Minho**
Departamento de Informática

# Preparação e Exploração avançada de dados com KNIME

**LEI @ 2025/2026, 2º sem**