

Guião de Apresentação — ADI Grupo 36

Duração total: ~10 minutos | Apresentadores: Jorge Fernandes, Diogo Fernandes, Hugo Soares

Slide 1 — Título

Tempo sugerido: 30 segundos

"Boa tarde a todos. Somos o Grupo 36 da unidade curricular de Aprendizagem e Decisão Inteligentes — eu sou o [nome], estou aqui com o [nome] e o [nome]. O nosso trabalho incidiu sobre dois datasets distintos: um dataset atribuído pela equipa docente, relacionado com produção energética, e um dataset escolhido por nós, sobre músicas do Spotify. Vamos apresentar o processo completo — desde a preparação dos dados até à avaliação crítica dos modelos."

Slide 2 — Agenda

Tempo sugerido: 30 segundos

"A apresentação está dividida em quatro blocos principais. Começamos pelo dataset atribuído — contexto, preparação e resultados. Depois passamos ao dataset do Spotify — a nossa escolha de grupo — onde seguimos o mesmo processo. Ao longo de tudo, usámos a metodologia CRISP-DM como guia estruturante e a plataforma KNIME para construir os workflows. No final, partilhamos as principais conclusões e análise crítica dos modelos."

Slide 3 — Dataset Atribuído: Visão Geral

Tempo sugerido: 1 minuto

"O dataset atribuído contém 8 783 registos e 24 colunas, cobrindo maioritariamente o ano de 2024. Os dados incluem variáveis energéticas, meteorológicas e temporais registadas em Portugal."

"Definimos dois problemas de machine learning. O primeiro é um problema de **classificação**: prever a variável `Productions`, que representa o nível de produção energética agregada — com 5 classes: Alto, MedioAlto, Médio, MedioBaixo e Baixo. O segundo é um problema de **regressão**: prever o valor contínuo de `Photovoltaics kWh`, ou seja, a produção fotovoltaica, usando apenas variáveis meteorológicas e temporais."

"Esta separação foi intencional — queríamos ter um cenário explicativo com todas as variáveis, e um cenário mais realista sem acesso direto às variáveis de produção."

Slide 4 — Data Preparation: Dataset Atribuído

Tempo sugerido: 1 minuto

"A preparação dos dados revelou vários desafios. O primeiro foi a elevada percentagem de valores em falta nas colunas rain e precipitation — perto de 80% — o que tornou a sua remoção a decisão mais segura. As restantes colunas tinham cerca de 10% de NaN, tratados por imputação separada em treino e teste para evitar fuga de informação."

"O segundo desafio foi a inconsistência na variável Productions: existiam 11 variantes ortográficas diferentes para as mesmas classes — 'Hgh' em vez de 'Alto', 'Lw' em vez de 'Baixo', entre outros. Normalizámos tudo para 5 classes consistentes."

"Outro passo importante foi a extração temporal a partir da coluna DateTime, que nos deu Hour, Month, DayOfWeek, Season e isWeekend — variáveis fundamentais para capturar os padrões diários de produção fotovoltaica, que é zero durante a noite e máxima ao meio-dia."

"Por fim, criámos 5 branches experimentais com diferentes conjuntos de features, para comparar modelos explicativos com modelos genuinamente preditivos — nomeadamente a branch WeatherTime-only, que simula um cenário realista sem variáveis energéticas diretas."

Slide 5 — Resultados: Dataset Atribuído

Tempo sugerido: 1 minuto

"Os resultados da classificação mostram um padrão muito claro. Nas branches com variáveis energéticas — como Except-Photovoltaics e Energy-only — os modelos ensemble atingem até 93,6% de accuracy. O Gradient Boosted Trees destacou-se com 93,4% e Kappa de 0,915."

"No entanto, quando passamos para a branch WeatherTime-only — o cenário realista — o desempenho cai 30 pontos percentuais para 63,7% com Random Forest, e a rede neuronal ficou nos 44,5%. Isto demonstra que parte do desempenho elevado nas outras branches se deve à proximidade entre as variáveis preditoras e o target — quase data leakage implícito."

"Na regressão de Photovoltaics, a Linear Regression obteve o melhor desempenho global com $R^2=0.836$ e RMSE de 5 005, enquanto a Simple Regression Tree teve menor MAE mas pior RMSE, o que indica erros pontuais maiores."

Slide 6 — Dataset Grupo: Spotify

Tempo sugerido: 1 minuto

"Para o dataset de grupo, escolhemos o *Spotify Dataset for ML Practice*, disponível publicamente no Kaggle. A razão da escolha foi a riqueza do dataset: 114 000 faixas musicais, 125 géneros distintos, e — o que foi determinante — um segundo ficheiro com **feature engineering** já aplicado, expandindo as 24 colunas originais para 158 features."

"Isso permitiu-nos centrar o trabalho na fase de modelação em KNIME, sem precisar de implementar todas as transformações de raiz."

"Definimos dois problemas. Para regressão, usámos a variável `popularity` já normalizada em Z-Score — escala aproximada de -1.5 a 3. Para classificação, criámos a variável binária `isdancehit`, que vale 1 quando uma faixa tem simultaneamente $\text{danceability} \geq 0.7$ e $\text{energy} \geq 0.6$, ou seja, músicas altamente dançáveis e energéticas."

Slide 7 — Feature Engineering do Spotify

Tempo sugerido: 45 segundos

"As 24 colunas originais são atributos acústicos extraídos diretamente da API do Spotify — `danceability`, `energy`, `loudness`, `valence`, tempo, entre outros. O dataset com **feature engineering** adicionou 134 colunas derivadas organizadas em vários grupos."

"Os mais relevantes incluem: 114 colunas de **one-hot encoding** para os géneros musicais; **interações entre features** como `happy_dance` — produto de `valence` por `danceability` — e `loud_energy_ratio`; **transformações cíclicas** do tom musical com seno e cosseno para preservar a sua natureza periódica; e **clusters de mood** pré-computados."

"A análise exploratória confirmou padrões esperados: correlação positiva entre `energy` e `loudness`, correlação negativa entre `acousticness` e `energy`, e um forte desequilíbrio de classes na variável `isdancehit` — a grande maioria das faixas é classe 0, o que exigiu tratamento explícito antes da modelação."

Slide 8 — Data Preparation: Spotify

Tempo sugerido: 1 minuto

"O pipeline de preparação no KNIME seguiu 7 etapas sequenciais."

"Começámos com o **Duplicate Row Filter**, que reduziu o dataset de 114 000 para 113 999 registos — uma faixa aparecia em múltiplos géneros, e este passo garantiu que cada música fosse representada apenas uma vez."

"Seguiu-se o tratamento de valores em falta em duas passagens: a primeira com lógica diferenciada — média para distribuições simétricas, mediana para assimétricas como tempo e `loudness`; a segunda como segurança após o tratamento de outliers."

"O **Numeric Outliers** foi configurado com o método IQR, multiplicador 1.5, aplicado a tempo, `loudness`, `popularity` e `duration_ms` — com substituição pelos valores limite para preservar todos os registos."

"Na normalização, usámos Z-Score para a maioria das colunas. Para o ramo RProp MLP, foi necessário um Normalizer Min-Max exclusivo para popularity, porque este nodo do KNIME exige que o target esteja no intervalo 0-1."

"Por fim, a divisão treino-teste foi feita com Table Partitioner a 70/30, estratificada por género com seed=42 para reprodutibilidade. Para a classificação, o Equal Size Sampling equilibróu as classes de isdancehit antes dos modelos."

Slide 9 — Regressão: Spotify

Tempo sugerido: 1 minuto

"Para a regressão de popularity, testámos 5 modelos com abordagens distintas."

"O resultado mais interessante é que o Gradient Boosted Trees e a Linear Regression ficaram praticamente empatados — R^2 de 0.725 e 0.723, respetivamente, com RMSE de 0.493 e 0.495. Esta diferença de apenas 0.002 em R^2 indica que, após o feature engineering aplicado, as relações entre as features e a popularity tornaram-se aproximadamente lineares — o que retira a vantagem habitual dos modelos ensemble."

"O Random Forest ficou em terceiro com $R^2=0.687$, e a Simple Regression Tree em quarto com $R^2=0.531$, evidenciando overfitting ou insuficiente capacidade de generalização face aos ensemble."

"O resultado mais crítico foi o RProp MLP com $R^2=0.039$ e $RMSE=0.922$ — essencialmente sem poder preditivo. A causa mais provável é a necessidade de normalização Min-Max do target para o intervalo 0-1, exigida pelo nodo no KNIME. Mesmo com essa normalização aplicada, os hiperparâmetros — 2 camadas, 50 neurónios, 500 iterações — podem ter sido insuficientes para este volume de dados, ou a rede ficou presa num mínimo local."

"O MAE do GBT de 0.249 significa que, em média, as previsões erram menos de 0.25 unidades na escala Z-Score, o que corresponde a cerca de 5-6 pontos na escala original de popularidade 0-100."

Slide 10 — Classificação: Spotify

Tempo sugerido: 1 minuto

"Os resultados da classificação são os mais interessantes de analisar — porque demonstram perfeitamente por que a accuracy isolada é uma métrica enganosa quando as classes estão desbalanceadas."

"A Decision Tree obteve Kappa de 0.947 com accuracy de 99.98% — excelente resultado real, com capacidade discriminativa genuína."

"O Random Forest apresentou Kappa de 1.0 e accuracy de 100% — classificação perfeita. Este resultado merece análise crítica: é possível que as features *danceability* e *energy*, que definem diretamente a variável *isdancehit*, não tenham sido excluídas do Column Filter. Se isso aconteceu, o modelo aprendeu trivialmente a regra de definição da variável-alvo — o que constitui *data leakage*. Ainda assim, demonstra que modelos baseados em árvores capturam regras de limiar de forma extremamente eficiente."

"O Naive Bayes teve accuracy de 95.6% mas Kappa de apenas 0.072 — praticamente um classificador aleatório em termos de concordância real. A razão estrutural é que o Naive Bayes assume independência condicional entre as features, mas *danceability* e *energy* — as variáveis que definem *isdancehit* — são altamente correlacionadas."

"O SVM com kernel RBF é o caso mais extremo: accuracy de 99.8% mas Kappa de 0.0. O modelo está simplesmente a prever sempre a classe majoritária — *isdancehit*=0 — sem qualquer poder discriminativo sobre a classe positiva. Kappa zero confirma isso."

Slide 11 — Análise Crítica

Tempo sugerido: 45 segundos

"Quatro lições principais que retiramos deste projeto."

"Primeira: feature engineering pré-aplicado acelera muito a iteração, mas pode linearizar as relações ao ponto de modelos simples competirem com ensemble — foi o que aconteceu no Spotify com GBT $\approx$ Linear Regression."

"Segunda: accuracy alta não significa modelo bom em dados desbalanceados. O SVM com 99.8% e Kappa zero é o exemplo perfeito. Em problemas de classificação desequilibrada, Cohen's Kappa ou F1-Score são as métricas corretas."

"Terceira: as branches experimentais no dataset energético foram fundamentais para distinguir modelos explicativos de modelos preditivos genuínos. A diferença de 30 pontos percentuais entre Except-Photovoltaics e WeatherTime-only revela claramente onde estava o *data leakage* implícito."

"Quarta: redes neuronais em dados tabulares no KNIME exigem cuidado especial de configuração. O RProp MLP com $R^2=0.039$ não é um problema inerente ao modelo — é uma limitação de hiperparâmetros e de pré-processamento específico do nodo."

Slide 12 — Conclusão

Tempo sugerido: 30 segundos

"Para resumir: no dataset atribuído, o Gradient Boosted Trees foi o melhor classificador no cenário com variáveis energéticas, e a Linear Regression liderou a regressão de Photovoltaics. No dataset Spotify, o GBT foi também o melhor modelo de regressão para popularity, e a Decision Tree — com Kappa de 0.947 — foi o modelo de classificação mais fiável sem suspeita de *leakage*."

"Analisámos no total quase 114 000 faixas musicais e mais de 8 700 registos energéticos, construímos workflows completos em KNIME seguindo CRISP-DM, e aprendemos que as métricas certas e a análise crítica dos resultados são tão importantes quanto os próprios modelos."

"Obrigado pela atenção — ficamos disponíveis para perguntas."

Dicas de Apresentação

- **Distribuição de slides por apresentador:** Cada membro apresenta ~4 slides para tempo equilibrado
- **Transições:** Aguardar que o slide carregue completamente antes de começar a falar
- **Dados numéricos:** Falar devagar ao apresentar R^2 , accuracy e Kappa — dar tempo para o público processar
- **Análise crítica:** Este é o slide que mais diferencia uma apresentação boa de uma excelente — não ter pressa aqui
- **Perguntas frequentes a preparar:**
 - *"Por que escolheram o dataset Spotify?"* → Riqueza de features, FE pré-aplicado, problema real e apelativo
 - *"Por que o RProp MLP falhou?"* → Limitação de normalização do target no KNIME + hiperparâmetros
 - *"O RF com $\kappa=1.0$ é válido?"* → Pode ser data leakage se danceability/energy não foram removidos; demonstra sensibilidade do modelo a features diretamente correlacionadas com o target