



Universidade do Minho
Departamento de Informática

Redes Neurais Artificiais

ADI³ - LEI @ 2025/2026, 2º sem




- Sistemas conexionistas
- Redes Neurais Artificiais
- Resolução de problemas com RNA
- Treino de RNA






Aprendizagem por Máquinas (Machine Learning)



Source: The map of the machine learning world
Vasily Zubarev (vas3k.com)



- [Inteligência Artificial:](#)




inteligência artificial

- [Informática] Ramo da ciência da computação que estuda o desenvolvimento de sistemas computacionais com base no conhecimento sobre a inteligência humana (sigla: *I.A.*).


⌘ Origem etimológica: latim *intelligentia*, -ae, plural neutro de *intelligens*, -entis, particípio presente de *intelligo*, -ere, perceber, compreender.



- [Inteligência Artificial:](#)



The screenshot shows the Priberam Dictionary interface. At the top is the logo 'priberom DICCIONÁRIO'. Below it are language selection buttons for 'PT' (Portuguese) and 'BR' (Brazilian Portuguese). A search bar contains the text 'inteligência'. The definition for 'inteligência artificial' is displayed, starting with '[Informática] Ramo da ciência da computação que e'. Below the definition, there is a section for etymology: 'Origem etimológica: latim *intelligentia*, -ae, plural *intelligo*, -ere, perceber, compreender.'





Machine Learning **Definição**

- *“Every aspect of learning or any other feature of intelligence can in principle be so precisely described that a machine can be made to simulate it.*

An attempt will be made to find how to make machines use language, form abstractions and concepts, solve kinds of problems now reserved for humans, and improve themselves.”

John McCarthy, Dartmouth Conference, 1956

<http://jmc.stanford.edu>



- Cada aspeto da aprendizagem ou qualquer outra característica da inteligência pode, em princípio, ser descrito de forma tão precisa que será possível construir uma máquina para o simular.
Serão feitas tentativas para descobrir como fazer com que as máquinas usem a linguagem, formem abstrações e conceitos, resolvam tipos de problemas até agora reservados para os humanos, e sejam capazes de se melhorarem a si próprias.



Machine Learning **Definição**

- *“Machine learning is an application of artificial intelligence that provides systems the ability to automatically learn and improve from experience without being explicitly programmed. Machine learning focuses on developing computer programs that can access data and use it to learn for themselves.”*

Marco Varone et al.


(www.expertsystem.com/machine-learning-definition)



- Aprendizagem computacional é uma aplicação de inteligência artificial que permite que, de forma automática, os sistemas aprendam e melhorem a partir da experiência, sem necessidade de serem explicitamente programados. Esta aprendizagem foca-se no desenvolvimento de programas que usam dados para aprenderem por si próprios.




Redes Neurais Artificiais



youtube.com/watch?v=aircAruvnKk



Evolução Redes Neurais Artificiais



S. McCulloch - W. Pitts



F. Rosenblatt



B. Widrow - M. Hoff



M. Minsky - S. Papert




D. Rumelhart - G. Hinton - R. Williams




V. Vapnik - C. Cortes




G. Hinton - S. Ruslan




- Adjustable Weights
- Weights are not Learned




- Learnable Weights and Threshold




- XOR Problem



- Solution to nonlinearly separable problems
- Big computation, local optima and overfitting



- Limitations of learning prior knowledge
- Kernel function: Human Intervention



- Hierarchical feature Learning

[linkedin.com/pulse/history-neural-networks](https://www.linkedin.com/pulse/history-neural-networks)



Evolução Redes Neurais Artificiais

THE NOBEL PRIZE

Geoffrey Hinton

Facts

-- Facts



© Nobel Prize Outreach.

Photo: Clément Morin

Geoffrey Hinton

Nobel Prize in Physics 2024

Born: 6 December 1947, London, United Kingdom

Affiliation at the time of the award: University of Toronto,
Toronto, Canada

Prize motivation: “for foundational discoveries and inventions
that enable machine learning with artificial neural networks”

Prize share: 1/2

XOR Problem

nobelprize.org/prizes/physics/2024/hinton/facts/

Neural Network
(Pretraining)

Multi-layered
Perceptron
(Backpropagation)

SVM

Electronic Brain

Perceptron

1943

1957

1940


1950




S. McCulloch – W. Pitts



F. Rosenblatt B. Widrow




- Adjustable Weights
- Weights are not Learned



- Learnable Weights and Biases



G. Hinton – S. Ruslan




- Hierarchical feature Learning



Definição

Redes Neurais Artificiais

- Uma **Rede Neuronal Artificial** (RNA) é um sistema computacional de base conexionista para a resolução de problemas.
- Uma RNA é concebida com base num **modelo** simplificado **do sistema nervoso central** dos seres humanos.
- Uma RNA é definida por uma estrutura interligada de unidades computacionais, designadas **neurónios**, com capacidade de **aprendizagem**.






Definição

Redes Neurais Artificiais

- Uma **Rede Neuronal Artificial** (RNA) é um sistema computacional de base conexionista para a resolução de problemas.
- Uma RNA é concebida com base num **modelo** simplificado do **sistema nervoso central** dos seres humanos.
- Uma RNA é definida por uma estrutura interligada de unidades computacionais, designadas **neurónios**, com capacidade de **aprendizagem**.




Copyright © 2005 Pearson Education, Inc. Publishing as Pearson Benjamin Cummings. All rights reserved.



Definição


Redes Neurais Artificiais

- Uma **Rede Neuronal Artificial** (RNA) é um sistema computacional de base conexionista para a resolução de problemas.
- Uma RNA é concebida com base num **modelo simplificado do sistema nervoso central** dos seres humanos.
- Uma RNA é definida por uma estrutura interligada com a capacidade de **aprendizagem**.






- Reconhecimento de caracteres
- Detecção de fraudes
- Reconhecimento de áudio/vídeo
- Processamento de linguagem natural



Por onde andam? Redes Neurais Artificiais





Por onde andam? Redes Neurais Artificiais






Por onde andam? Redes Neuronais Artificiais

▪ AlphaGO (Google DeepMind)

- A partida entre Lee Sedol (o campeão do mundo de GO) e a máquina não correu bem (para o ele!);
- GO é um jogo para 2 participantes, similar ao xadrez, mas bastante mais complexo;
- AlphaGO combina *deep neural networks* (avaliação) e algoritmos de procura Monte Carlo (seleção), numa combinação de paradigmas de aprendizagem supervisionada e por reforço.



deepmind.com/blog/alphago-zero-starting-from-scratch





Por onde andam? Redes Neuronais Artificiais

▪ AlphaGO (Google DeepMind)


○ A partida entre Lee Sedol (o campeão do mundo de GO) e a máquina não correu bem (para o ele!);

○ GO é um jogo para 2 participantes similar ao xadrez mas bastante mais complexo;

○ AlphaGO combina *deep reinforcement learning* (aprendizagem por reforço profundo) com Monte Carlo (seleção), numa abordagem de aprendizagem supervisionada e não supervisionada.




deepmind.com/blog/alphago-zero-starting-from-scratch





O cérebro humano


- 100.000.000.000 neurónios
- 10.000 entradas por neurónio
- 1 sinal eletroquímico em cada neurónio
- Neurónios são conectados através de neurotransmissores químicos (dopamina, serotonina, glutamato ↑, gama-aminobutírico ↓)
- Representa 2% da massa do corpo humano
- Recebe 25% do sangue bombeado pelo coração





O “cérebro” artificial


- Perceptron (por volta de 1960)






O “cérebro” artificial

- Perceptron (por volta de 1960)



- Função linear


p	q	and
V	V	V 
V	F	F 
F	V	F 
F	F	F 






O “cérebro” artificial

- Perceptron (por volta de 1960)



- Função linear


p	q	or
V	V	V 
V	F	V 
F	V	V 
F	F	F 





O “cérebro” artificial


- Perceptron (por volta de 1960)




csulb.edu/~cwallis/artificialn/History

- Função linear

p	q	or
V	V	V
V	F	V
F	V	V
F	F	F




p	q	xor
V	V	F
V	F	V
F	V	V
F	F	F





0 “cérebro” artificial


- Perceptron (por volta de 1960)



csulb.edu/~cwallis/artificialn/History

- Função linear


p	q	xor
V	V	F 
V	F	V 
F	V	V 
F	F	F 





O “cérebro” artificial


- Perceptron (por volta de 1960)



csulb.edu/~cwallis/artificialn/History

- Função linear


p	q	xor
V	V	F 
V	F	V 
F	V	V 
F	F	F 





O “cérebro” artificial


- Perceptron (por volta de 1960)



csulb.edu/~cwallis/artificialn/History

- Função linear

p	q	xor
V	V	F 
V	F	V 
F	V	V 
F	F	F 








Problema: XOR

p	q	xor
1	1	0
1	0	1
0	1	1
0	0	0


- Função de ativação:
 $\mathcal{F}_A = \sum \text{entradas} \times \text{pesos}$

- Função de transferência:






Problema: XOR Perceptron



$$F_A = \sum \text{entradas} \times \text{pesos}$$




p	q	xor
1	1	
1	0	
0	1	
0	0	






Problema: XOR Multi-layer Perceptron




$$\mathcal{F}_A = \sum \text{entradas} \times \text{pesos}$$




p	q	xor
1	1	
1	0	
0	1	
0	0	



Problema: XOR Multi-layer Perceptron




$$F_A = \sum \text{entradas} \times \text{pesos}$$



p	q	xor
1	1	0
1	0	1
0	1	1
0	0	0



Conceitos e definições






Conceitos e definições Neurónio

- **Unidade computacional** de composição da RNA.
- **Identificado** pela sua **posição** na rede.
- Caracterizado pelo **valor do estado**.

NEURÓNIO






Conceitos e definições

Axónio

- **Via de comunicação** entre os neurónios.
- Pode **ligar qualquer neurónio**, incluindo o próprio.
- As ligações podem **variar** ao longo do **tempo**.
- A informação circula em **um só sentido**.






Conceitos e definições

Sinapses

- **Ponto de ligação** entre axónios e neurónios.
- O **valor da sinapse** determina o **peso** (importância) do sinal a entrar no neurónio: excitativo, inibidor ou nulo.
- A **variação no tempo determina a aprendizagem** da RNA.






Conceitos e definições

Ativação

- O valor de ativação é representado por **um único valor**.
- O valor de ativação **varia com o tempo**.
- A gama de valores varia com o modelo adotado (normalmente está dependente das entradas e de algum efeito de memória).






Conceitos e definições

Transferência




- O valor de transferência de um neurónio determina **o valor** que é **colocado na saída** (transferido através do axónio).
- É calculado como uma função do valor de ativação (eventualmente com algum efeito de memória).





- Cálculo do valor de saída (output = O_i), função do valor de ativação, por uma função de transferência (f_T):

$$O_i = f_T (A_i)$$



- Cálculo do valor de ativação (A_j).
- Varia no tempo com o seu próprio valor e o de outras entradas ($w_i ; I$):


$$A_j = \mathcal{F}(A_{j-1}; I_j; \sum w_{i,j} \times O_i)$$

- **Aprendizagem:** regras de modificação dos pesos (w_i).




Organização dos neurónios


- Arquitetura *Feed forward*, de uma só camada:
(*Perceptron*)



- Arquitetura *Feed forward*, multi-camada:
(*Multi-layer Perceptron*)




- Arquitetura Recorrente






- Sem supervisão:



(p.ex., quando dois neurónios adjacentes têm variações da ativação no mesmo sentido, então o peso da ligação deve ser progressivamente aumentado.)



- Com supervisão:



(p.ex., os ajustes nos pesos das ligações são efetuados por forma a minimizar o erro produzido pelos resultados da RNA.)

- De reforço: o exemplo contém, apenas, uma indicação sobre a correção do resultado.



Regras de aprendizagem

- O treino de uma RNA corresponde à **aplicação de regras de aprendizagem**, por forma a fazer **variar os pesos das ligações** (sinapses);






Regras de aprendizagem

- O treino de uma RNA corresponde à **aplicação de regras de aprendizagem**, por forma a fazer **variar os pesos das ligações** (sinapses);
- Regras de aprendizagem mais comuns:
 - *Hebbian Learning Rule*
 - Desenvolvida por Donald Hebb em 1949 para o treino não supervisionado de RNAs;
 - Se dois neurónios adjacentes sofrem variações no mesmo sentido, o peso da ligação deve aumentar;
 - Se as variações acontecem em sentido oposto, o peso da ligação deve diminuir;
 - Não havendo variação, o peso deve manter-se inalterado;
 - Os pesos são inicializados a zero;

$$W_{ij} = x_i * x_j$$






Regras de aprendizagem

- O treino de uma RNA corresponde à **aplicação de regras de aprendizagem**, por forma a fazer **variar os pesos das ligações** (sinapses);
- Regras de aprendizagem mais comuns:
 - *Hebbian Learning Rule*
 - *Perceptron Learning Rule*

- Desenvolvida para aprendizagem supervisionada;
- Os pesos iniciais são atribuídos aleatoriamente;
- Os *inputs* são processados pela rede e comparados com o *output* desejado;
- Calcula-se o erro produzido pela rede na forma:

$$\sum_i \sum_j (E_{ij} - O_{ij})^2$$


- A função de alteração dos pesos usa este erro para calcular a atualização dos seus valores;





Regras de aprendizagem


- O treino de uma RNA corresponde à **aplicação de regras de aprendizagem**, por forma a fazer **variar os pesos das ligações** (sinapses);
- Regras de aprendizagem mais comuns:
 - *Hebbian Learning Rule*
 - *Perceptron Learning Rule*
 - *Widrow-Hoff Learning Rule*
 - Desenvolvida por Bernard Widrow e Marcian Hoff;
 - A principal diferença para *Perceptron Learning* é a de que é usado um sinal linear e não binário para cálculo do erro e consequente atualização dos pesos;





Regras de aprendizagem

- O treino de uma RNA corresponde à **aplicação de regras de aprendizagem**, por forma a fazer **variar os pesos das ligações** (sinapses);
- Regras de aprendizagem mais comuns:
 - *Hebbian Learning Rule*
 - *Perceptron Learning Rule*
 - *Widrow-Hoff Learning Rule*
 - *Competitive Learning Rule*
 - Desenvolvida para aprendizagem não supervisionada;
 - Os neurónios de *output* competem entre si para representarem o padrão do *input*;
 - O neurónio com maior *output* para um dado *input* é declarado vencedor, sendo o único a alterar os pesos;





Regras de aprendizagem

- O treino de uma RNA corresponde à **aplicação de regras de aprendizagem**, por forma a fazer **variar os pesos das ligações** (sinapses);
- Regras de aprendizagem mais comuns:
 - *Hebbian Learning Rule*
 - *Perceptron Learning Rule*
 - *Widrow-Hoff Learning Rule (Delta Rule)*
 - *Competitive Learning Rule (Winner-takes-it-all Rule)*
 - *Correlation Learning Rule*
 - *Outstar Learning Rule (Grossberg Rule)*





Treino de uma RNA (Afinação de parâmetros)

- Quantidade de neurónios:
 - na camada de entrada;
 - na camada de saída;
 - nas camadas intermédias;
- Níveis (ou camadas) da RNA;
- Ligações entre neurónios;
- Topologia das ligações;
- Esquema de atribuição e atualização dos pesos;
- Funções:
 - de transferência;
 - de ativação;
 - de aprendizagem;
- Métodos de treino.







- Considere-se uma Rede Neuronal Artificial...

RNA




- ... composta por 2 neurónios à entrada e 1 à saída...






- ... *feed forward*, completamente ligada, com 1 camada intermédia.






- Os exemplos de treino contêm os resultados pretendidos, pelo que a aprendizagem será supervisionada.





- Atribuição aleatória dos pesos às sinapses.




$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = A$$




- Fluxo dos dados pela rede, calculando os valores de ativação...



$$f_A(P, E) = \sum P \times E$$
$$f_T(A) = A$$



- ... para todos os neurónios da camada intermédia.




$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = A$$



- Cálculo do valor de transferência (dado pela função identidade por facilidade de demonstração!).




$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = A$$




- Fluxo da informação e cálculo do valor de ativação na camada de saída...



$$f_A(P,E) = \sum P \times E$$
$$f_T(A) = A$$



- ... e respetivo valor de transferência.




$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = A$$



- Cálculo do erro na camada de saída...




$$\mathcal{E} = OUT_D - OUT_C$$

$$\mathcal{E}_{\leftarrow} = \mathcal{E} \times P$$



- ... e cálculo do valor estimado do erro na camada intermédia.




$$\mathcal{E} = OUT_D - OUT_C$$

$$\mathcal{E}_{\leftarrow} = \mathcal{E} \times P$$




- Aplicação de uma regra de atualização dos pesos das sinapses...



$$P_{i+1} = P_i + \epsilon \times f_T$$




- ... para atualizar os valores das sinapses de todos os neurónios.



$$P_{i+1} = P_i + \epsilon \times f_T$$



- Segunda iteração da propagação do caso de treino...




$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = A$$




- ... e cálculo do erro produzido pela RNA na segunda iteração.





Referências bibliográficas

- Cortez, P., Neves, J., “Redes Neurais Artificiais”, Unidade de Ensino, Departamento de Informática, Universidade do Minho, 2000;
- Haykin, S., “Neural Networks - A Comprehensive Foundation”, Prentice-Hall, New Jersey, 1999, ISBN 978-0-13-273350-2;
- Bishop, Christopher M., “Neural networks for pattern recognition”, Clarendon Press, 1995, ISBN 978-0-19-853849-3;
- Charu C. Aggarwal, “Neural Networks and Deep Learning”, Springer, 2018, ISBN 978-3-319-94463-0.





Universidade do Minho
Departamento de Informática

Redes Neurais Artificiais

ADI³ - LEI @ 2025/2026, 2º sem